缺失标签下多标签分类的无偏损失函数

Erik Schultheis；Rohit Babbar
阿尔托大学计算机科学系
Konemiehentie 2, 02150 Espoo
两位作者的电子邮箱均按原文记为 firstname.lastname@aalto.fi。
编辑：〔原文此栏留空〕

原文版本与译文说明。 本译文以用户上传的研究交接压缩包中所含完整 PDF 为唯一正文来源：arXiv:2109.11282v1 [cs.LG]，2021 年 9 月 23 日，共 45 页。原文页眉题名为“缺失标签下用于评估与训练的无偏损失函数”；正文题名如上。此为私人使用的非官方中文全译，涵盖正文、参考文献及全部附录。原有署名、版本信息和其他权利声明均保留；本译文不增加开放许可，也不表示获得公开再分发授权。公式、图、表中的原始符号与数值采用原文裁图保留；裁图内英文的必要释义随文给出。原文的公式写法及潜在排印问题不作无声修正。源文件 SHA-256：8a4b307e9a905404ed1a3d2d2f93aaf5c8a0bd2da7bac949a03f30bb8427e66f。

摘要

本文研究标签独立地以已知概率缺失时的二分类与多标签分类问题。标签缺失在极端多标签分类（XMC）任务中普遍存在，例如为维基百科文章从数十万个候选标签中匹配一个很小的子集；在这类任务中，任何人工标注者都不可能检验所有负样本是否确实为负。因此，倾向评分精确率——在已知噪声模型下对 precision-at-k 的无偏估计——已成为 XMC 的标准指标之一。仅有少数方法在训练阶段就考虑这一问题，而且它们都局限于能够分解为各标签贡献之和的损失函数。常见训练策略是将多标签问题归约为一系列二分类或多分类问题。已有研究表明，如果代理任务要对召回率优化保持一致性，所得到的损失函数就无法按标签分解。因此，本文推导了各种多标签归约（包括不可分解归约）的唯一无偏估计量。这些估计量会增大方差，并可能使优化问题不适定；我们通过改用凸上界处理这一问题。实验研究进一步补充了理论分析，表明改用无偏估计量会显著改变偏差—方差权衡，因此可能需要更强的正则化，而在某些情况下，这会抵消无偏估计带来的收益。

1 引言

极端多标签分类（XMC）是一种机器学习设定，其目标是：针对每个数据实例，从极其庞大的候选标签集合（数千至数百万个标签）中预测一个很小的正标签（或相关标签）子集。此类问题见于大型百科全书的标注（Dekel and Shamir, 2010；Partalas et al., 2015）、细粒度图像分类（Deng et al., 2010）和下一词预测（Mikolov et al., 2013）。XMC 还应用于推荐系统、网络广告以及搜索引擎中的相关搜索预测（Agrawal et al., 2013；Prabhu and Varma, 2014；Jain et al., 2019；Dahiya et al., 2021）。

这些场景中的典型数据集规模很大，可能产生数十亿个“数据—标签”对。这意味着人工标注者无法检查每一对，因此可用训练数据很可能含有错误。即便只标注少量样本以生成干净测试集，成本也可能高得难以承受。幸运的是，在许多情况下可以限制标注错误的结构。以文档打标签为例，可以假设标注者已

经判断所添加的每个标签都与文档相关，因此这些标签较为可靠地是正确标签。另一方面，标注者不可能检查数十万个负标签。这就引出了本文研究的标签缺失设定：只有正标签受噪声影响（可能缺失），负标签则保持不变（不会产生伪标签）。正式定义见第 2 节；关于标签缺失及相关设定的既有研究，更完整的讨论见第 8 节。

许多机器学习方法通过最小化数据分布上的期望损失来学习，通常以经验风险作为统计估计量。因此，扩展到标签缺失设定的一种自然方式，是根据带噪数据构造真实风险的无偏估计。在 XMC 中，Jain et al. (2016) 提出了这一思路，为一些常用损失函数构造了倾向评分版本。他们假设每个标签不缺失的概率（称为该标签的倾向概率，propensity）已知，并提出了根据数据统计量估计这些概率的经验模型。该模型假定所有数据点的倾向概率相同（标签缺失与特征无关），且含有两个依赖于数据集的参数；这些参数仅在少数基准数据集上得到确定并公开。尽管有这些不足，所得倾向评分指标仍在 XMC 中广泛使用（Bhatia et al., 2016）。

然而，许多用于训练的损失，例如二元交叉熵和平方铰链损失，并不在 Jain et al. (2016) 的适用范围内。因此，许多使用倾向评分精确率作为评估指标的方法，训练时仍采用为干净标签设计的损失函数（Dahiya et al., 2021；Guo et al., 2019；You et al., 2019；Babbar and Schölkopf, 2019）。

基于 Natarajan et al. (2017) 在类别条件噪声设定下给出的无偏估计量，Qaraei et al. (2021) 为若干常见损失函数提供了无偏版本。与相关学习设定中的观察相似（Kiryo et al., 2017；Chou et al., 2020），他们发现无偏估计可能非凸、无下界，并因高方差而造成严重过拟合。本文进一步给出唯一性结果（定理 7），说明不存在方差更小的其他无偏估计；还给出泛化界（定理 6），提示了实践中观察到的偏差—方差权衡。一种缓解策略是把这些损失视为 0-1 损失的凸代理，并从“代理损失的无偏估计”转向“无偏估计的凸代理”（Qaraei et al., 2021；Chou et al., 2020）。

XMC 问题常表述为排序任务，目标是最大化前 k 个预测中的召回率或精确率。通常不直接优化这些指标，而是将任务归约为一系列二分类或多分类问题，不同归约分别对召回率或精确率保持一致性（Menon et al., 2019）。

对精确率一致的归约产生的损失可写成各标签贡献之和，因此能够应用 Natarajan et al. (2017) 的方法。相比之下，对召回率一致的归约包含一个归一化项，即真实标签总数的倒数。计算召回率本身也需要这一项，说明有必要为真正不可分解的多标签损失函数构造无偏估计。

定理 12 给出一般多标签情形的唯一无偏估计。该结果可视为 Van Rooyen and Williamson (2017, Theorem 5) 的特例：其结论是，将标签污染算子的伴随算子的逆作用于给定预测对应的所有 2^l 个损失值组成的向量，即可得到无偏估计；对于具有 l 个候选标签的问题，该算子为 $2^l \times 2^l$ 矩阵。我们直接计算得到的解，其计算量仅对观测到的标签数呈指数增长。在大规模多标签问题中，相关标签通常远少于候选标签（Jain et al., 2016）。如果相关标签数按对数增长，那么我们的方法只需对损失函数求值 $O(l)$ 次。

推导的基础是将观测标签建模为真实标签与一个未知掩码变量的乘积。注意，这不同于具有已标注和未标注数据的半监督学习：掩码仅用于数学处理方便，并不假设知道其实际取值。这种表述的优点是，即便所建模的噪声是类别条件噪声，也可以选取一个与其他所有随机变量独立的掩码变量实现。

为了判断方差与过拟合问题在实践中的严重程度，我们进行了两个实验。〔原文此处再次重复“我们进行了两个实验”。〕首先，在纯评估设定中，随着缺失标签比例变化计算无偏 recall@k。结果表明，当缺失比例过大时，估计方差会爆炸，以致无法使用。因此，这一指标只能在倾向概率适中且数据点数量较多的数据集上计算。第二个实验展示改用无偏估计后偏差—方差权衡的变化。我们使用不同版本的损失函数，在不同 L_2 正则化强度下训练线性模型。发现带噪标签训练通常使最优权衡移向更强的正则化；对于不可分解损失的高方差无偏估计，原始损失版本反而比无偏版本表现更好。

综上，本文的主要贡献如下。

1. 将标签缺失建模为真实标签与独立掩码变量的乘积（定义 2），使证明和推导中的期望运算更方便。先在二分类情形展示其用途，推导关于无偏估计量唯一性（定理 7）与方差的新结果，并给出泛化界（定理 6），它是 Natarajan et al. (2017, Lemma 8) 的修正版。

2. 给出一般多标签函数的无偏估计（定理 12）。它们可应用于归一化损失归约（Menon et al., 2019），而这类归约是对 recall@k 保持一致性的训练所必需的。结果表明，即便仅无偏估计 recall@k，也会成为相当复杂的过程：与 precision@k 相比，它需要对观测标签的所有子集的贡献求和。

3. 研究缺失标签与无偏估计对偏差—方差权衡的影响。我们验证了泛化界所提示的直觉：用无偏损失训练可能导致严重过拟合，需要重新调整正则化，有时甚至完全抵消无偏估计的收益。若能够构造凸上界，可用它们缓解这一问题。

2 记号与问题设定

本文用大写字母 $X, Y, \ldots$ 表示随机变量，用花体字母表示集合，用小写字母表示集合元素，如 $x \in \mathcal{X}$。当需要利用向量可分解为分量 $y_1, \ldots, y_k$ 这一事实时，用粗体表示向量，如 $\mathbf{y} \in \mathcal{Y}$。字母 f, g, h 专用于函数，i, j, k 表示整数。$[k]$ 表示集合 $\{1, \ldots, k\}$；$\mathcal{M}(A, B)$ 是从 A 到 B 的全部可测映射组成的集合。

具有 l 个候选标签的多标签数据点有两种自然表示：$\{0, 1\}^l$ 中的向量，或 $[l]$ 的子集。我们主要采用前者，故令 $\mathcal{Y} = \{0, 1\}^l$。在子集记法更方便时，用 $\mathcal{I}(\mathbf{v}) := \{i \in [l] : v_i = 1\}$ 表示相应转换，用 $\mathbf{1}^{(\mathcal{I}(\mathbf{v}))} = \mathbf{v}$ 表示反向转换。〔原文对前一转换的文字方向写为“从子集到向量”，此处保留定义本身；按定义实际为向量到子集。〕

全文假设一个抽象概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$。用 $\mathcal{X}$ 表示数据空间，$\mathcal{Y}$ 表示标签空间，$\widehat{\mathcal{Y}}$ 表示预测空间。数据集通过三个随机变量 $X \in \mathcal{X}$、$\mathbf{Y} \in \mathcal{Y}$ 和 $\mathbf{Y}^* \in \mathcal{Y}$ 定义，分别表示数据、观测标签和真实标签。与不可观测真值有关的量通常带星号上标，且称 $\left(X, \mathbf{Y}^*\right)$ 为干净数据。

给定损失函数 $f : \mathcal{Y} \times \widehat{\mathcal{Y}} \to \mathbb{R}$，分类器 $h : \mathcal{X} \to \widehat{\mathcal{Y}}$ 的真实风险和观测风险记为：

$$\mathrm{R}_f^*[h] := \mathbb{E}[f(\mathbf{Y}^*, h(X))], \mathrm{R}_f[h] := \mathbb{E}[f(\mathbf{Y}, h(X))],$$

对应的经验风险记为 $\widehat{\mathrm{R}}_f^*$ 和 $\widehat{\mathrm{R}}_f$。

本文关注的标签噪声只能使标签缺失。接下来的两个定义描述这种情况：第一个从现象上刻画问题设定，第二个定义用于描述该设定的数学模型。

定义 1（倾向概率）。引言中非正式描述的标签缺失设定，对 l 个随机变量给出如下条件：

$$\mathbb{P}\{Y_j = 1 \mid Y_j^* = 1, X\} =: p_j \qquad \textit{labels may go missing,} \tag{1}$$
$$\mathbb{P}\{Y_j = 1 \mid Y_j^* = 0, X\} = 0 \qquad \textit{but no spurious labels.} \tag{2}$$

其中，式（1）表示标签可能缺失，式（2）表示不会出现伪标签。$p_j \in (0,\, 1]$ 称为标签 j 的倾向概率。

在 Jain et al. (2016) 的模型中，数据集含 n 个数据点，标签 j 出现 n_j 次。给定依赖数据集的常数 $a,\, b$ 以及 $c := (\log n - 1)(b+1)^a$，倾向概率由下式确定：

$$p_j = (1 + c\exp(-a\log(n_j + b))^{-1}. \tag{3}$$

定义 2（掩码模型）。$\mathbf{Y}^*$ 与 $\mathbf{Y}$ 的关系可用一组掩码随机变量 $\mathbf{M} \in \{0,\, 1\}^l$ 建模，使得 $\mathbf{Y} = \mathbf{M} \odot \mathbf{Y}^*$。要求掩码与数据和标签相互独立。

与 Jain et al. (2016) 相比，这似乎增加了限制，因为他们看似没有作任何独立性假设。然而，他们的定理要求预测固定，用我们的记法即 X 为常量，因此与 X 的独立性实际上隐含成立。此外，他们假定逐样本的倾向概率已知，即对于数据集 $\big((x_1,\, \mathbf{y}_1),\, \ldots,\, (x_n,\, \mathbf{y}_n)\big)$，需要知道完整倾向概率矩阵 p_{ij}，其中 $i \in [n],\, j \in [l]$；也就是每个实例 i 和每个标签 j 的倾向概率都必须已知。而他们估计倾向概率的经验模型只产生数据集层面的值，因此隐含假设 $p_{ij} = p_{kj}$ 对全部 $i,\, k \in [n],\, j \in [l]$ 成立。

要满足单侧类别条件噪声模型的条件，需要：

$$\mathbb{P}\{Y_j = 1 \mid Y_j^* = 1\} = \mathbb{P}\{Y_j^* = 1, M_j = 1 \mid Y_j^* = 1\} = \mathbb{P}\{M_i = 1 \mid Y_j^* = 1\} \overset{!}{=} p_j \tag{4}$$
$$\mathbb{P}\{Y_j = 1 \mid Y_j^* = 0\} = \mathbb{P}\{Y_j^* = 1, M_j = 1 \mid Y_j^* = 0\} = 0, \tag{5}$$

为使记法简洁，省略了对 X 的条件。因此，可选择 $\mathbf{M}$ 使得：

$$p_j = \mathbb{P}\{M_j = 1 \mid Y_j^* = 1\} = \mathbb{P}\{M_j = 1 \mid Y_j^* = 0\} = \mathbb{P}\{M_j = 1\} = \mathbb{E}[M_j]\,, \tag{6}$$

这意味着 M_j 与真实标签向量 $\mathbf{Y}^*$ 及数据点 X 独立。

3 二分类损失的无偏估计

本节首先推导二分类损失无偏估计的一般解，并证明其唯一性。进一步证明一个泛化界，展示无偏损失与原始损失之间的偏差—方差权衡。最后说明如何把二分类结果用于损失可分解的多标签情形，即一对其余（one-vs-all，OvA）和选取全部标签（pick-all-labels，PAL）归约（Menon et al., 2019）。

这里的技术主要依赖问题的两个性质：

- 标签空间是离散的，因此可把损失函数重写为每一种标签取值所作贡献的和。
- $\mathbf{M}$ 的独立性使得：对于含有 M_i 的乘积，可将其期望中的该因子替换为乘以 p_i。

3.1 二分类无偏损失的推导

由于此处只考虑二分类，省略标签的向量记号及相应下标。这里的“二分类”指判断某个标签是否存在（“这张图片中有没有狗？”），而非在两个类别之间作决定（“这张图片里是狗还是猫？”）。

首先定义倾向评分算子：它将一个函数映射为一个可补偿标签缺失的代理函数，并证明这确实产生无偏估计。

定义 3（PS 算子）。设 $\mathcal{Z}$ 为任意集合，$\mathcal{V}$ 为向量空间，$f^* : \{0,\ 1\}\times\mathcal{Z} \to \mathcal{V}$ 为一个函数。由于第一个参数只能取 0 和 1，可分解为：

$$f^*(y, z) =: y f^*_+(z) + (1 - y) f^*_-(z). \tag{7}$$

对任意 $p \in (0,\ 1]$，将下式定义的 $f : \{0,\ 1\}\times\mathcal{Z} \to \mathcal{V}$ 称为 f^* 的倾向评分版本：

$$f(y, z) := y\frac{f^*_+(z) + (p - 1)f^*_-(z)}{p} + (1 - y)f^*_-(z) \tag{8}$$

映射 $\mathfrak{P}_p : f^* \mapsto f$ 称为倾向概率 p 下的倾向评分（PS）算子。〔算子的具体字形以原公式为准。〕

一般而言，f^* 的凸性和非负性并不保证 f 的凸性和非负性，参见 3.2 节。PS 算子给出无偏估计，如下所示。

定理 4（存在缺失二元标签时的无偏估计）。在掩码模型下，令 $k \in \mathbb{N}$ 且 $f^* : \{0,\ 1\}\times\mathcal{X} \to \mathbb{R}^k$，则 $f := \mathfrak{P}_p\left(f^*\right)$ 可用于计算 f^* 的无偏估计：

$$\mathbb{E}[f^*(Y^*, X)] = \mathbb{E}[f(Y, X)]\,. \tag{9}$$

证明。利用期望的线性性以及 M 的独立性，可以计算：

$$\begin{aligned}
\mathbb{E}[f(Y, X)] &= \mathbb{E}[MY^* f_+(X) + (1 - MY^*)f_-(X))] \\
&= \mathbb{E}[M]\,\mathbb{E}\big[Y^*(f_+(X) - f^*_-(X))\big] + \mathbb{E}\big[f^*_-(X)\big] \\
&= p\,\mathbb{E}\big[Y^*(p^{-1}\left(f^*_+(X) + (p - 1)f^*_-(X)\right) - f^*_-(X)\big] + \mathbb{E}\big[f^*_-(X)\big] \\
&= \mathbb{E}\big[Y^*\left(f^*_+(X) - f^*_-(X)\right)\big] + \mathbb{E}\big[f^*_-(X)\big] \\
&= \mathbb{E}[f^*(Y^*, X)]\,.
\end{aligned}$$

该定理对应于 Natarajan et al. (2017, Lemma 7)。实践中，损失函数的参数是某个分类器 φ 给出的预测，因此需要以下结论。

推论 5（二分类损失函数的梯度）。 设 $\varphi : \mathcal{X}\times\mathbb{R}^k \to \mathbb{R}$ 为具有 $k \in \mathbb{N}$ 个参数的二分类器，$\ell^* : \{0,\,1\}\times\mathbb{R} \to \mathbb{R}$ 为损失函数，$\ell = \mathfrak{P}_p\big(\ell^*\big)$。假定掩码 M 与 $\big(X,\,Y^*,\,\mathbf{W}\big)$ 独立。则：

$$\begin{aligned}\mathbb{E}[\ell^*(Y^*, \phi(X,\mathbf{W}))] &= \mathbb{E}[\ell(Y, \phi(X,\mathbf{W}))]\\ \mathbb{E}[\nabla_{\mathbf{W}}\ell^*(Y^*, \phi(X,\mathbf{W}))] &= \mathbb{E}[\nabla_{\mathbf{W}}\ell(Y, \phi(X,\mathbf{W}))]\,.\end{aligned}$$

证明。 X, $\mathbf{W}$ 与 M 的独立性蕴含 $\varphi(X;\,\mathbf{W})$ 与 M 独立。第二个等式可通过令 $\mathcal{X}' = \mathcal{X}\times\mathbb{R}^k$，将定理 4 应用于损失函数的梯度，并利用 $\mathfrak{P}_p$ 算子、期望与梯度的线性性得到。细节见附录 B.1。

3.2 示例

平方误差。 对平方误差 $f^*_{\mathrm{SE}}\big(y,\,\widehat{y}\big) = \big(y-\widehat{y}\big)^2$，无偏估计为：

$$f_{\mathrm{SE}}(y,\hat{y}) = \frac{y}{p}\,(1-2\hat{y}) + \hat{y}^2, \tag{10}$$

这里利用了 $y \in \{0,\,1\}$ 所以 $y^2 = y$。当标签存在（$y=1$）时，该式在 $\widehat{y} = y/p$ 处取最小值。最小值点落在区间 $[0,\,1]$ 外，如图 1 所示。

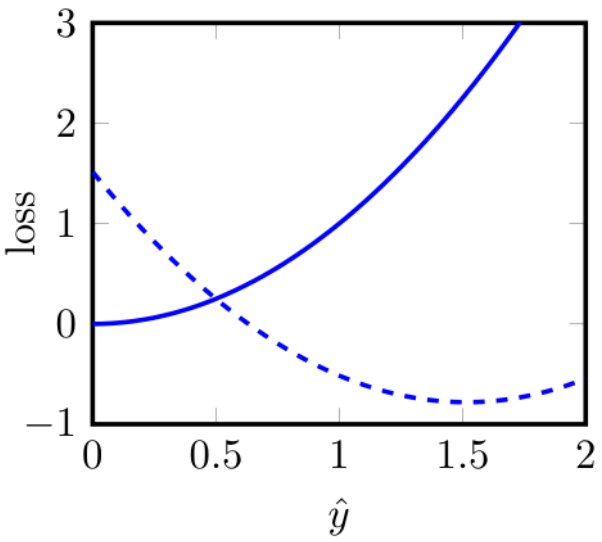


图 1。 倾向评分平方误差损失。虚线表示 $y=1$ 时的损失，实线表示 $y=0$ 时的损失。倾向概率取 $p = 0.66$。纵轴 loss 为“损失”，横轴为预测值 $\widehat{y}$。

二元交叉熵。 BCE 损失为：

$$f^*_{\mathrm{BCE}}(y,\hat{y}) = -y\log(\hat{y}) - (1-y)\log(1-\hat{y}). \tag{11}$$

由于该式关于 y 为线性，可以直接写出无偏估计：

$$f_{\mathrm{BCE}}(y,\hat{y}) = -\frac{y}{p}\log(\hat{y}) - \left(1-\frac{y}{p}\right)\log(1-\hat{y}). \tag{12}$$

注意，由于 BCE 损失无上界，无偏 BCE 损失便无下界；从优化角度看，这可能是不利的。

3.3 无偏估计量的性质

尽管无偏估计保证在数据无限时给出正确结果，但在有限数据下究竟有多大帮助，并不直接明了。在相关的正例—未标记学习（PU 学习）和互补标签学习问题中，虽然已知无偏估计量，但实践发现它们存在问题（Kiryo et al., 2017；Chou et al., 2020）。

第一个问题是，即便原始损失被选为凸函数，无偏估计量也可能不凸。Natarajan et al. (2017, Lemma 10) 给出了凸性的一个充分条件。事实上，如果原始损失无上界（例如铰链损失、逻辑损失和平方损失），无偏估计甚至可能无下界，从而使优化问题失去良好定义。处理方法之一是放弃无偏性，转而使用第 5 节讨论的凸代理损失。

方差。 无偏估计量的第二个潜在问题是方差。对于二分类情形，可以证明当 $p \to 0$ 时，与在干净数据上评估相比，方差按 p^{-1} 增长。无噪声时，方差为：

$$\begin{aligned}\mathbb{V}[f^*(\hat{y}, Y^*)] &= \mathbb{V}\left[Y^* f_+^*(\hat{y}) + (1 - Y^*) f_-^*(\hat{y})\right] \\ &= \mathbb{V}[Y^*] \left(f_+^*(\hat{y}) - f_-^*(\hat{y})\right)^2 \end{aligned} \tag{13}$$

带噪估计量的方差为：

$$\begin{aligned}\mathbb{V}[f(\hat{y}, Y)] &= \mathbb{V}\left[Y \frac{f_+^*(\hat{y}) + (p-1) f_-^*(\hat{y})}{p} + (1 - Y) f_-^*(\hat{y})\right] \\ &= \mathbb{V}[Y] \left(\frac{f_+^*(\hat{y}) + (p-1) f_-^*(\hat{y})}{p}\right)^2 + \mathbb{V}[Y]\, f_-^*(\hat{y})^2 \\ &= \mathbb{V}[Y] \frac{\left(f_+^*(\hat{y}) + (p-1) f_-^*(\hat{y})\right)^2 + p^2 f_-^*(\hat{y})^2}{p^2}. \end{aligned} \tag{14}$$

当倾向概率远小于 1 时，可近似为下式（回忆 $q := \mathbb{E}[Y]$）：

$$\approx \mathbb{V}[Y] \frac{\left(f_+^*(\hat{y}) - f_-^*(\hat{y})\right)^2}{p^2} = q(1-q) \frac{\left(f_+^*(\hat{y}) - f_-^*(\hat{y})\right)^2}{p^2}. \tag{15}$$

令 $q^* := \mathbb{E}\left[Y^*\right] = q/p$，利用 $1 - q = 1 - pq^* \approx 1$，得到：

$$\mathbb{V}[f(\hat{y}, Y)] \approx \frac{q(1-q)}{p^2} \frac{\mathbb{V}[f^*(\hat{y}, Y^*)]}{q^*(1-q^*)} \approx \frac{1}{p(1-q^*)} \mathbb{V}[f^*(\hat{y}, Y^*)], \tag{16}$$

这意味着方差随逆倾向概率线性增大。

泛化。 上述分析提示两种选择之间可能存在偏差—方差权衡：无偏损失可能更强烈地过拟合观测噪声；原始损失函数则即使在 $n \to \infty$ 时仍给出错误结果。理解这一点的第一步是确定泛化误差的上界（证明见附录 B.2）。

定理 6（泛化界）。设 $\mathcal{H}$ 是 Rademacher 复杂度为 $\mathfrak{R}_n(\mathcal{H})$ 的函数类。设 $f^* : \mathcal{Y}\times\widehat{\mathcal{Y}} \to [a, b]$ 是关于第二个参数 ρ-Lipschitz 连续的损失函数，其中 $a < b$ 且 $a, b \in \mathbb{R}$。令 $f{:=}\mathfrak{P}_p f^*$，并记：

$$r^\star \coloneqq \inf_{h\in\mathcal{H}} \mathrm{R}^*_{f^*}[h]\,, \quad \hat{h} \coloneqq \operatorname*{argmin}_{h\in\mathcal{H}} \hat{\mathrm{R}}_f[h]\,, \quad \tilde{h} \coloneqq \operatorname*{argmin}_{h\in\mathcal{H}} \hat{\mathrm{R}}_{f^*}[h]\,. \tag{17}$$

以及：

$$\begin{aligned} c &\coloneqq \rho\,\mathfrak{R}_n(\mathcal{H}) + (b-a)\sqrt{\frac{\log(2/\delta)}{2n}} \\ m &\coloneqq \sup_{x\in\mathcal{X}}(|f^*(1,x) - f^*(0,x)|). \end{aligned} \tag{18}$$

对于由 n 个点组成的给定样本，以下结论以至少 $1-\delta$ 的概率成立：

$$\hat{r} \coloneqq \mathrm{R}^*_{f^*}\left[\hat{h}\right] \qquad \leq r^\star \qquad\qquad + 2\frac{2-p}{p}c \tag{19}$$

$$\tilde{r} \coloneqq \mathrm{R}^*_{f^*}\left[\tilde{h}\right] \qquad \leq r^\star + \qquad q\frac{1-p}{p}m \qquad + 2c, \tag{20}$$

其中 $q{:=}\mathbb{E}[Y] \leq 1$。

给定假设类 $\mathcal{H}$，其针对 n 个样本点的期望 Rademacher 复杂度定义为：

$$\mathfrak{R}_n(\mathcal{H}) = \mathbb{E}\left[\sup_{h\in\mathcal{H}} \sum_{i=1}^{n} \sigma_i h(X_i)\right], \tag{21}$$

其中 $\sigma_i \in \{-1, 1\}$ 是独立的 Rademacher 随机变量（参见 Shalev-Shwartz and Ben-David, 2014，第 26 章）。

原始损失函数的界除了贝叶斯误差和近似误差 $r^\star$ 外，还含有第二个偏差项 $q\big(1-p\big)m/p$，它不会随 n 增大而减小。另一方面，无偏估计在依赖样本量的项前引入因子 $\big(2-p\big)/p$。这提示：当训练样本很少时，无偏损失的经验风险最小化可能得到更差的分类器。

唯一性。上述结果引出一个问题：是否存在方差更小、泛化更好的其他无偏估计量？例如，条件期望 $\mathbb{E}\left[f^*\big(Y^*, X\big) \mid Y\right]$ 也给出方差较小的无偏估计，但如果不知道条件概率 $\mathbb{P}\{Y \mid X\}$，便无法计算。下面的定理说明，如果事先知道标签的边缘概率，则 $\mathfrak{P}_p$ 本质上唯一；否则它完全唯一。因此，不能借此降低方差。

定理 7（唯一性）。设 $|\mathcal{X}| \geq 2$，$p \in (0, 1]$，$q \in (0, p]$，$\mathcal{F} = \mathcal{M}\big(\{0, 1\}\times\mathcal{X}, \mathbb{R}\big)$ 为一个函数集合。设 $\mathfrak{P} : \mathcal{F} \to \mathcal{F}$ 是一个算子，将函数映射为标签缺失设定下的无偏估计，使得对于满足倾向概率为 p、边缘概率为 q 的掩码模型的所有 X, Y, Y^*，均有：

$$\forall f^* \in \mathcal{F} : \mathbb{E}[f^*(Y^*, X)] = \mathbb{E}[\mathfrak{P}(f^*)(Y, X)]\,. \tag{22}$$

则 $\mathfrak{P}$ 与倾向评分算子 $\mathfrak{P}_p$ 的关系为：

$$\mathfrak{P}(f^*)(y,x) = \mathfrak{P}_p(f^*)(y,x) + (y-q)\gamma \tag{23}$$

其中某个 $\gamma \in \mathbb{R}$。由于这一项不会改变对 x 的依赖，从学习角度看，倾向评分算子 $\mathfrak{P}_p$ 本质上唯一。

证明。 充分性由定理 4 得到；必要性可通过选取 X 集中在两个点上的 $X,\ Y^*$ 分布证明，见 B.1。

3.4 可分解为二分类损失的多标签损失

利用期望的线性性，上述结果可直接推广到下列形式的多标签损失函数。

定义 8（可分解损失函数）。 若多标签损失函数 $f^*: \mathcal{Y}\times\mathbb{R}^l \to \mathbb{R}$ 可写为下式，则称其为可分解损失：

$$f^*(\mathbf{y},\hat{\mathbf{y}}) = \sum_{i=1}^{l} f_i^*(y_i,\hat{\mathbf{y}}), \tag{24}$$

其中 $f_i^*: \{0,\ 1\}\times\mathbb{R}^l \to \mathbb{R}$。其他多标签损失称为不可分解损失。

对于可分解损失函数，有以下结论。

推论 9（可分解损失的无偏估计）。 设 f^* 是由分量函数 f_i^* 构成的可分解多标签损失，对应的倾向评分函数为 $f_i{:=}\mathfrak{P}_{p_i}\left(f_i^*\right)$。则函数：

$$f(\mathbf{y},\hat{\mathbf{y}}) \coloneqq \sum_{i=1}^{l} f_i(y_i,\hat{\mathbf{y}}), \tag{25}$$

应用于按照掩码模型生成的带噪标签时，给出真实损失的无偏估计。

证明。 由期望的线性性得到。

作为推论，可以写出两种重要多标签归约特例——OvA 和 PAL 归约——的无偏估计（Menon et al., 2019）。在 OvA 归约中，真实／观测标签与预测都被分解到二分类设定，因此分量函数由二分类损失 $g_i^*: \{0,\ 1\}\times\mathbb{R} \to \mathbb{R}$ 通过 $f_i^*\left(y_i,\ \widehat{\mathbf{y}}\right) = g_i^*\left(y_i,\ \widehat{y_i}\right)$ 生成。通常所有标签使用相同的二分类损失，但我们保留更一般的表述，允许根据标签频率采用不同权重或间隔参数，以缓解标签不平衡。

推论 10（一对其余）。 对具有二分类损失 g_i^* 的一对其余归约，可由下式计算无偏估计：

$$f(\mathbf{y},\hat{\mathbf{y}}) \coloneqq \sum_{i=1}^{l} \mathfrak{P}_{p_i}\left(g_i^*\right)(y_i,\hat{y}_i). \tag{26}$$

选取全部标签归约同样限制了 f_i^* 的结构，因为只有标签存在时，PAL 归约才有非零贡献。

推论 11（选取全部标签）。 对于 PAL 损失函数：

$$f^*(\mathbf{y}, \hat{\mathbf{y}}) = \sum_{i=1}^{l} y_i f_i^*(\hat{\mathbf{y}}), \tag{27}$$

无偏估计由下述函数给出：

$$f(\mathbf{y}, \hat{\mathbf{y}}) := \sum_{i=1}^{l} \frac{y_i}{p_i} f_i^*(\hat{\mathbf{y}}). \tag{28}$$

这意味着在 PAL 设定中，无偏估计只是原始分量函数的加权和。特别地，如果这些分量函数是凸的（有界的），无偏估计也同样是凸的（有界的）。

4 多标签损失的无偏估计

本节考虑无法将损失分解为逐标签贡献的一般多标签情形。首先推导一般表达式及其性质，然后应用于两种特殊情形；它们是许多具体多标签损失的构成基础。最后推导归一化 PAL 与 OvA 分解，以及召回率和成对损失的表达式。

4.1 一般多标签情形

对于一般多标签情形，可得如下结论。

定理 12（多标签损失）。 设 $l \in \mathbb{N}$， $f^* : \{0,\ 1\}^l \times \mathcal{X} \to \mathbb{R}$ 为某个映射。可用下列倾向评分表达式 $\mathfrak{P}_{\mathbf{p}}\left(f^*\right) = f$ 计算该函数的无偏估计：

$$(\mathbf{y}, x) \mapsto \left(\prod_{i \in \mathcal{I}(\mathbf{y})} \frac{1}{p_i} \right) \cdot \sum_{\mathcal{J} \subset \mathcal{I}(\mathbf{y})} f^*(\mathbf{1}^{(\mathcal{J})}, x) \prod_{j \in \mathcal{I}(\mathbf{y}) \setminus \mathcal{J}} (p_j - 1)\,, \tag{29}$$

其中， $\mathbf{1}^{(\mathcal{J})} \in \{0,\ 1\}^l$ 在所有 $j \in \mathcal{J}$ 对应的分量上取 1。

证明。 将 f^* 按 $\mathbf{Y}$ 的每种可能取值分解为各自的贡献： $f^*(\mathbf{Y},\ X) = \sum_{\mathbf{y}} \mathbb{1}\{\mathbf{Y} = \mathbf{y}\} f^*\left(\mathbf{y},\ X\right)$，再把指示函数写成 Y_i 和 $1 - Y_i$ 的乘积。随后利用期望的线性性及 $\mathbf{M}$ 的独立性。细节见补充材料 B.3。

把定理 12 应用于二分类情形，得到：

$$f(0, x) = f^*(0, x) \qquad (J = \emptyset) \tag{30}$$

$$\begin{aligned} f(1, x) &= \frac{p - 1}{p} \cdot \left(f^*(0, x) + f^*(1, x)\,(p - 1)^{-1} \right) \\ &= p^{-1} \cdot \left(f^*(0, x)(p - 1) + f^*(1, x) \right), \end{aligned} \tag{31}$$

从而恢复定理 4。

遗憾的是，对所有子集求和的结构使这一估计计算昂贵。不过，在标签空间很大的情形下，实际标签向量通常相当稀疏，这在一定程度上缓解了问题，见注 16。即便如此，它仍远比 Van Rooyen and Williamson (2017, Theorem 5) 的一般解高效。

后者以观测之间的转移表示。在本问题中，2^l 种可能的相关标签组合分别对应一个不同观测。他们的无偏估计为：

$$\mathbf{f}(\hat{y}) = R^* \mathbf{f}^*(\hat{y}), \tag{32}$$

其中 R^* 表示污染矩阵的逆的伴随算子，$\mathbf{f}$ 与 $\mathbf{f}^*$ 表示包含每个可能观测对应损失的向量。这意味着，朴素实现需要对 $f^*(\cdot, \mathbf{y})$ 的全部 2^l 种可能值求值，然后用一个稀疏的 $2^l \times 2^l$ 矩阵组合它们。

与二分类情形一样，可给出唯一性定理。

定理 13（多标签唯一性）。 设 $\mathfrak{P}_{\mathbf{p}}$ 为定理 12 中的倾向评分算子，$\mathfrak{P}$ 为另一个算子，并且对所有 f^*、所有 $\mathbf{Y}^*$ 与 X 的分布，均有：

$$\mathbb{E}[f^*(\mathbf{Y}^*, X)] = \mathbb{E}[\mathfrak{P}(f^*)(\mathbf{Y}, X)] \tag{33}$$

则 $\mathfrak{P}\left(f^*\right) = \mathfrak{P}_{\mathbf{p}}\left(f^*\right)$。

证明。 因为 $\mathfrak{P}$ 必须对 X 与 $\mathbf{Y}^*$ 的全部可能分布成立，所以特别也必须适用于 $\mathbb{P}\{X = x, \mathbf{Y}^* = \mathbf{y}\} = 1$。由于 $\mathbf{Y}$ 只有有限种状态，可将 $\mathfrak{P}\left(f^*\right)$ 分解为这些状态上的和。随后对 $\mathbf{y}$ 中非零元素数目作归纳；每一步在分解中只会引入一个新的加项，即可证明结论。细节见补充材料 B.3。

4.2 归一化多标签归约

首先引入归一化归约的一般形式，以便统一处理 PAL-N 与 OvA-N 归约，以及作为具体损失函数的逐实例召回率。归一化归约由基本归约得到：将标签 Y_i^* 替换为重缩放变量 $\widetilde{Y}_i^* = Y_i^* / \sum_{j=1}^{l} Y_j^*$。

定义 14。 如果存在函数 g_i 与 h，使多标签损失 f^* 满足下式，则称其为归一化归约：

$$f^*(\mathbf{y}, \hat{\mathbf{y}}) = h(\hat{\mathbf{y}}) + \sum_{i=1}^{l} \frac{y_i}{\sum_{j=1}^{l} y_j} g_i(\hat{\mathbf{y}}). \tag{34}$$

定义一组随机变量 T_i^*：

$$T_i^* := \frac{Y_i^*}{\sum_{j=1}^{l} Y_j^*} \tag{35}$$

便可将该损失写为 $f^*\left(Y^*,\,\widehat{\mathbf{y}}\right)=\sum_{i=1}^{l}T_i^*g_i\left(\widehat{\mathbf{y}}\right)+h\left(\widehat{\mathbf{y}}\right)$。因此，只需把定理 12 的一般公式用于 T_i^*，并利用线性性，即可计算无偏估计。得到：

$$T_i=\left(\prod_{j\in\mathcal{I}(\mathbf{y})}\frac{1}{p_j}\right)\cdot\sum_{\mathcal{J}\subset\mathcal{I}(\mathbf{y})}\frac{\mathbb{1}\{i\in\mathcal{J}\}}{|\mathcal{J}|}\prod_{k\in\mathcal{I}(\mathbf{y})\setminus\mathcal{J}}(p_k-1)\,. \tag{36}$$

所以，对应的无偏损失函数为：

$$f(\mathbf{y},\hat{\mathbf{y}})=h(\hat{\mathbf{y}})+\left(\prod_{j\in\mathcal{I}(\mathbf{y})}\frac{1}{p_j}\right)\sum_{\mathcal{J}\subset\mathcal{I}(\mathbf{y})}\frac{\sum_{j\in\mathcal{J}}g_j(\hat{\mathbf{y}})}{|\mathcal{J}|}\prod_{k\in\mathcal{I}(\mathbf{y})\setminus\mathcal{J}}(p_k-1)\,. \tag{37}$$

归一化一对其余。令 g_{BC} 为一个二分类损失函数。[脚注 1：推广到依赖标签的损失函数是直接的。] OvA-N 归约定义为：

$$f^*_{\mathrm{OvA-N}}(\mathbf{y},\hat{\mathbf{y}})\coloneqq\sum_{i=1}^{l}\frac{y_i}{\sum_{j=1}^{l}y_j}g_{\mathrm{BC}}(1,\hat{y}_i)+\left(1-\frac{y_i}{\sum_{j=1}^{l}y_j}\right)g_{\mathrm{BC}}(0,\hat{y}_i). \tag{38}$$

逐项比较可见，对应关系为 $g_i\left(\widehat{\mathbf{y}}\right)=g_{\mathrm{BC}}\left(1,\,\widehat{y_i}\right)-g_{\mathrm{BC}}\left(0,\,\widehat{y_i}\right)$，以及 $h\left(\widehat{\mathbf{y}}\right)=\sum_{i=1}^{l}g_{\mathrm{BC}}\left(0,\,\widehat{y_i}\right)$。

归一化选取全部标签。给定多分类损失 g_{MC}，PAL-N 归约为：

$$f^*(\mathbf{y},\hat{\mathbf{y}})\coloneqq\sum_{i=1}^{l}\frac{y_i}{\sum_{j=1}^{l}y_j}g_{\mathrm{MC}}(i,\hat{\mathbf{y}}), \tag{39}$$

立即得到对应关系 $g_i\left(\widehat{\mathbf{y}}\right)=g_{\mathrm{MC}}\left(i,\,\widehat{\mathbf{y}}\right)$ 和 $h\equiv 0$。

逐样本召回率。在多标签设定下，可把召回率定义为被预测出来的相关标签所占比例（Lapin et al., 2018）。这里针对单个样本的全部标签，而非在整个数据集上针对单个标签。因此，对 $\widehat{\mathbf{y}}\in\{0,\,1\}^l$，有：

$$\mathrm{Rec}^*(\mathbf{y},\hat{\mathbf{y}})\coloneqq|\mathcal{I}(\mathbf{y})|^{-1}\sum_{i\in\mathcal{I}(\mathbf{y})}\hat{y}_i. \tag{40}$$

这对应于 $g_{\mathrm{MC}}\left(i,\,\widehat{\mathbf{y}}\right)=\widehat{y_i}$ 的归一化 PAL 归约。

注意，$\widehat{\mathbf{y}}$ 通常也是稀疏向量，例如计算 recall@k 时恰有 k 个非零分量。这可能使计算略为高效。令 $\mathcal{S}\coloneqq\mathcal{I}\left(\mathbf{y}\right)\cap\mathcal{I}\left(\widehat{\mathbf{y}}\right)$，$\mathcal{T}=\mathcal{I}\left(\mathbf{y}\right)\setminus\mathcal{S}$，重新整理各项（见附录 A.1），倾向评分召回率为：

$$\mathrm{Rec}(\mathbf{y},\hat{\mathbf{y}})=\prod_{i\in\mathcal{I}(\mathbf{y})}\frac{p_i-1}{p_i}\cdot\sum_{s=1}^{|\mathcal{S}|}\sum_{\substack{\mathcal{K}\subset\mathcal{S}\\|\mathcal{K}|=s}}\prod_{k\in\mathcal{K}}\frac{1}{p_k-1}\cdot s\left(\sum_{\mathcal{J}\subset\mathcal{T}}\frac{\prod_{j\in\mathcal{J}}(p_j-1)^{-1}}{|\mathcal{J}|+s}\right). \tag{41}$$

无偏估计的一个注意事项是：即使其期望被限制在 $[0,\,1]$ 区间内，单个实例的取值却可能远远偏离该区间。以下例子说明这一点。

表 1。 在预测为标签 0、真实标签为 0 和 1 的条件下，不同观测标签对应的概率、普通召回率及倾向评分召回率。

Y_0	Y_1	Y_2	$\mathbb{P}$	R@1	PsR@1
0	0	0	$4/9$	0	0
0	1	0	$2/9$	0	0
1	0	0	$2/9$	1	3
1	1	0	$1/9$	0.5	$-3/2$

表中 $\mathbb{P}$ 为概率，R@1 为普通 recall@1，PsR@1 为倾向评分 recall@1。

例。 假定 $l = 3$，且 $Y_0^* = Y_1^* = 1 - Y_2^* = 1$ 以概率 1 成立。令预测为 $\widehat{y_0} = 1$、$\widehat{y_1} = \widehat{y_2} = 0$。对于任意 $Y_0 = 0$ 的观测，$\mathcal{S}$ 为空，召回率为 0。当 $Y_0 = 1,\, Y_1 = 0$ 时，$\mathcal{S} = \{0\}$、$\mathcal{T} = \varnothing$，故：

$$\mathrm{Rec} = \frac{p_0 - 1}{p_0} \cdot 1 \cdot \frac{1}{p_0 - 1} = \frac{1}{p_0}. \tag{42}$$

最后，如果 $Y_0 Y_1 = 1$，则 $\mathcal{S} = \{0\}$、$\mathcal{T} = \{1\}$，且：

$$\mathrm{Rec} = \frac{p_0 - 1}{p_0}\frac{p_1 - 1}{p_1}\left(1 + \frac{(p_1 - 1)^{-1}}{2}\right) \cdot \frac{1}{p_0 - 1} = \frac{2(p_1 - 1) + 1}{2 p_0 p_1}. \tag{43}$$

表 1 明确列出了倾向概率为 $1/3$ 时的各状态。期望变为：

$$\mathbb{E}[\mathrm{Recall}] = \frac{2}{9} \cdot 3 + \frac{1}{9} \cdot \frac{-3}{2} = \frac{2}{3} - \frac{1}{6} = \frac{1}{2}, \tag{44}$$

这就是真实召回率。然而，方差明显增大，标准差甚至大于已知包含真实值的整个区间。

5 上界

5.1 OvA 损失的凸上界

机器学习中许多二分类损失都是 0-1 损失的凸代理，例如逻辑损失、铰链损失及平方铰链损失、平方误差。因此，要得到适用于标签缺失的凸损失函数，可以交换操作顺序：不再计算凸代理的无偏估计，而是先计算 0-1 损失的无偏估计，再对所得表达式构造凸代理。

为此，先考虑二分类情形。设 $f^* : \{0,\ 1\} \times \mathbb{R} \to \mathbb{R}$ 关于第二个参数为凸函数，并且是 0-1 损失的上界。对于正标签，0-1 损失的无偏估计量为：

$$\begin{aligned}
\mathfrak{P}_p(f_{01})(1, \hat{y}) &= p^{-1} \left(\mathbb{1}\{\hat{y} \leq 0\} + (p-1)\mathbb{1}\{\hat{y} > 0\} \right) \\
&= p^{-1} \left(\mathbb{1}\{\hat{y} \leq 0\} + (p-1)(1 - \mathbb{1}\{\hat{y} \leq 0\}) \right) \\
&= p^{-1} \left((2-p)\mathbb{1}\{\hat{y} \leq 0\} + p - 1 \right) \\
&= (2/p - 1)\, \mathbb{1}\{\hat{y} \leq 0\} + \text{const.}
\end{aligned} \tag{45}$$

从经验风险最小化角度看，常数不影响结果，因此可忽略。于是，去掉常数后的无偏 0-1 损失的一个凸上界为：

$$f(y, \hat{y}) = y \left(\frac{2}{p} - 1 \right) f^*(1, \hat{y}) + (1 - y) f^*(0, \hat{y}). \tag{46}$$

5.2 归一化多标签归约的上界

前文用下述变量表述归一化多标签归约：

$$T_i^* = \frac{Y_i^*}{\sum_{j=1}^{l} Y_j^*} = \frac{Y_i^*}{1 + \sum_{j \neq i} Y_j^*}. \tag{47}$$

校正带噪标签的一种朴素尝试，是以 Y/p 替换 Y^*，即：

$$\tilde{T}_i \coloneqq \frac{Y_i / p_i}{1 + \sum_{j \neq i} Y_j / p_j}, \tag{48}$$

它不是无偏的。不过，可以证明该表达式满足：

$$\begin{aligned}
\mathbb{E}\left[\tilde{T}_i\right] &= \mathbb{E}\left[\frac{M_i Y_i^* / p_i}{1 + \sum_{j \neq i} M_j Y_j^* / p_j} \right] && (49) \\
&= \mathbb{E}[M_i / p_i]\, \mathbb{E}\left[\frac{Y_i^*}{1 + \sum_{j \neq i} M_j Y_j^* / p_j} \right] && \text{(independence)} \\
&= \mathbb{E}\left[\mathbb{E}\left[\frac{Y_i^*}{1 + \sum_{j \neq i} M_j Y_j^* / p_j} \;\middle|\; \mathbf{Y}^* \right] \right] && \text{(tower)} \\
&= \mathbb{E}\left[Y_i^*\, \mathbb{E}\left[\frac{1}{1 + \sum_{j \neq i} M_j Y_j^* / p_j} \;\middle|\; \mathbf{Y}^* \right] \right] && \text{(measurable factor)}
\end{aligned}$$

各步依次利用独立性、条件期望的塔式法则，以及提出可测因子。

现在对第二个因子应用 Jensen 不等式：

$$\begin{aligned}\mathbb{E}\left[\tilde{T}_i\right] &\geq \mathbb{E}\left[\frac{Y_i^*}{1+\mathbb{E}\left[\sum_{j\neq i} M_j Y_j^*/p_j \mid \mathbf{Y}^*\right]}\right] && \text{(convexity)}\\ &= \mathbb{E}\left[\frac{Y_i^*}{1+\mathbb{E}\left[\sum_{j\neq i} Y_j^* \mid \mathbf{Y}^*\right]}\right] && \text{(masking model)}\\ &= \mathbb{E}\left[\frac{Y_i^*}{1+\sum_{j\neq i} Y_j^*}\right]. && (50)\end{aligned}$$

这里先利用凸性，再利用掩码模型。

注 15。 注意，这不同于直接对朴素公式作替换 $Y^* \leftarrow Y/p$；后者会产生一个并非上界的表达式：

$$\frac{Y_i/p_j}{\sum_{j=1}^{l} Y_j/p_j} = \frac{Y_i/p_j}{p_i^{-1}+\sum_{j\neq i} Y_j/p_j}. \tag{51}$$

T_i^* 在损失函数表达式中可以带正的或负的前置系数。因此，式（37）的一个上界为：

$$\tilde{f}(\mathbf{y},\hat{\mathbf{y}}) \coloneqq h(\hat{\mathbf{y}}) + \sum_{i=1}^{l} \frac{y_i/p_i}{1+\sum_{j=1}^{l} y_j/p_j} g_i(\hat{\mathbf{y}}). \tag{52}$$

应用于 OvA-N 与 PAL-N，得到以下两个表达式：

$$\tilde{f}_{\mathrm{OvA-N}}(\mathbf{y},\hat{\mathbf{y}}) \coloneqq \sum_{i=1}^{l} \frac{y_i/p_i}{1+\sum_{j=1}^{l} y_j/p_j}\left(g_{\mathrm{BC}}(1,\hat{y}_i) - g_{\mathrm{BC}}(0,\hat{y}_i)\right) + g_{\mathrm{BC}}(0,\hat{y}_i) \tag{53}$$

$$\tilde{f}_{\mathrm{PAL-N}}(\mathbf{y},\hat{\mathbf{y}}) \coloneqq \sum_{i=1}^{l} \frac{y_i/p_i}{1+\sum_{j=1}^{l} y_j/p_j} g_{\mathrm{MC}}(i,\hat{\mathbf{y}}). \tag{54}$$

与无偏估计相比，这些表达式不会带来额外计算开销，且从方差角度看也有优势。

6 评估实验

本节以召回率为例，通过实验验证定理 12。先研究合成数据，其倾向概率精确已知，且可计算作为参照的真值。这会表明：即使在理想设定下，如果倾向概率过低，估计方差也会大到无法使用。随后将估计量应用于真实预测，展示它在某些数据集上可用，在另一些数据集上却无用。

考虑 100 个不同标签，各标签独立且出现概率均为 10%。随机抽取 10,000 个真实标签向量，再以所有标签共同的倾向概率 p 删除标签以生成观测标签。预测通过从真实标签中随机选一个生成。用普通估计量、无偏估计量及上界计算平均逐样本召回率，结果绘于图 2。

图中可见，倾向概率小于 0.4 时，无偏估计的方差变得过大。上界也不再适用，因为它显著偏离真实值；有偏的普通估计最终反而最接近真值。倾向概率中等时，无偏估计量的方差仍小，而且精度明显优于普通估计量。结合唯一性定理 13，这些结果表明，对倾向概率很低的数据集，无偏估计不适合计算逐样本召回率。

查看 Bhatia et al. (2016) 展示的结果，会发现召回率指标明显缺席。推测这是因为它们并不容易计算。Jain et al. (2016) 有一节讨论在标签总数已知时如何计算该指标，但其他情形仍留有空白，定理 12 填补了这一空白。遗憾的是，合成数据结果显示，一旦倾向概率太低，这种方法就无法使用。因此它不能应用于 Amazon-670K 或 EURLex-4K 等数据集。

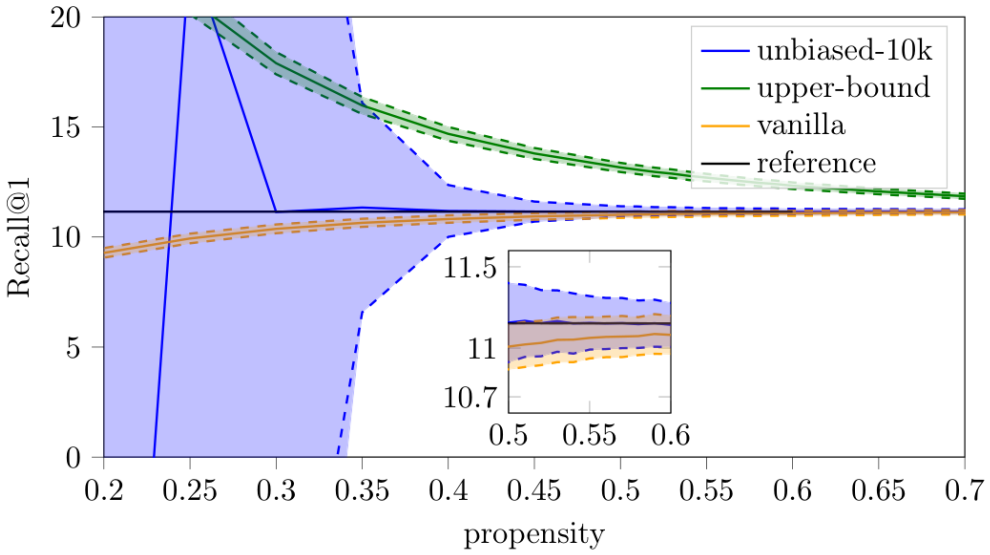


图 2。 按正文所述方式生成的人造数据上的逐样本召回率无偏估计。阴影区域为 100 次重复实验估计出的一个标准差范围，黑线表示真实召回率。图例：unbiased-10k 为 10,000 个样本上的无偏估计，upper-bound 为上界，vanilla 为普通估计，reference 为参考真值；横轴 propensity 为倾向概率，纵轴为 Recall@1。

表 2。 用 Qaraei et al. (2021) 的平方铰链凸代理训练的 DiSMEC 风格模型，其倾向评分 recall@k（式 41）和普通 recall@k（式 40）。Filter 列表示为将方差降至合理水平而作为离群点删除的数据点比例。

	PsRec@k			Rec@k			Filter
Dataset/k	1	3	5	1	3	5	
Bibtex	42.1	65.9	78.3	33.6	53.0	62.0	0%
Mediamill	21.6	49.2	61.9	23.3	52.6	65.6	0%
RCV1-2K	42.4	78.1	82.3	40.4	74.4	80.7	1%
AmazonCat-13K	24.2	57.1	72.3	26.4	59.7	75.0	0.05%
AmazonCat-14K	38.8	68.1	83.0	39.4	69.3	83.9	0.01%

表头 Dataset/k 表示数据集及 k；PsRec@k 表示倾向评分召回率，Rec@k 表示普通召回率，Filter 表示过滤比例。

为生成预测，我们使用平方铰链损失的无偏损失凸代理（Qaraei et al., 2021），训练 DiSMEC 模型（Babbar and Schölkopf, 2017）。计算无偏召回率估计时有两个困难。首先，即使相关标签数的平均值较低，仍可能存在真实标签很多的样本，其计算量高得难以承受；这可以用抽样方法处理。其次，无偏估计的代价是方差大幅增加。事实上，我们发现均值被极少数离群样本主导，得到毫无意义的数值。因此过滤掉最低及最高分位区间中的值。这会使估计有偏，但显著降低方差。细节见补充材料 C.1。

表 2 显示，除 Bibtex 外，各数据集的普通估计与无偏估计的召回率很接近。一个可能原因是，基于超大数据集经验确定的倾向概率模型，并不适合这个小数据集。对数据仓库（Bhatia et al., 2016）中的其他数据集 Amazon-670K、WikiLSHTC-325K 和 EURLex-4K，无偏估计方差太大，无法得到有意义的结果。

7 训练实验

理想情况下，我们会在基于真实数据的任务上比较这些损失函数。然而，对这类数据既不知道精确倾向概率，也无法验证无偏估计与上界是否给出合理结果，因为完全标注的真值未知。

7.1 实验设定

我们没有使用完全人造数据，而是基于现有真实数据构造数据集：从 AmazonCat-13k 仅保留最常见的 100 个标签，按照 Jain et al. (2016) 的模型，它们也是倾向概率最高的标签。根据逆倾向概率人为删除标签；逆倾向概率随标签频率排序线性增加，最常见标签的逆倾向概率为 2，第 100 常见标签为 20。这个过程部分保留了极端分类数据集典型的强不平衡性。

在该数据上进行如下实验：训练带 L_2 正则化的线性分类器，采用不同基础损失，并设置四种配置：a）在干净训练数据上使用普通损失；b）在带噪训练数据上使用普通损失；c）在带噪数据上使用无偏版本；d）在带噪数据上使用上界版本。每次训练后，在带噪和干净的训练集、测试集上评估训练损失以及任务损失 precision@k 和 recall@k。在带噪数据上评估时使用相应的无偏估计量。

用普通损失训练，可得到该网络在无噪声时所能达到性能的上界（配置 a），以及不采取缓解措施时性能会差到何种程度（配置 b）。在第一种配置中，预期干净与带噪数据上的损失计算结果相同，因为模型无法过拟合训练数据中特定的噪声模式；而在配置 b 至 d 中，预期会出现差异。由于标签删除与特征独立，带噪测试数据上的无偏估计应与干净数据上计算的值相等。

上述相等要求测试集含有足够多的样本，从而估计足够精确。

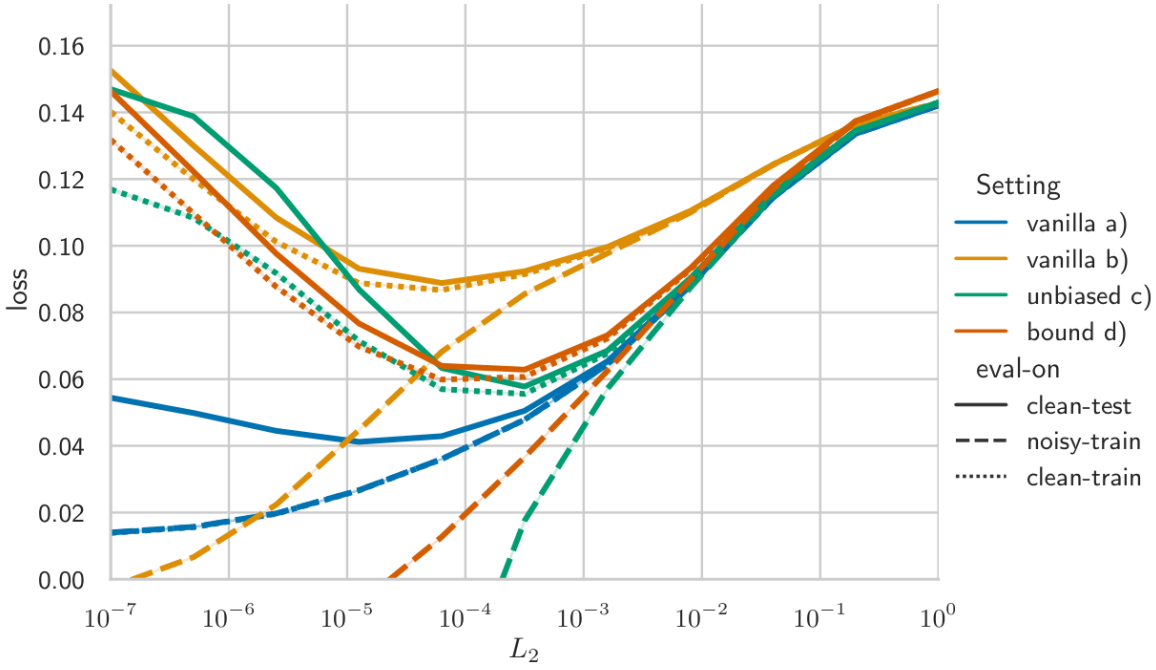


图 3。 不同正则化强度下的二元交叉熵，分别在带噪训练数据、干净训练数据及干净测试数据上评估。虚线与点线之间的差距对应于对噪声模式的过拟合；点线与实线之间小得多的差距，表示有限训练样本造成的额外泛化差距。Setting 表示配置：vanilla a/b 为普通损失配置 a/b，unbiased c 为无偏配置 c，bound d 为上界配置 d。eval-on 表示评估数据：clean-test 为干净测试集，noisy-train 为带噪训练集，clean-train 为干净训练集。纵轴 loss 为损失，横轴为 L_2 正则化强度。

取原训练数据的 30% 作为验证集，用于确定最优 L_2 正则化强度。由于损失函数的选择影响偏差—方差权衡，每种配置都必须单独确定该值。注意，用带噪数据训练时，也用带噪数据验证，即假设完全没有干净数据可用。

网络使用 Adam（Kingma and Ba, 2017）优化，前 15 轮的初始学习率为 10^{-4}，余下 5 轮为 10^{-5}，小批量大小为 512。

7.2 对样本与噪声模式的过拟合

除了训练数据有限导致的过拟合外，标签缺失设定还会引起额外过拟合，因为只能观测到噪声模式的一次实现。

设 h 是依赖于观测数据 Y 的分类器，f^* 是损失函数，其估计量为 $f = \mathfrak{P}_p\left(f^*\right)$。则泛化差距可分解为：

$$\mathrm{R}^*_{f*}[h] - \hat{\mathrm{R}}_f[h] = \underbrace{\mathrm{R}^*_{f*}[h] - \hat{\mathrm{R}}^*_{f*}[h]}_{\text{finite sample}} + \underbrace{\hat{\mathrm{R}}^*_{f*}[h] - \hat{\mathrm{R}}_f[h]}_{\text{noise pattern}}, \tag{55}$$

第一项（finite sample，有限样本）是真实风险 $\mathrm{R}^*_{f^*}[h]$ 与干净训练数据上经验风险 $\widehat{\mathrm{R}}^*_{f^*}[h]$ 的差；第二项（noise pattern，噪声模式）是后者与观测数据上估计的经验风险 $\widehat{\mathrm{R}}_f[h]$ 的差。由于分类器 h 通过 $Y = \mathbf{M} \odot Y^*$ 依赖于掩码变量，f 在训练数据上不再给出无偏估计，因此第二项即使取期望也非零。

事实上，在这里的线性分类器实验中，对噪声模式的过拟合远强于有限抽样导致的过拟合。图 3 展示了 OvA 归约下 BCE 损失的情况；其他损失函数也有同样效果，见补充材料。对于在干净数据上训练的分类器（蓝色），其权重与噪声模式独立，因此虚线和点线在期望上重合。

还可看出，标签噪声起到隐式正则化作用：在正则化较弱时，带噪数据训练得到的分类器，其干净测试集与干净训练集之间的差距远小于干净数据训练的分类器。

7.3 损失最小化的结果

如图 3 所示，在使用 BCE 损失的 OvA 归约中，相比普通损失，无偏损失或上界损失可使训练损失降得更多。这一下降幅度足以弥补泛化差距的增加，所以这两个损失版本的最小损失（即最优正则化下的损失）更好。

这种改进是否也出现在其他归约与损失函数中？图 4 回答了这一问题，它针对不同基础损失，绘制干净测试数据上的损失随 L_2 正则化强度的变化。

第一行是基于 BCE 的损失，左图与图 3 使用同一数据。右图对应归一化归约，其中过拟合增加量超过训练损失的改善量，因此总体上，无偏训练比直接用普通损失训练更差。我们也纳入了用上界公式（48）得到的评估。注意，对归一化 BCE 损失，该公式实际上不构成上界；但图中显示，其经验表现优于无偏损失，仍劣于普通损失。

归一化 BCE 结果有一点令人意外：即使正则化极强，无偏估计仍不如普通损失。我们将其归因于式（38）的非凸性，因为损失上升来自较大的训练损失，而不是泛化差距。选取不同初始权重（见补充材料 C.2），可使无偏训练的训练损失降至普通训练水平，支持“次优极小值导致问题”的假说。与同样非凸的可分解情形相比，归一化情形需要乘以若干逆倾向概率的乘积，因此在导致非凸性的项前引入大得多的系数。这可能解释了为什么可分解归约没有出现相同现象。

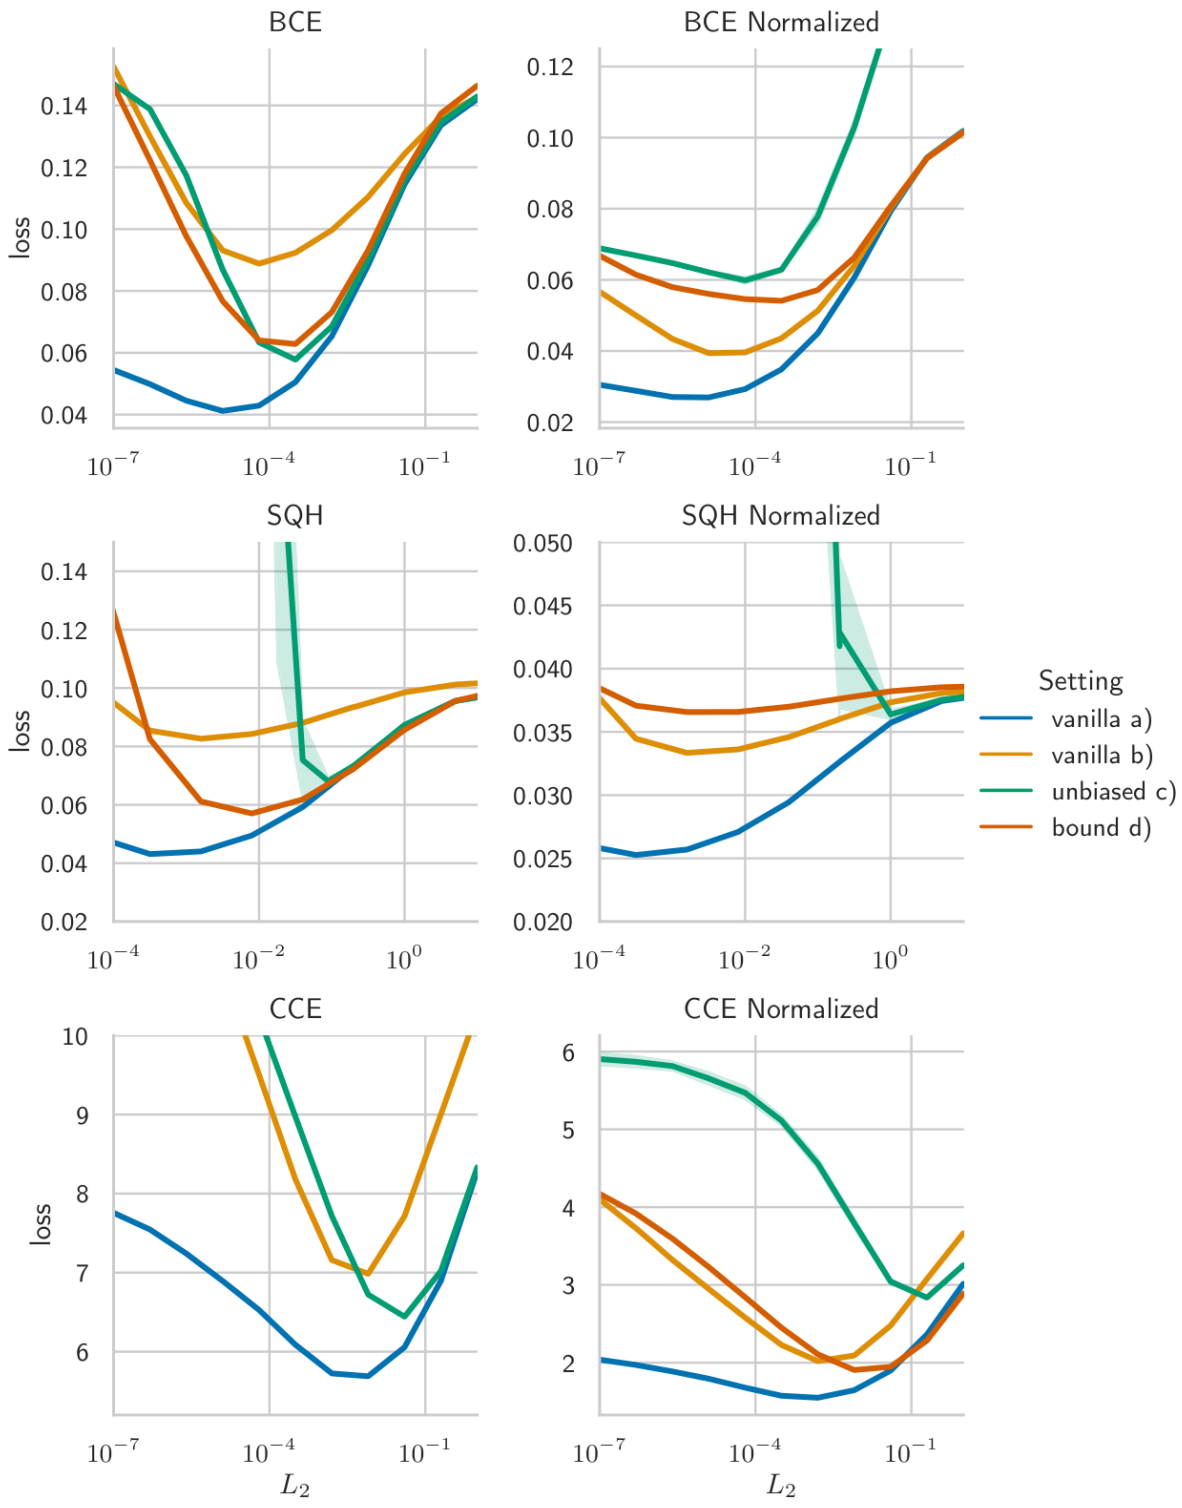


图 4。 比较不同损失函数与不同标签缺失处理方案的组合，在干净测试数据上评估。细节见正文。各行依次为 BCE（二元交叉熵）、SQH（平方铰链损失）、CCE（类别交叉熵）；右列 Normalized 为相应的归一化版本。图例的 a–d 配置与图 3 相同。纵轴 loss 为损失，横轴为 L_2 正则化强度。

第二行是基于平方铰链的损失，同样采用一对其余归约。它与 BCE 的主要区别在于，无偏情况下平方铰链更容易过拟合。对于 BCE，无偏版本与上界版本的结果大致相当；但这里上界损失要稳定得多。在归一化设定中，正则化强度尚大约为 10^{-1} 时，无偏损失就变得很大，而可分解版本约在 10^{-2} 时才出现这种情况。与 BCE 归一化情形一样，式（48）实际上不是上界，经验上也表现不佳。再次观察到普通损失优于无偏损失。

第三行是类别交叉熵，与前两行不同，它产生选取全部标签（PAL）归约。在非归一化情形，上界与无偏损失相同，且优于普通损失。归一化情形的无偏损失仍有上述问题，但上界（54）成功优于普通损失。

从偏差—方差权衡看，图中趋势明确：带噪数据训练的最优正则化强于干净数据训练；使用无偏损失或上界损失时，最优正则化也强于普通损失。

7.4 任务损失

即使干净数据上的训练过程是优化分解得到的可微损失，这也通常不是最终关注的量。我们真正想要的是最大化排名前列的精确率或召回率。

图 5 展示了 BCE 损失下 precision@k 随正则化强度的变化。P@k 指标与损失函数的行为有若干显著差异：弱正则化时，过拟合增强会使损失函数大幅恶化，但精确率指标的相应下降相对温和。对于损失函数，在强正则化时无偏估计优于上界，在弱正则化时则劣于上界；但这里的情况相反。

图 6 给出最优正则化参数下精确率与召回率的完整结果。这里的“最优”指在带噪验证数据上使损失函数的无偏估计最小的值，它可能与某个特定 P@k 或 R@k 指标的最优值略有不同。同一组数据及对应损失值、最优正则化参数汇总于表 3。

比较可分解与归一化设定可见，在 OvA 配置和无偏 PAL 配置中，归一化损失产生的波动（以标准差衡量）更大；唯一例外是 BCE 损失在带噪数据上的普通训练（b）。这一现象对全部六个任务损失都成立。注意，这不能由无偏估计量的方差解释，因为此处的数值是直接在具有干净真值的测试数据上计算的。

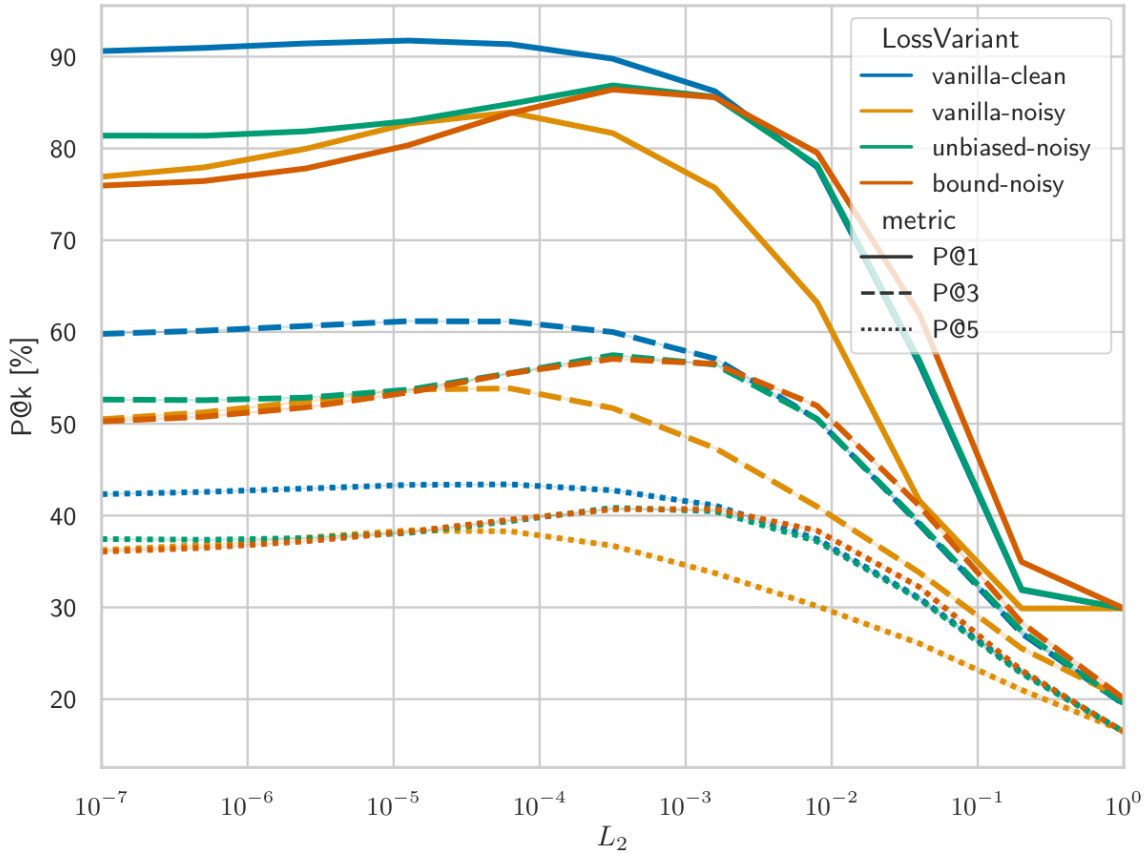


图 5。 使用二元交叉熵（归一化归约）训练时，不同损失版本的 precision@k。LossVariant 表示损失版本：vanilla-clean 为干净数据上的普通损失，vanilla-noisy 为带噪数据上的普通损失，unbiased-noisy 为带噪数据上的无偏损失，bound-noisy 为带噪数据上的上界损失；metric 为指标。纵轴为精确率百分比，横轴为 L_2 正则化强度。

图中还显示，对于固定损失函数，a–d 四种配置在六个指标上的排序大体稳定，但改变损失函数后排序会变化。对于 OvA-BCE，无偏损失 c 与上界损失 d 几乎相同；对于 OvA-SQH，无偏损失差得多，且波动大得多，这与图 4 的观察一致。对于 PAL-CCE，这两种配置相同。

在归一化情形中，OvA-N 归约对于 BCE 与 SQH 基本产生相同排序：普通损失 b 优于应用式（54）的 d，而 d 又优于无偏损失 c。例外是 BCE 的召回率指标，无偏损失似乎更好。〔式号按原文保留。〕

对于 PAL-N 归约，上界 d 的任务损失确实优于普通损失 b，但与其他归一化配置一样，无偏损失 c 更差。

最后，我们希望知道归一化版本在什么情况下优于可分解版本。Menon et al. (2019) 证明，在渐近情形，归一化归约对召回率一致，其他归约则对精确率一致。

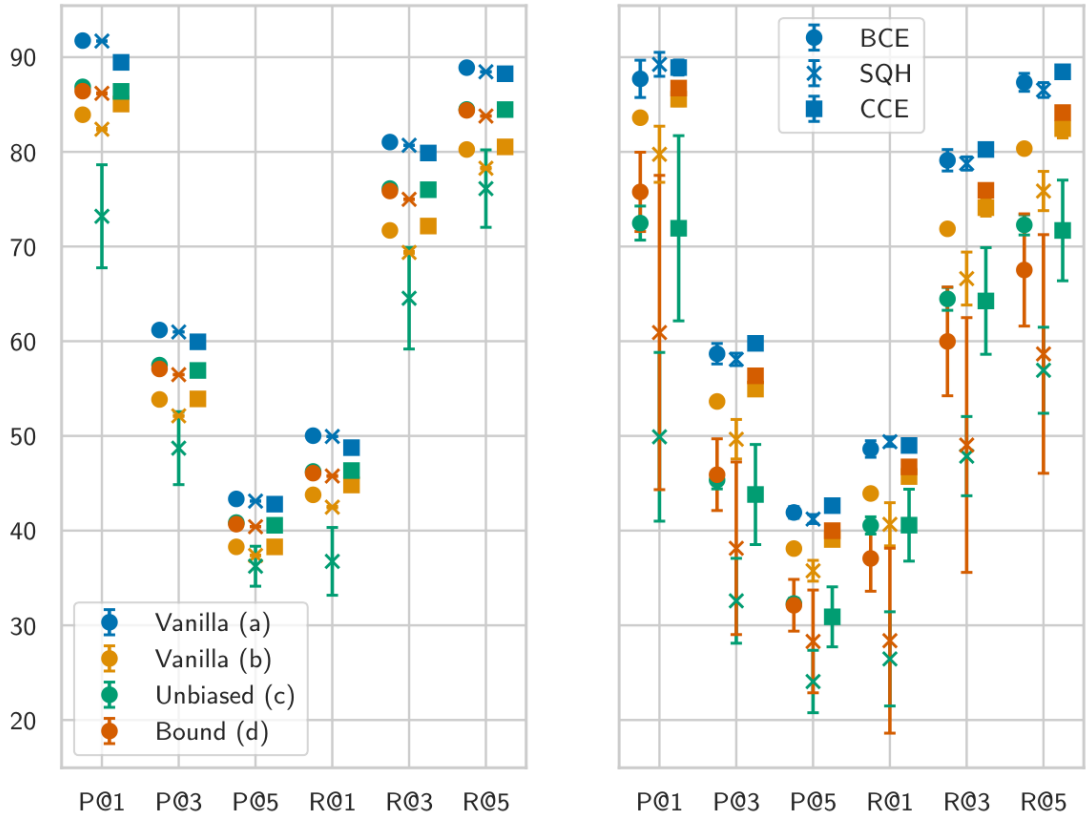


图 6。 对于可分解训练损失（左）和归一化训练损失（右），在使损失最小的最优正则化强度下的精确率与召回率。这些数值在干净测试集上计算；误差区间为 5 次运行所得标准差。Vanilla a/b 为普通损失配置 a/b，Unbiased c 为无偏配置 c，Bound d 为上界配置 d；BCE、SQH、CCE 分别为二元交叉熵、平方铰链损失、类别交叉熵。

然而，如上所见，尽管数据集中的训练实例很多，过拟合仍是主要问题。因此，如果某种对召回率一致的方法的泛化差距显著较小，它也完全可能在精确率上取得更好的结果。

由表 3 可见，对 BCE 损失，归一化归约通常使精确率和召回率都变差；明显例外是在带噪数据上使用普通损失，此时召回率略有提高。不过，在可分解归约中使用无偏损失或上界损失，总体性能仍更好。对于平方铰链（SQH）损失，归一化归约在所有版本、所有指标上都更差。

表 3。 在修改后的 AmazonCat-13K 数据上，使用不同损失函数的普通（Vanilla）、无偏（Unbiased）和上界（Upper-Bounded）版本得到的训练结果。BCE 表示二元交叉熵、SQH 表示平方铰链损失，二者对应 OvA 分解；CCE 表示 softmax 类别交叉熵，对应 PAL 分解。带 a* 标记的配置表示干净数据上的参考运行〔表内实际以 V-...* 标示〕。

Setting	Precision			Recall			Loss	Reg.
	P@1	P@3	P@5	R@1	R@3	R@5		
B-BCE	86.4	57.1	40.7	46.1	75.9	84.4	$6.3 \cdot 10^{-2}$	$3.16 \cdot 10^{-4}$
B-NBCE	75.8	45.9	32.1	37.1	60.0	67.5	$5.6 \cdot 10^{-2}$	$3.4 \cdot 10^{-4}$
U-BCE	86.9	57.5	40.9	46.2	76.1	84.5	$5.8 \cdot 10^{-2}$	$3.16 \cdot 10^{-4}$
U-NBCE	72.5	45.3	32.3	40.5	64.5	72.3	$6.2 \cdot 10^{-2}$	$3.41 \cdot 10^{-5}$
V-BCE*	91.7	61.2	43.3	50.0	81.0	88.9	$4.1 \cdot 10^{-2}$	$1.26 \cdot 10^{-5}$
V-NBCE*	87.7	58.7	41.9	48.6	79.1	87.3	$2.8 \cdot 10^{-2}$	$4.73 \cdot 10^{-6}$
V-BCE	83.9	53.9	38.3	43.8	71.7	80.2	$8.9 \cdot 10^{-2}$	$6.31 \cdot 10^{-5}$
V-NBCE	83.6	53.6	38.1	43.9	71.9	80.3	$3.9 \cdot 10^{-2}$	$2.1 \cdot 10^{-5}$
B-CCE	86.4	56.9	40.6	46.3	76.0	84.5	6.4	$3.98 \cdot 10^{-2}$
B-NCCE	86.7	56.3	40.0	46.7	75.9	84.1	1.9	$2.39 \cdot 10^{-2}$
U-CCE	86.4	56.9	40.6	46.3	76.0	84.5	6.4	$3.98 \cdot 10^{-2}$
U-NCCE	71.9	43.8	30.9	40.6	64.3	71.7	3.3	0.13
V-CCE*	89.4	59.9	42.8	48.8	79.9	88.2	5.7	$7.94 \cdot 10^{-3}$
V-NCCE*	88.9	59.8	42.6	49.0	80.2	88.5	1.6	$4.43 \cdot 10^{-4}$
V-CCE	85.0	53.9	38.3	44.8	72.2	80.5	7	$7.94 \cdot 10^{-3}$
V-NCCE	85.6	54.9	39.1	45.7	74.1	82.5	2.1	$2.06 \cdot 10^{-3}$
B-SQH	86.2	56.5	40.4	45.8	75.0	83.8	$5.7 \cdot 10^{-2}$	$7.94 \cdot 10^{-3}$
B-NSQH	60.9	38.1	28.3	28.4	49.0	58.7	$3.8 \cdot 10^{-2}$	0.21
U-SQH	73.2	48.7	36.2	36.8	64.5	76.1	$1.7 \cdot 10^{-1}$	0.1
U-NSQH	49.9	32.6	24.1	26.5	47.9	56.9	$1.9 \cdot 10^{-1}$	0.43
V-SQH*	91.7	61.0	43.1	49.9	80.7	88.5	$4.3 \cdot 10^{-2}$	$3.16 \cdot 10^{-4}$
V-NSQH*	89.2	58.1	41.2	49.4	78.8	86.5	$2.6 \cdot 10^{-2}$	$7.44 \cdot 10^{-4}$
V-SQH	82.4	52.1	37.4	42.5	69.4	78.3	$8.3 \cdot 10^{-2}$	$1.58 \cdot 10^{-3}$
V-NSQH	79.7	49.7	35.8	40.7	66.6	75.9	$3.4 \cdot 10^{-2}$	$1.07 \cdot 10^{-2}$

表头 Setting 为配置，Precision 为精确率，Recall 为召回率，Loss 为损失，Reg. 为正则化强度。配置前缀 B、U、V 分别表示上界、无偏、普通版本，N 表示归一化。

对于可分解 CCE 归约，上界等于无偏损失。与之相比，归一化归约的上界在 P@1 和 R@1 上更好，其他指标更差。无偏的归一化归约在所有指标上都差得多。对于普通损失，结果符合 Menon et al. (2019) 的预期：归一化版本召回率更好。有趣的是，在带噪数据上使用时，它的精确率也更好。

8 相关工作

带噪标签的无偏估计。 缺失标签学习是类别条件噪声学习的一种特殊情形。二元标签下损失函数的无偏估计见 Natarajan et al. (2017)。注意，其中的泛化界（引理 8）遗漏了适配后损失函数最大范数 $\| \widetilde{f} \|_\infty$ 这一因子，参见定理 6。

Van Rooyen and Williamson (2017) 给出了更一般的方法。在其记号中，f 是函数，$\mathbb{P}$ 是干净数据上的概率分布，经可逆算子 T 转换为受污染概率分布。令 R 为 T 的逆，R^* 为其伴随，则有：

$$\langle \mathbb{P}, f \rangle = \langle \mathsf{R} \circ \mathsf{T}(\mathbb{P}), f \rangle = \langle \mathsf{T}(\mathbb{P}), \mathsf{R}^*(f) \rangle. \tag{56}$$

这个等式构成其“定理 5（污染校正损失）”的基础，该定理指出，污染校正函数 l_{R} 为：

$$l_{\mathrm{R}}(\cdot, a) = \mathsf{R}^*(l(\cdot, a)) \; \forall a \in \mathcal{A}, \tag{57}$$

其中 $\mathcal{A}$ 是损失函数所评估的可能动作集合。对于具有 n 种可能取值的有限标签空间，算子 R^* 可用 $n \times n$ 矩阵表示。

对于多标签分类这一特例，定理 12 表明：一般情况下计算式（57）需要考虑标签向量的 2^l 种取值，但实际上只需考虑观测标签的子集，因此只要求值 $2^{\|y\|_0}$ 次。

鲁棒损失函数。 比选择能够补偿标签噪声的损失更鲁棒的策略，是采用本身就容忍噪声的学习算法。优点是不必估计噪声率，也就不会因模型设定错误而引入额外误差。对噪声率小于 50% 的对称标签噪声，Ghosh et al. (2015) 证明：若某种方法最小化的损失满足对称条件 $f(0, \cdot) + f(1, \cdot) = c$（$c$ 为常数），则它容忍噪声。Menon et al. (2015) 表明，某些性能目标（如平衡误差和 AUC）甚至在更一般的相互污染分布设定下也具有噪声鲁棒性。

数据重新校准。 数据重新校准方法尝试从训练数据中识别哪些样本受到污染（Han et al., 2018；Zheng et al., 2020；Jiang et al., 2018）。协同教学（co-teaching；Han et al., 2018）维持两个相互作用的网络：对每个小批量，各网络选择损失值较小的一部分样本，并假定低损失意味着这些是干净实例。随后，仅用选中样本训练另一个网络，以更新其权重。已有观察指出，深度神经网络先拟合干净数据，随着训练推进才开始过拟合噪声（Arpit et al., 2017）；因此该方法随时间减少从每个小批量中选择的样本比例。

Zheng et al. (2020) 在非常靠近决策边界的实例所占概率质量较低时，为此类方法提供了一些理论依据。对转移概率与特征无关的标签噪声，只要预测真实类别条件概率 $\eta(X) = \mathbb{P}\{Y = 1 \mid X\}$ 的模型足够准确，就能识别错误标注样本。

据此，他们提出似然比检验，判断是否应翻转训练数据中的标签。尽管方法有理论基础，实际运行仍需要经验调整，例如增加回溯损失项来稳定训练。

后处理。 也可先在带噪数据上直接训练评分器，再选择适当阈值，构造适应给定标签缺失率的分类器。对于为各数据点预测类别概率的朴素评分器，校正阈值见 Menon et al. (2015)。类似地，概率标签树的推断过程也可调整为考虑倾向概率模型（Wydmuch et al., 2021）。

其他方法尝试专门为标签缺失设计新损失，例如基于 group-lasso 的表述（Bucak et al., 2011）。

正例—未标记学习。 标签缺失学习与从正例及未标记（PU）数据学习密切相关。后者有两种解释：截尾（censoring）设定，与标签缺失学习完全相同；病例—对照（case-control）设定，正例独立于未标记数据抽取（Elkan and Noto, 2008）。后一设定中，训练集与测试集真实标签的边缘分布可能不

同。此时需要知道（或估计）类别先验 π，而非噪声率，再按 Du Plessis et al. (2015) 确定校正损失。新损失可能不保留非负性和凸性，这些困难与我们的设定相同（Kiryo et al., 2017；Chou et al., 2020）。

半监督学习。 半监督学习给出一种略有不同的缺失标签设定。这里每个样本只知道某个已知标签子集的取值，即标签可取三种值：1 为正，-1 为负，0 为未知。如果损失可按标签分解，Yu et al. (2014) 采用的一种策略是，仅对标签已知的贡献求和，也就是用掩码排除未知标签。

9 总结与讨论

我们表明，若标签独立缺失，使用掩码变量建模标签缺失学习问题，可方便地推导二分类与多标签设定下的无偏估计量。这些无偏估计量是唯一的，但可能具有不希望出现的性质：即使原始损失函数凸且有下界，估计仍可能非凸且无界。即便在不要求这些性质的纯评估情形，倾向概率下降时方差增大也构成重大问题，甚至使无偏估计无法使用。

为缓解这些问题，我们建议使用凸上界。二分类情形的一般解为式（46）。多标签设定中，我们考虑了由 Menon et al. (2019) 的多标签归约产生的四种重要情形。其中，选取全部标签归约尤其有利，因为它直接产生凸函数。对于其归一化形式，也仍可构造凸上界。未经归一化的一对其余情形可以应用二分类凸上界，但归一化后的上界仍是开放问题。表 4 给出这些归约的概览。

表 4。 多标签损失归约概览。

Reduction	Base	Consistency	Convexity
One-vs-All	Binary	Precision	Upper-Bound
OvA-Norm	Binary	Recall	?
Pick-all-Labels	Multiclass	Precision	Yes
PaL-Norm	Multiclass	Recall	Upper-Bound

表头依次为归约、基础任务、一致性目标、凸性。One-vs-All：二分类、精确率、可构造上界；OvA-Norm：二分类、召回率、未知；Pick-all-Labels：多分类、精确率、是；PaL-Norm：多分类、召回率、可构造上界。

这些结果提示，在渐近情形下，PAL 归约优于 OvA 归约。不过实践中的情况没有这么明确。实验中，未经归一化的 OvA 在召回率上取得最佳结果，尽管该损失实际上不对召回率一致。从结果中能够给出的最明确建议是：若要使用归一化归约，优先选择 PaL-Norm 而非 OvA-Norm，因为目前还没有后者的凸代理。

理论结果（定理 6）及实验均表明，标签缺失会使偏差—方差权衡发生移动。只要数据存在标签缺失，无论训练采用普通损失、无偏损失还是凸上界损失，都需要更强的正则化。进一步考察过拟合后发现，泛化误差可分成两部分：带噪有限数据与干净有限数据上的经验误差之差，以及干净经验误差与真实风险之差。对特定噪声模式的过拟合显著超过对有限样本的过拟合。这与 Arpit et al. (2017) 的观察相符：典型正则化器会防止深度网络记忆带噪样本，但不会阻碍从干净实例中学习模式。

由于唯一性结果，使用无偏估计时无法避免上述问题。这提示未来应研究能够调节偏差—方差权衡的损失函数。损失具有轻微偏差通常并无大碍，尤其考虑到本文假定已知的倾向概率在实践中实际上也只是估计值；于是本文推导的无偏估计也会因设定错误而带有轻微偏差。

致谢

感谢 Krzysztof Dembczynski、Marek Wydmuch、Mohammadreza Qaraei 和 Thomas Staudt 对本文早期草稿的讨论与反馈。

参考文献

以下完整保留作者、刊会名称、卷期、页码、日期、出版者、标识符与链接；论文及图书题名译为中文。

Rahul Agrawal, Archit Gupta, Yashoteja Prabhu, and Manik Varma. 百万标签下的多标签学习：为网页推荐广告商竞价短语。载 Proceedings of the 22nd International Conference on World Wide Web, WWW '13，第 13–24 页，New York, NY, USA，2013。Association for Computing Machinery. ISBN 9781450320351. doi: 10.1145/2488388.2488391. URL：https://doi.org/10.1145/2488388.2488391。

Devansh Arpit, Stanisław Jastrzębski, Nicolas Ballas, David Krueger, Emmanuel Bengio, Maxinder S. Kanwal, Tegan Maharaj, Asja Fischer, Aaron Courville, Yoshua Bengio, and Simon Lacoste-Julien. 深入考察深度网络中的记忆现象。载 Doina Precup and Yee Whye Teh 编，Proceedings of the 34th International Conference on Machine Learning，Proceedings of Machine Learning Research 第 70 卷，第 233–242 页。PMLR，2017 年 8 月 6–11 日。

Rohit Babbar and Bernhard Schölkopf. DiSMEC：用于极端多标签分类的分布式稀疏机器。载 WSDM，第 721–729 页，2017。

Rohit Babbar and Bernhard Schölkopf. 数据稀缺性、鲁棒性与极端多标签分类。Machine Learning, 108(8):1329–1351，2019 年 9 月。ISSN 1573-0565. doi: 10.1007/s10994-019-05791-5. URL：https://doi.org/10.1007/s10994-019-05791-5。

Kush Bhatia, Kunal Dahiya, Himanshu Jain, Yashoteja Prabhu, and Manik Varma. 极端分类资源库：多标签数据集与代码。http://manikvarma.org/downloads/XC/XMLRepository.html，2016。

Serhat S Bucak, Pavan Kumar Mallapragada, Rong Jin, and Anil K Jain. 面向多分类学习的高效多标签排序：在目标识别中的应用。载 2009 IEEE 12th International Conference on Computer Vision，第 2098–2105 页。IEEE，2009。

Serhat Selcuk Bucak, Rong Jin, and Anil K Jain. 类别分配不完整情况下的多标签学习。载 CVPR 2011，第 2801–2808 页。IEEE，2011。

Yu-Ting Chou, Gang Niu, Hsuan-Tien Lin, and Masashi Sugiyama. 无偏风险估计量可能产生误导：互补标签学习的案例研究。载 International Conference on Machine Learning，第 1929–1938 页。PMLR，2020 年 11 月。URL：https://proceedings.mlr.press/v119/chou20a.html。ISSN: 2640-3498.

K. Dahiya, A. Agarwal, D. Saini, K. Gururaj, J. Jiao, A. Singh, S. Agarwal, P. Kar, and M Varma. SiameseXML：孪生网络遇上具有一亿标签的极端分类器。载 Proceedings of the International Conference on Machine Learning，2021 年 7 月。

Ofer Dekel and Ohad Shamir. 类别数多于样本数时的多类多标签分类。载 Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics，第 137–144 页，2010。

Jia Deng, Alexander C Berg, Kai Li, and Li Fei-Fei. 对一万多个图像类别进行分类告诉了我们什么？载 ECCV，2010。

Marthinus Du Plessis, Gang Niu, and Masashi Sugiyama. 从正例及未标记数据学习的凸表述。载 International conference on machine learning，第 1386–1394 页，2015。

Charles Elkan and Keith Noto. 仅从正例及未标记数据学习分类器。载 Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining, KDD '08，第 213–220 页，New York, NY, USA，2008 年 8 月。Association for Computing Machinery. ISBN 978-1-60558-193-4. doi: 10.1145/1401890.1401920. URL：https://doi.org/10.1145/1401890.1401920。

Aritra Ghosh, Naresh Manwani, and P. S. Sastry. 使风险最小化容忍标签噪声。Neurocomputing, 160:93–107，2015。出版者：Elsevier。

Chuan Guo, Ali Mousavi, Xiang Wu, Daniel N. Holtmann-Rice, Satyen Kale, Sashank Reddi, and Sanjiv Kumar. 打破大输出空间中基于嵌入的分类器的性能上限。Advances in Neural Information Processing Systems, 32，2019。URL：https://proceedings.neurips.cc/paper/2019/hash/78f7d96ea21ccae89a7b581295f34135-Abstract.html。

Bo Han, Quanming Yao, Xingrui Yu, Gang Niu, Miao Xu, Weihua Hu, Ivor Tsang, and Masashi Sugiyama. Co-teaching：在极强标签噪声下鲁棒地训练深度神经网络。载 S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett 编，Advances in Neural Information Processing Systems 第 31 卷。Curran Associates, Inc.，2018。URL：https://proceedings.neurips.cc/paper/2018/file/a19744e268754fb0148b017647355b7b-Paper.pdf。

Himanshu Jain, Yashoteja Prabhu, and Manik Varma. 用于推荐、标签标注、排序及其他标签缺失应用的极端多标签损失函数。载 KDD，2016 年 8 月。

Himanshu Jain, Venkatesh Balasubramanian, Bhanu Chunduri, and Manik Varma. Slice：在一亿标签上训练、用于相关搜索的可扩展线性极端分类器。载 WSDM，第 528–536 页，2019。

Lu Jiang, Zhengyuan Zhou, Thomas Leung, Li-Jia Li, and Li Fei-Fei. MentorNet：在受污染标签上为极深神经网络学习数据驱动的课程。载 Jennifer Dy and Andreas Krause 编，Proceedings of the 35th International Conference on Machine Learning，Proceedings of Machine Learning Research 第 80 卷，第 2304–2313 页。PMLR，2018 年 7 月 10–15 日。URL：https://proceedings.mlr.press/v80/jiang18c.html。

Diederik P. Kingma and Jimmy Ba. Adam：一种随机优化方法。2017。

Ryuichi Kiryo, Gang Niu, Marthinus C du Plessis, and Masashi Sugiyama. 使用非负风险估计量的正例—未标记学习。载 I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett 编，Advances in Neural Information Processing Systems 30，第 1675–1685 页。Curran Associates, Inc.，2017。URL：http://papers.nips.cc/paper/6765-positive-unlabeled-learning-with-non-negative-risk-estimator.pdf。

M. Lapin, M. Hein, and B. Schiele. 多分类、top-k 分类与多标签分类的损失函数分析与优化。IEEE Transactions on Pattern Analysis and Machine Intelligence, 40(7):1533–1554，2018。doi: 10.1109/TPAMI.2017.2751607.

Aditya Menon, Brendan Van Rooyen, Cheng Soon Ong, and Bob Williamson. 通过类别概率估计从受污染的二元标签学习。载 International Conference on Machine Learning，第 125–134 页，2015。

Aditya K. Menon, Ankit Singh Rawat, Sashank Reddi, and Sanjiv Kumar. 多标签归约：我的损失在优化什么？Advances in Neural Information Processing Systems, 32，2019。URL：https://papers.nips.cc/paper/2019/hash/da647c549dde572c2c5edc4f5bef039c-Abstract.html。

Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 向量空间中词表示的高效估计。arXiv preprint arXiv:1301.3781，2013。

Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar.《机器学习基础》。MIT press，2018。

Nagarajan Natarajan, Inderjit S. Dhillon, Pradeep Ravikumar, and Ambuj Tewari. 带噪标签下的代价敏感学习。The Journal of Machine Learning Research, 18(1):5666–5698，2017。出版者：JMLR. org.

Ioannis Partalas, Aris Kosmopoulos, Nicolas Baskiotis, Thierry Artieres, George Paliouras, Eric Gaussier, Ion Androutsopoulos, Massih-Reza Amini, and Patrick Galinari. LSHTC：大规模文本分类基准。arXiv preprint arXiv:1503.08581，2015。

Yashoteja Prabhu and Manik Varma. FastXML：用于极端多标签学习的快速、准确、稳定的树分类器。载 KDD，第 263–272 页。ACM，2014。

Mohammadreza Qaraei, Erik Schultheis, Priyanshu Gupta, and Rohit Babbar. 缺失标签下极端分类中无偏损失函数的凸代理。载 Proceedings of the Web Conference 2021，第 3711–3720 页，Ljubljana Slovenia，2021 年 4 月。ACM. ISBN 978-1-4503-8312-7. doi: 10.1145/3442381.3450139. URL：https://dl.acm.org/doi/10.1145/3442381.3450139。

Shai Shalev-Shwartz and Shai Ben-David. 《理解机器学习：从理论到算法》。Cambridge university press，2014。

Brendan Van Rooyen and Robert C. Williamson. 受污染标签下的学习理论。18(1):8501–8550, 2017。ISSN 1532-4435.〔原文未列刊名。〕

Marek Wydmuch, Kalina Jasinska-Kobus, Rohit Babbar, and Krzysztof Dembczynski. 倾向评分概率标签树，第 2252–2256 页。Association for Computing Machinery, New York, NY, USA，2021。ISBN 9781450380379. URL：https://doi.org/10.1145/3404835.3463084。

Ronghui You, Zihan Zhang, Ziye Wang, Suyang Dai, Hiroshi Mamitsuka, and Shanfeng Zhu. AttentionXML：用于高性能极端多标签文本分类的、基于标签树的注意力感知深度模型。

载 H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett 编，Advances in Neural Information Processing Systems 第 32 卷。Curran Associates, Inc.，2019。URL：https://proceedings.neurips.cc/paper/2019/file/9e6a921fbc428b5638b3986e365d4f21-Paper.pdf。

Hsiang-Fu Yu, Prateek Jain, Purushottam Kar, and Inderjit Dhillon. 缺失标签下的大规模多标签学习。载 International conference on machine learning，第 593–601 页，2014。

Songzhu Zheng, Pengxiang Wu, Aman Goswami, Mayank Goswami, Dimitris Metaxas, and Chao Chen. 具有误差界的噪声标签校正。载 International Conference on Machine Learning，第 11447–11457 页。PMLR，2020。

附录 A 损失函数示例

A.1 多标签损失

注 16（计算复杂度）。 按定理 12 计算一般多标签损失的无偏估计，计算量随观测标签数指数增长。对大标签空间而言，观测标签数通常远小于真实标签数（Jain et al., 2016）。若假定它为 $O(\log l)$，且 f^* 可在 $O\left(l^k\right)$ 时间内计算，则所需计算量为：

$$2^{O(\log(l))} \cdot \left(O(\log(l)) + O(l^k)\right) = O\left(l^{1+k}\right). \tag{58}$$

逐样本召回率。 将定理 12 的一般解用于式（40）给出的逐样本召回率定义，得到：

$$\text{Recall}(\mathbf{y}, \hat{\mathbf{y}}) = \left(\prod_{i \in \mathcal{I}(\mathbf{y})} \frac{p_i - 1}{p_i}\right) \cdot \sum_{\mathcal{J} \subset \mathcal{I}(\mathbf{y})} |\mathcal{J}|^{-1} \left(\sum_{k \in \mathcal{J}} \hat{y}_k\right) \prod_{j \in \mathcal{J}} (p_j - 1)^{-1}. \tag{59}$$

注意，预测 $\widehat{\mathbf{y}}$ 通常是稀疏向量，例如计算 recall@k 时，恰有 k 个非零分量。这可能使计算略为高效。记正确预测的集合为 $\mathcal{S}:=\mathcal{I}(\mathbf{y})\cap\mathcal{I}(\widehat{\mathbf{y}})$，漏掉的标签为 $\mathcal{T}=\mathcal{I}(\mathbf{y})\backslash\mathcal{S}$，从而 $\mathcal{I}(\mathbf{y})=\mathcal{S}\cup\mathcal{T}$，对 $\mathcal{I}(\mathbf{y})$ 的子集求和可写为对 $\mathcal{S}$ 与 $\mathcal{T}$ 的嵌套求和。为方便起见，公共因子简记为 $c(\mathbf{y}):=\prod_{i\in\mathcal{I}(\mathbf{y})}(p_i-1)/p_i$，并令 $d(\mathcal{U}):=\prod_{j\in\mathcal{U}}(p_j-1)$。得到：

$$\mathrm{Recall}(\mathbf{y},\hat{\mathbf{y}})=c(\mathbf{y})\sum_{\substack{\mathcal{U}\subset\mathcal{T}\\ \mathcal{V}\subset\mathcal{S}}}\frac{|\mathcal{V}|}{|\mathcal{U}|+|\mathcal{V}|}\left(\prod_{j\in\mathcal{U}}\frac{1}{p_j-1}\right)\left(\prod_{k\in\mathcal{V}}\frac{1}{p_k-1}\right)=c(\mathbf{y})\sum_{\mathcal{V}\subset\mathcal{S}}\frac{|\mathcal{V}|}{d(\mathcal{V})}\sum_{\mathcal{U}\subset\mathcal{T}}\frac{d(\mathcal{U})^{-1}}{|\mathcal{U}|+|\mathcal{V}|}. \tag{60}$$

第二个求和几乎与第一个独立：如果 $\mathcal{V}$ 中元素个数固定，就可以将嵌套求和改写为两个独立求和的乘积。因此，按 $\mathcal{V}$ 的元素数汇集各项并重新整理，即可恢复正文中的结果：

$$\mathrm{Recall}(\mathbf{y},\hat{\mathbf{y}})=c(\mathbf{y})\sum_{s=1}^{|\mathcal{S}|}\sum_{\substack{\mathcal{V}\subset\mathcal{S}\\ |\mathcal{V}|=s}}\frac{s}{d(\mathcal{V})}\cdot\sum_{\mathcal{U}\subset\mathcal{T}}\frac{d(\mathcal{U})^{-1}}{|\mathcal{U}|+s}=c(\mathbf{y})\sum_{s=1}^{|\mathcal{S}|}\left(\sum_{\mathcal{U}\subset\mathcal{T}}\frac{d(\mathcal{U})^{-1}}{|\mathcal{U}|+s}\right)\sum_{\substack{\mathcal{V}\subset\mathcal{S}\\ |\mathcal{V}|=s}}\frac{s}{d(\mathcal{V})}. \tag{61}$$

成对损失函数。还可考虑如下形式的损失：

$$f^*(\mathbf{y},\hat{\mathbf{y}})=\sum_{i=1}^{l}\sum_{j=i+1}^{l}g_{y_i,y_j}(\hat{y}_i,\hat{y}_j)=\sum_{a,b=0}^{1}\sum_{i=1}^{l}\sum_{j=i+1}^{l}\mathbb{1}\{y_i=a\}\,\mathbb{1}\{y_j=b\}\,g_{a,b}(\hat{y}_i,\hat{y}_j) \tag{62}$$

其中给定四个函数 $g_{ab}:\widehat{\mathcal{Y}}\times\widehat{\mathcal{Y}}\to\mathbb{R}$。与之前一样，由于标签向量 $\mathbf{y}$ 的分量只能为 0 或 1，可将指示函数重写为线性函数 $\mathbb{1}y=a=ya+(1-y)(1-a)$。

由此得到：

$$\begin{aligned}f^*(\mathbf{y},\hat{\mathbf{y}})&=\sum_{a,b=0}^{1}\sum_{i=1}^{l}\sum_{j=i+1}^{l}[y_ia+(1-y_i)(1-a)][y_jb+(1-y_j)(1-b)]g_{a,b}(\hat{y}_i,\hat{y}_j)\\&=\sum_{a,b=0}^{1}\sum_{i=1}^{l}\sum_{j=i+1}^{l}[y_i(2a-1)+1-a)][y_j(2b-1)+1-b]g_{a,b}(\hat{y}_i,\hat{y}_j).\end{aligned} \tag{63}$$

不必应用定理 12，因为上述等式分别对每个标签都是线性的（求和范围排除了 $i=j$）。利用掩码变量的独立性，可直接写出：

$$\begin{aligned}f(\mathbf{y},\hat{\mathbf{y}})&=\sum_{a,b=0}^{1}\sum_{i=1}^{l}\sum_{j=i+1}^{l}\left(\frac{y_i}{p_i}(2a-1)+1-a\right)\left(\frac{y_j}{p_j}(2b-1)+1-b\right)g_{a,b}(\hat{y}_i,\hat{y}_j)\\&=\sum_{i=1}^{l}\sum_{j=i+1}^{l}p_i^{-1}p_j^{-1}\sum_{a,b=0}^{1}\left((2a-1)y_i+p_i(1-a)\right)\left((2b-1)y_j+p_j(1-b)\right)g_{a,b}(\hat{y}_i,\hat{y}_j).\end{aligned} \tag{64}$$

一个例子是 Kendall–Tau 损失（Shalev-Shwartz and Ben-David, 2014，第 202 页），它用于排序任务，计算预测与真值中排序不一致的标签对数。多标签分类可解释为一种二部排序：若两个标签具有相同真值，无论它们的预测如何，都不产生损失（Bucak et al., 2009）。此时有：

$$g_{00}(p,q) = 0 \qquad g_{10}(p,q) = \mathbb{1}\{q > p\} \tag{65}$$
$$g_{01}(p,q) = \mathbb{1}\{p > q\} \qquad g_{11}(p,q) = 0. \tag{66}$$

利用真实排序相同时损失为零这一点，无偏估计可简化为：

$$\mathrm{KT}(\mathbf{y}, \hat{\mathbf{y}}) = \sum_{i=1}^{l} \sum_{j=i+1}^{l} p_i^{-1} p_j^{-1} \left(p_i - y_i\right) y_j g_{01}(\hat{y}_i, \hat{y}_j) + y_i \left(p_j - y_j\right) g_{10}(\hat{y}_i, \hat{y}_j), \tag{67}$$

在训练应用中，上述不连续的 g_{01}，g_{10} 将替换为凸上界。注意，与定理 12 的一般解不同，这一等式只含两个逆倾向概率的乘积。因此，预期其方差增幅小于召回率的情形，但大于二分类损失的情形。当然，由唯一性定理 13 可知，将成对损失的定义代入一般解后，应得到与此处相同的结果。我们没有采用这一路径，是因为化简对所有子集求和的结构，比从头推导更费事；不过二者依据相同的原则，即独立掩码，以及标签集合离散所允许的线性化。

附录 B 定理与证明

B.1 二分类情形的无偏估计

推论 5（二分类损失函数的梯度）。 设 $\varphi : \mathcal{X} \times \mathbb{R}^k \to \mathbb{R}$ 是具有 $k \in \mathbb{N}$ 个参数的二分类器，$\ell^* : \{0,\ 1\} \times \mathbb{R} \to \mathbb{R}$ 是损失函数，$\ell = \mathfrak{P}_p\left(\ell^*\right)$。假设掩码 M 与 $\left(X,\ Y^*,\ \mathbf{W}\right)$ 独立。那么：

$$\mathbb{E}[\ell^*(Y^*, \phi(X, \mathbf{W}))] = \mathbb{E}[\ell(Y, \phi(X, \mathbf{W}))]$$
$$\mathbb{E}[\nabla_{\mathbf{W}} \ell^*(Y^*, \phi(X, \mathbf{W}))] = \mathbb{E}[\nabla_{\mathbf{W}} \ell(Y, \phi(X, \mathbf{W}))]\,.$$

证明。 $X,\ \mathbf{W}$ 与 M 的独立性意味着 $\varphi(X;\ \mathbf{W})$ 与 M 独立，因此第一个等式直接由定理 4 得到。对于第二个等式，令 $\mathcal{X}' = \mathcal{X} \times \mathbb{R}^k$、$X' = (X,\ \mathbf{W})$，并定义：

$$g^* : \mathcal{Y} \times \mathcal{X}' \longrightarrow \mathbb{R}^k \tag{68}$$
$$(y, (x, \mathbf{w})) \mapsto \nabla_{\mathbf{w}} \ell^*(y, \phi(x, \mathbf{w})). \tag{69}$$

令 $g = \mathfrak{P}_p\left(g^*\right)$，即可将定理 4 应用于 X'。剩下只需证明 g 具有所要求的结构；利用求导的线性性可得：

$$g(1, x, \mathbf{w}) = p^{-1} \left(g^*(1, x, \mathbf{w}) + (p-1) g^*(0, x, \mathbf{w})\right) \tag{70}$$
$$= p^{-1} \left(\nabla_{\mathbf{w}} \ell^*(1, \phi(x, \mathbf{w})) + (p-1) \nabla_{\mathbf{w}} \ell^*(0, \phi(x, \mathbf{w}))\right) \tag{71}$$
$$= \nabla_{\mathbf{w}} \left(p^{-1} \left(\ell^*(1, \phi(x, \mathbf{w})) + (p-1) \ell^*(0, \phi(x, \mathbf{w}))\right)\right) \tag{72}$$
$$= \nabla_{\mathbf{w}} \ell(1, \phi(x, \mathbf{w})). \tag{73}$$

证毕。

定理 7（唯一性）。设 $|\mathcal{X}| \geq 2$、$p \in (0,\, 1]$、$q \in (0,\, p]$，且 $\mathcal{F} = \mathcal{M}\big(\{0,\, 1\}\times\mathcal{X},\, \mathbb{R}\big)$ 为一个函数集合。设 $\mathfrak{P} : \mathcal{F} \to \mathcal{F}$ 是一个将函数映射为缺失标签情形下无偏估计的算子，使得对于所有满足倾向概率为 p、边缘概率为 q 的掩码模型的 $X,\, Y,\, Y^*$，都有：

$$\forall f^* \in \mathcal{F} : \mathbb{E}[f^*(Y^*, X)] = \mathbb{E}[\mathfrak{P}(f^*)(Y, X)]\,. \tag{22}$$

那么，$\mathfrak{P}$ 与倾向评分算子 $\mathfrak{P}_p$ 具有如下关系：

$$\mathfrak{P}(f^*)(y, x) = \mathfrak{P}_p(f^*)(y, x) + (y - q)\gamma \tag{23}$$

其中 $\gamma \in \mathbb{R}$。由于该项不影响对 x 的依赖关系，从学习的角度而言，倾向评分算子 $\mathfrak{P}_p$ 本质上是唯一的。

证明。 $\mathfrak{P}_p$ 满足条件（22）这一事实由定理 4 得到。由于 $\mathbb{E}[Y] = q$，附加项的期望为零。

设 $\mathfrak{P}$ 是另一个满足该条件的算子，则式（22）尤其也对下列形式的分布成立：

$$X, Y^* \sim q^*\delta(x_1, 1) + (1 - q^*)\delta(x_2, 0), \tag{74}$$

其中 $\delta\big(x,\, y\big)$ 表示点 $\big(x,\, y\big)$ 处的 Dirac 测度，且 $q^*{:=}q/p$。这些分布是有效的，因为 $q \overset{!}{=} \mathbb{P}\{Y = 1\} = \mathbb{P}\{Y^* = 1,\, M = 1\} = p{\cdot}q^* = q$。

进一步记 $f = \mathfrak{P}\big(f^*\big)$、$f^*\big(y,\, x\big) = yg^*(x) + h^*(x)$，以及 $f\big(x,\, y\big) = yg(x) + h(x)$。由于 $y \in \{0,\, 1\}$，总能将函数分解为 g 与 h。

采用这一记法，可以显式计算期望：

$$\mathbb{E}[f^*(Y^*, X)] = \mathbb{E}[Y^*g^*(X) + h^*(X)] = q^*(g^*(x_1) + h^*(x_1)) + (1 - q^*)h^*(x_2) \tag{75}$$
$$\mathbb{E}[f(Y, X)] = \mathbb{E}[MY^*g(X) + h(X)] = q^*(pg(x_1) + h(x_1)) + (1 - q^*)h(x_2). \tag{76}$$

根据对 $\mathfrak{P}$ 的假设，二者相等：

$$q^*(g^*(x_1) + h^*(x_1)) + (1 - q^*)h^*(x_2) = q^*(pg(x_1) + h(x_1)) + (1 - q^*)h(x_2) \tag{77}$$
$$q^*(g^*(x_1) + h^*(x_1) - h(x_1)) + (1 - q^*)(h^*(x_2) - h(x_2)) = p\,q^*g(x_1). \tag{78}$$

令 $x_1 = x_2 = :x$，得到：

$$q^*(g^*(x) - pg(x)) = h(x) - h^*(x), \tag{79}$$

将其代回式（78），得到：

$$q^*(g^*(x_1) - q^*(g^*(x_1) - pg(x_1))) + (1 - q^*)(q^*(g^*(x_2) - pg(x_2))) = pq^*g(x_1) \tag{80}$$
$$(1 - q^*)g^*(x_1) + (q^* - 1)pg(x_1) + (1 - q^*)(g^*(x_2) - pg(x_2)) = 0 \tag{81}$$
$$g^*(x_1) - pg(x_1) + g^*(x_2) - pg(x_2) = 0. \tag{82}$$

由于此等式对所有 $x_1, x_2 \in \mathcal{X}$ 都成立，它将 g 确定到一个常数平移。固定 $x_0 \in \mathcal{X}$，记 $c = g^*(x_0)/p - g(x_0)$，则对任意 $x \in \mathcal{X}$，有：

$$g(x) = g^*(x)/p + c. \tag{83}$$

将其代回式（79），得到：

$$h(x) = h^*(x) - pcq^* = h^*(x) - qc. \tag{84}$$

结合这两个表达式，即得所要证明的结论：

$$\mathfrak{P}(f^*)(y, x) = yg(x) + h(x) = \frac{yg^*(x)}{p} + yc + h^*(x) - qc = \frac{y}{p}g^*(x) + h^*(x) + (y - q)c. \tag{85}$$

证毕。

译注（原文记号保留）。上文分解式中的 $f(x, y)$ 与随后采用的 $f(y, x)$ 参数顺序不同；式（80）至（83）的符号、常数 c 的定义，以及原文未单独讨论 $q^* = 1$ 边界的处理，均按原文保留，不作静默修正。

B.2 泛化界

本节给出定理 6 的证明。为此，我们先证明以下辅助结果。

定理 17。设 $\mathcal{H} \subset \mathcal{M}(\mathcal{X}, \widehat{\mathcal{Y}})$ 是函数类，$f : \mathcal{Y} \times \widehat{\mathcal{Y}} \to [a, b]$ 是有界且关于第二个自变量 ρ-Lipschitz 连续的函数。记 $\widetilde{f} := \mathfrak{P}_p f$。给定包含 n 个带噪训练点的样本，下列不等式以至少 $1 - \delta$ 的概率成立：

$$\sup_{h \in \mathcal{H}} \left(\hat{\mathrm{R}}_{\tilde{f}}[h] - \mathrm{R}_{\tilde{f}}[h] \right) \leq \frac{4 - 2p}{p} \rho \, \mathfrak{R}_n(\mathcal{H}) + \frac{(2 - p)(b - a)}{p} \sqrt{\frac{\log(1/\delta)}{2n}} \tag{86}$$

$$\sup_{h \in \mathcal{H}} \left(\mathrm{R}_{\tilde{f}}[h] - \hat{\mathrm{R}}_{\tilde{f}}[h] \right) \leq \frac{4 - 2p}{p} \rho \, \mathfrak{R}_n(\mathcal{H}) + \frac{(2 - p)(b - a)}{p} \sqrt{\frac{\log(1/\delta)}{2n}}. \tag{87}$$

证明。首先确定 $\widetilde{f}$ 的 Lipschitz 常数。当 $y = 0$ 时，它与 f 的 Lipschitz 常数相同，因此只需考虑 $y = 1$ 的情形。

$$\left| \tilde{f}(1, x_1) - \tilde{f}(1, x_2) \right| = \frac{f(1, x_1) + (p - 1) f(0, x_1) - f(1, x_2) - (p - 1) f(0, x_2)}{p} \tag{88}$$

$$\leq \frac{1}{p} \left| f(1, x_1) - f(1, x_2) \right| + \frac{1 - p}{p} \left| f(0, x_1) - f(0, x_2) \right| \tag{89}$$

$$\leq \left(\frac{1}{p} + \frac{1 - p}{p} \right) \rho \| x_1 - x_2 \|. \tag{90}$$

在式（89）中，我们利用了 $0 < p \leq 1$。这也意味着 $(2 - p)/p \geq 1$，因此 $\widetilde{f}$ 的 Lipschitz 常数为 $\frac{2 - p}{p} \rho$。

接着计算 $\widetilde{f}$ 的值域。对于所有 $x \in \mathcal{X}$，有：

$$\tilde{a} := \frac{a + (p-1)b}{p} \leq a \leq \tilde{f}(1, x) \leq b \leq \frac{b + (p-1)a}{p} =: \tilde{b}. \tag{91}$$

这里，第一个和最后一个不等式由 $p \in (0,\ 1]$ 及 $a \leq b$ 得到。定义 $c := \widetilde{b} - \widetilde{a}$。

最后，可以通过仿射变换 $f_{01} = c^{-1}\left(\widetilde{f} - \widetilde{a}\right)$ 构造函数 $f_{01} : \mathcal{Y} \times \widehat{\mathcal{Y}} \to [0,\ 1]$，使得：

$$\mathrm{R}_{\tilde{f}}[h] - \hat{\mathrm{R}}_{\tilde{f}}[h] = c\left(\mathrm{R}_{f_{01}}[h] - \hat{\mathrm{R}}_{f_{01}}[h]\right). \tag{92}$$

利用 Mohri et al.（2018，定理 3.3），右侧可以以 $1 - \delta$ 的概率界定为：

$$\mathrm{R}_{f_{01}}[h] - \hat{\mathrm{R}}_{f_{01}}[h] \leq \mathfrak{R}_n(f_{01} \circ \mathcal{H}) + \sqrt{\frac{\log(1/\delta)}{2n}}. \tag{93}$$

由于 f_{01} 的 Lipschitz 常数为 $c^{-1}p^{-1}(2 - p)$，根据收缩引理（Shalev-Shwartz and Ben-David, 2014，引理 26.9），有：

$$\mathfrak{R}_n(f_{01} \circ \mathcal{H}) \leq c^{-1}\frac{2-p}{p}\rho\,\mathfrak{R}_n(\mathcal{H}). \tag{94}$$

因此，以 $1 - \delta$ 的概率，对所有 $h \in \mathcal{H}$，都有：

$$\mathrm{R}_{\tilde{f}}[h] - \hat{\mathrm{R}}_{\tilde{f}}[h] \leq cc^{-1}\frac{2-p}{p}\rho\,\mathfrak{R}_n(\mathcal{H}) + c\sqrt{\frac{\log(1/\delta)}{2n}} \tag{95}$$

$$= \frac{2-p}{p}\rho\,\mathfrak{R}_n(\mathcal{H}) + \frac{(2-p)(b-a)}{p}\sqrt{\frac{\log(1/\delta)}{2n}} \tag{96}$$

将 f 替换为 $-f$，即可得到第二个界。证毕。

译注（原文公式保留）。原文式（88）右侧未加绝对值；式（91）包含中间不等式 $a \leq \widetilde{f}(1,\ x) \leq b$；式（94）前对 Lipschitz 常数的文字表述未写 ρ；定理陈述中的 Rademacher 项系数与式（95）、（96）中的系数也不同。此处均照录原文。

这一结果与 Natarajan et al.（2017，引理 8）非常相似。然而，如下文所论证，该定理缺少一个与损失函数值域有关的缩放因子。为便于对照，原定理的表述如下。

定理 18（Natarajan et al.（2017，引理 8））。设对于每个 y，$l(t,\ y)$ 关于 t 都是 L-Lipschitz 连续的。那么，对任意 $\alpha \in (0,\ 1)$，以至少 $1 - \delta$ 的概率，有：

$$\max_{f \in \mathcal{F}} \left| \hat{R}_{\tilde{l}_\alpha}(f) - R_{\tilde{l}_\alpha, D_\rho}(f) \right| \leq 2L_\rho\,\mathfrak{R}_n(\mathcal{F}) + \sqrt{\frac{\log(1/\delta)}{2n}}, \tag{97}$$

其中 $L_\rho \leq 2L/(1 - \rho_{+1} - \rho_{-1})$ 是 $\tilde{l}_\alpha$ 的 Lipschitz 常数。

在证明的第一步，他们使用了一个“风险与经验风险之间的基本 Rademacher 界”，其表述为：

$$\max_{f\in\mathcal{F}}\left|\hat{R}_{\tilde{l}_\alpha}(f)-R_{\tilde{l}_\alpha,D_\rho}(f)\right|\le 2\,\mathfrak{R}_n(\tilde{l}_\alpha\circ\mathcal{F})+\sqrt{\frac{\log(1/\delta)}{2n}} \tag{98}$$

然而，这样的界要么要求 $\tilde{l}_\alpha$ 的值域是 $[0,\,1]$ 的子集（Mohri et al., 2018，定理 3.3），要么会像 Shalev-Shwartz and Ben-David（2014，定理 26.5）那样，在平方根项前引入一个额外因子。另外，他们使用的是双侧界，而非所引用两个定理中的单侧界。这意味着需要将 δ 替换为 $\delta/2$，因为平方根项来自 McDiarmid 不等式的一次应用。

引理 19。对任意 $f\in\mathcal{M}(\mathcal{Y}\times\mathcal{X},\,\mathbb{R})$、$p\in(0,\,1]$，以及 $\mathbb{E}[Y]=q$，有：

$$\mathbb{E}[|\mathfrak{P}_p(f)(Y,X)-f(Y,X)|]\le q\frac{1-p}{p}m\quad with\quad m\coloneqq\sup_{x\in\mathcal{X}}(|f(1,x)-f(0,x)|). \tag{99}$$

其中，式中的 “with” 意为“其中”。

证明。为简化记号，记 $U{:=}f(1,\,X)$、$V{:=}f(0,\,X)$。代入 $\mathfrak{P}_p(f)$，可将差值化简为：

$$\begin{aligned}&\mathfrak{P}_p(f)(Y,X)-f(Y,X)\\&\quad=Yp^{-1}\left(f(1,X)+(p-1)f(0,X)\right)+(1-Y)f(0,X)-f(Y,X)\\&\quad=Yp^{-1}\left(U+(p-1)V\right)+(1-Y)V-YU-(1-Y)V\\&\quad=(p^{-1}-1)(YU)+\frac{p-1}{p}YV=\frac{1-p}{p}(Y(U-V)).\end{aligned}$$

由 m 的定义可知 $|U-V|\le m$，因此期望满足：

$$\mathbb{E}[|\mathfrak{P}_p(f)(Y,X)-f(Y,X)|]=\frac{1-p}{p}\,\mathbb{E}[|Y(U-V)|]\le\frac{1-p}{p}\,\mathbb{E}[Ym]\le\frac{1-p}{p}qm. \tag{100}$$

证毕。

定理 6（泛化界）。设 $\mathcal{H}$ 是 Rademacher 复杂度为 $\mathfrak{R}_n(\mathcal{H})$ 的函数类。设 $f^*:\mathcal{Y}\times\widehat{\mathcal{Y}}\to[a,\,b]$（$a<b\in\mathbb{R}$）是关于第二个自变量 ρ-Lipschitz 连续的损失函数。令 $f{:=}\mathfrak{P}_pf^*$，并记：

$$r^\star\coloneqq\inf_{h\in\mathcal{H}}\mathrm{R}^*_{f^*}[h]\,,\quad\hat{h}\coloneqq\operatorname*{argmin}_{h\in\mathcal{H}}\hat{\mathrm{R}}_f[h]\,,\quad\tilde{h}\coloneqq\operatorname*{argmin}_{h\in\mathcal{H}}\hat{\mathrm{R}}_{f^*}[h]\,. \tag{17}$$

以及：

$$\begin{aligned}c&\coloneqq\rho\,\mathfrak{R}_n(\mathcal{H})+(b-a)\sqrt{\frac{\log(2/\delta)}{2n}}\\m&\coloneqq\sup_{x\in\mathcal{X}}(|f^*(1,x)-f^*(0,x)|).\end{aligned} \tag{18}$$

对于给定的 n 个点组成的样本，以至少 $1-\delta$ 的概率，有：

$$\hat{r} \coloneqq \mathrm{R}^*_{f^*}\left[\hat{h}\right] \leq r^\star + 2\frac{2-p}{p}c \tag{19}$$

$$\tilde{r} \coloneqq \mathrm{R}^*_{f^*}\left[\tilde{h}\right] \leq r^\star + q\frac{1-p}{p}m + 2c, \tag{20}$$

其中 $q\coloneqq\mathbb{E}[Y] \leq 1$。

证明。取 $\epsilon > 0$，并选择 h'，使得：

$$wever\, \mathrm{R}^*_{f^*}\left[h'\right] \leq r' + \epsilon. \tag{101}$$

由此得到 $\hat{r} - r' \leq \mathrm{R}^*_{f^*}[\widehat{h}] - \mathrm{R}^*_{f^*}[h'] + \epsilon$，以及 $\tilde{r} - r' \leq \mathrm{R}^*_{f^*}\left[\widetilde{h}\right] - \mathrm{R}^*_{f^*}[h'] + \epsilon$。

利用 $\mathfrak{R}_n\big(\{h'=0\}\big) = 0$，可以将定理 17 应用于函数类 $\{h'\}$，得到以 $1-\delta/2$ 的概率成立的下式：

$$\hat{\mathrm{R}}_f\left[h'\right] - \mathrm{R}_f\left[h'\right] \leq \frac{(2-p)(b-a)}{p}\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{102}$$

对于第一个不等式，可以利用 f 的无偏性，以及 $\widehat{h}$ 关于 $\widehat{\mathrm{R}}_f$ 的近最优性，得到如下界：

$$\begin{aligned}
\mathrm{R}^*_{f^*}\left[\hat{h}\right] - \mathrm{R}^*_{f^*}\left[h'\right] &= \mathrm{R}_f\left[\hat{h}\right] - \mathrm{R}_f\left[h'\right] && \text{(unbiasedness)}\\
&= \mathrm{R}_f\left[\hat{h}\right] - \hat{\mathrm{R}}_f\left[\hat{h}\right] + \hat{\mathrm{R}}_f\left[\hat{h}\right] - \hat{\mathrm{R}}_f\left[h'\right] + \hat{\mathrm{R}}_f\left[h'\right] - \mathrm{R}_f\left[h'\right]\\
&\leq \mathrm{R}_f\left[\hat{h}\right] - \hat{\mathrm{R}}_f\left[\hat{h}\right] + \hat{\mathrm{R}}_f\left[h'\right] - \mathrm{R}_f\left[h'\right] && \text{(optimality)}\\
&\leq \sup_{h\in\mathcal{H}}\left(\mathrm{R}_f[h] - \hat{\mathrm{R}}_f[h]\right) + \hat{\mathrm{R}}_f\left[h'\right] - \mathrm{R}_f\left[h'\right].
\end{aligned}$$

式中的 “unbiasedness” 表示“无偏性”，“optimality” 表示“最优性”。

对剩余两项应用并集界，以 $1-\delta$ 的概率，有：

$$\begin{aligned}
\hat{r} - r' &\leq \epsilon + \frac{4-2p}{p}\,\mathfrak{R}(\mathcal{H}) + \frac{(2-p)(b-a)}{p}\sqrt{\frac{\log(2/\delta)}{2n}} + \frac{(2-p)(b-a)}{p}\sqrt{\frac{\log(2/\delta)}{2n}}\\
&= \epsilon + \frac{4-2p}{p}\left(\mathfrak{R}_n(\mathcal{H}) + (b-a)\sqrt{\frac{\log(2/\delta)}{2n}}\right).
\end{aligned} \tag{103}$$

令 $\epsilon \to 0$，即得第一个结论。

对于 $\widetilde{h}$，可将风险差分解为：

$$\mathrm{R}^*_{f^*}\left[\tilde{h}\right] - \mathrm{R}^*_{f^*}\left[h'\right] = \underbrace{\mathrm{R}^*_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right]}_{a} + \underbrace{\hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[h'\right]}_{b} + \underbrace{\hat{\mathrm{R}}_{f^*}\left[h'\right] - \mathrm{R}^*_{f^*}\left[h'\right]}_{c} \tag{104}$$

然后分别考察各项的贡献。由于 $\widetilde{h}$ 是经验风险最小化解（ERM），有：

$$b = \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[h'\right] \leq 0. \tag{105}$$

进一步，利用无偏性，并将引理 19 应用于函数 $(x,\, y) \mapsto f\left(y,\, \widetilde{h}\,(x)\right)$，得到：

$$\begin{aligned} a = \mathrm{R}^*_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] &= \mathrm{R}_{f}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] && \text{(unbiasedness)} \\ &= \mathrm{R}_{f}\left[\tilde{h}\right] - \mathrm{R}_{f^*}\left[\tilde{h}\right] + \mathrm{R}_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] && (106) \\ &\leq q\frac{1-p}{p}m + \mathrm{R}_{f^*}\left[\tilde{h}\right] - \hat{\mathrm{R}}_{f^*}\left[\tilde{h}\right] && \text{(Lemma 19)} \\ &\leq q\frac{1-p}{p}m + \sup_{h\in\mathcal{H}}\left(\mathrm{R}_{f^*}[h] - \hat{\mathrm{R}}_{f^*}[h]\right) && (107) \end{aligned}$$

式中的 “unbiasedness” 表示“无偏性”，“Lemma 19” 表示“引理 19”。

取 $p = 1$，应用定理 17，即可得到 $f^* = \mathfrak{P}_0 f^*$ 对应的界，使得以下两个不等式各自以 $1 - \delta/2$ 的概率成立：

$$\sup_{h\in\mathcal{H}}\left(\mathrm{R}_{f^*}[h] - \hat{\mathrm{R}}_{f^*}[h]\right) \leq \frac{4-2}{1}\,\mathfrak{R}_n(\mathcal{H}) + \frac{(2-1)(b-a)}{1}\sqrt{\frac{\log(2/\delta)}{2n}} \tag{108}$$

$$c = \hat{\mathrm{R}}_{f^*}\left[h'\right] - \mathrm{R}^*_{f^*}\left[h'\right] \leq \frac{(2-1)(b-a)}{1}\sqrt{\frac{\log(2/\delta)}{2n}}. \tag{109}$$

因此，利用并集界，以 $1 - \delta$ 的概率，有：

$$\mathrm{R}^*_{f^*}\left[\tilde{h}\right] - \mathrm{R}^*_{f^*}\left[h'\right] \leq q\frac{1-p}{p}m + 2\,\mathfrak{R}_n(\mathcal{H}) + 2(b-a)\sqrt{\frac{\log(2/\delta)}{2n}} + \epsilon. \tag{110}$$

令 $\epsilon \to 0$，即证得结论。证毕。

译注（原文记号保留）。本证明从式（101）起使用 r'，而定理陈述使用 $r^\star$；式（101）左侧还印有 “wever” 字样。原文的 $\mathfrak{R}_n\left(\{h' = 0\}\right) = 0$、式（103）第一行的 $\mathfrak{R}\,(\mathcal{H})$、式（103）、（108）、（110）中未写出的 ρ 因子，以及“取 $p = 1$”之后的 $\mathfrak{P}_0$ 下标，均按原文保留，不作修正。

B.3 多标签情形的无偏估计

定理 12（多标签损失）。设 $l \in \mathbb{N}$，且 $f^* : \{0,\, 1\}^l \times \mathcal{X} \to \mathbb{R}$ 是某个映射。该函数的无偏估计可以用倾向评分表达式 $\mathfrak{P}_{\mathbf{p}}\left(f^*\right) = f$ 计算，其中：

$$(\mathbf{y}, x) \mapsto \left(\prod_{i\in\mathcal{I}(\mathbf{y})}\frac{1}{p_i}\right)\cdot\sum_{\mathcal{J}\subset\mathcal{I}(\mathbf{y})} f^*(\mathbf{1}^{(\mathcal{J})}, x)\prod_{j\in\mathcal{I}(\mathbf{y})\setminus\mathcal{J}}(p_j - 1)\,, \tag{29}$$

这里，$\mathbf{1}^{(\mathcal{J})} \in \{0,\, 1\}^l$ 在所有下标 $j \in \mathcal{J}$ 处的分量均为 1。

证明。 与二分类情形一样，利用 $\{0,\,1\}^l$ 的有限性，可以将 f^* 写为：

$$f^*(y,x) = \sum_{\mathcal{I}\subset[l]} \mathbb{1}\Big\{y = \mathbf{1}^{(\mathcal{I})}\Big\}\, f^*(\mathbf{1}^{(\mathcal{I})},x) \tag{111}$$

$$= \sum_{\mathcal{I}\subset[l]} f^*(\mathbf{1}^{(\mathcal{I})},x) \left(\prod_{i\in\mathcal{I}} y_i\right) \prod_{j\in\overline{\mathcal{I}}} (1-y_j) \tag{112}$$

这里将指示函数改写为 y_i 与 $1-y_j$ 的乘积。

首先，证明以下表达式的无偏性：

$$\tilde{f}(\mathbf{y},x) \coloneqq \sum_{\mathcal{I}\subset[l]} f^*(\mathbf{1}^{(\mathcal{I})},x) \left(\prod_{i\in\mathcal{I}} \frac{y_i}{p_i}\right) \prod_{j\in\overline{\mathcal{I}}} \left(1-\frac{y_j}{p_j}\right). \tag{113}$$

稍后将证明，这个表达式实际上与式（29）等价。利用期望的线性性，可以显式计算：

$$\mathbb{E}\Big[\tilde{f}(\mathbf{Y},X)\Big] = \sum_{\mathcal{I}\subset[l]} \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \left(\prod_{i\in\mathcal{I}} \frac{M_i Y_i^*}{p_i}\right) \prod_{j\in\overline{\mathcal{I}}} \left(1-\frac{M_j Y_j^*}{p_j}\right)\right] \tag{114}$$

对于一个固定子集 $\mathcal{J}$，可将表达式改写为：

$$f^*(\mathbf{1}^{(\mathcal{I})},X) \left(\prod_{i\in\mathcal{I}} \frac{M_i Y_i^*}{p_i}\right) \prod_{j\in\overline{\mathcal{I}}} \left(1-\frac{M_j Y_j^*}{p_j}\right) = \sum_{\mathcal{J}\subset[l]} f^*(\mathbf{1}^{(\mathcal{I})},X) \prod_{i\in\mathcal{J}} \alpha_{\mathcal{J}} M_i Y_i^* \tag{115}$$

其中系数 $\alpha_{\mathcal{J}} \in \mathbb{R}$ 经过适当选取。利用 $\mathbf{M}$ 的独立性，可得：

$$\mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \prod_{i\in\mathcal{J}} \alpha_{\mathcal{J}} M_i Y_i^*\right] = \mathbb{E}\left[\prod_{i\in\mathcal{J}} M_i\right] \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \prod_{j\in\mathcal{J}} \alpha_{\mathcal{J}} Y_j^*\right] \tag{116}$$

$$= \left(\prod_{i\in\mathcal{J}} q_i\right) \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \prod_{j\in\mathcal{J}} \alpha_{\mathcal{J}} Y_j^*\right] = \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \prod_{j\in\mathcal{J}} \alpha_{\mathcal{J}} p_j Y_j^*\right]. \tag{117}$$

因此，可以将期望中所有出现的 M_i 替换为 p_i，并将结果与式（112）比较：

$$\mathbb{E}\Big[\tilde{f}(\mathbf{Y},X)\Big] = \sum_{\mathcal{I}\subset[l]} \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \left(\prod_{i\in\mathcal{I}} \frac{p_i Y_i^*}{p_i}\right) \prod_{j\in\overline{\mathcal{I}}} \left(1-\frac{p_j Y_j^*}{p_j}\right)\right] \tag{118}$$

$$= \sum_{\mathcal{I}\subset[l]} \mathbb{E}\left[f^*(\mathbf{1}^{(\mathcal{I})},X) \left(\prod_{i\in\mathcal{I}} Y_i^*\right) \prod_{j\in\overline{\mathcal{I}}} \left(1-Y_j^*\right)\right] \tag{119}$$

$$= \mathbb{E}[f^*(\mathbf{Y}^*,X)]\,. \tag{120}$$

译注（原文公式保留）。式（115）至（117）中系数 $\alpha_{\mathcal{J}}$ 位于乘积号内，式（117）的第一个乘积使用 q_i，而后续表达式使用 p_j；此处均按原文保留。

现在证明 $\widetilde{f} = f$：对于任意 $\mathcal{J} \not\subset \mathcal{I}(\mathbf{y})$，存在 $j \in \mathcal{J}$ 使得 $y_j = 0$，所以相应求和项的贡献为零。因此：

$$\tilde{f}(\mathbf{y}, x) = \sum_{\mathcal{J} \subset \mathcal{I}(\mathbf{y})} f^*(\mathbf{1}^{(\mathcal{J})}, x) \left(\prod_{i \in \mathcal{J}} \frac{1}{p_i} \right) \prod_{j \in \overline{\mathcal{J}}} \left(1 - \frac{y_j}{p_j} \right). \tag{121}$$

现在，对于每个满足下式的 j：

$$j \in \overline{\mathcal{I}(\mathbf{y})}$$

都有 $y_j = 0$，因此可以进一步化简为：

$$= \sum_{\mathcal{J} \subset \mathcal{I}(\mathbf{y})} f^*(\mathbf{1}^{(\mathcal{J})}, x) \left(\prod_{i \in \mathcal{J}} \frac{1}{p_i} \right) \prod_{k \in \mathcal{I}(\mathbf{y}) \setminus \mathcal{J}} \left(1 - \frac{1}{p_k} \right). \tag{122}$$

最后，注意到：

$$\left(\prod_{i \in \mathcal{J}} \frac{1}{p_i} \right) \prod_{k \in \mathcal{I}(\mathbf{y}) \setminus \mathcal{J}} \left(1 - \frac{1}{p_k} \right) = \left(\prod_{i \in \mathcal{J}} \frac{1}{p_i} \left(\frac{p_i - 1}{p_i} \right)^{-1} \right) \prod_{k \in \mathcal{I}(\mathbf{y})} \left(\frac{p_k - 1}{p_k} \right), \tag{123}$$

这就证明了所述结论。证毕。

定理 13（多标签唯一性）。设 $\mathfrak{P}_{\mathbf{p}}$ 表示定理 12 中的倾向评分算子，$\mathfrak{P}$ 是另一个算子，使得对于所有 f^*，以及 $\mathbf{Y}^*$ 与 X 的所有分布，都有：

$$\mathbb{E}[f^*(\mathbf{Y}^*, X)] = \mathbb{E}[\mathfrak{P}(f^*)(\mathbf{Y}, X)] \tag{33}$$

那么 $\mathfrak{P}\left(f^*\right) = \mathfrak{P}_{\mathbf{p}}\left(f^*\right)$。

证明。设 f^* 是任意函数 $f^* : \mathcal{Y} \times \mathcal{X} \to \mathbb{R}$。需要证明：

$$\tilde{f} := \mathfrak{P}(f^*) = \mathfrak{P}_{\mathbf{p}}(f^*) =: f. \tag{124}$$

由于式（33）必须对 X 与 $\mathbf{Y}^*$ 的所有可能分布成立，特别地，它也必须在 $\mathbb{P}\{X = x,\ \mathbf{Y}^* = \mathbf{y}^*\} = 1$ 时成立。由于 $\mathbf{Y}$ 只能取有限多个状态，可以将 $\mathfrak{P}\left(f^*\right)$ 分解为对这些状态的求和。已知 f 满足式（33），因此关于 $\widetilde{f}$ 的等式变为：

$$0 = \mathbb{E}\Big[\tilde{f}(\mathbf{Y}, X) - f(\mathbf{Y}, X)\Big] = \sum_{\mathbf{y} \in 2^{\mathcal{Y}}} \mathbb{E}\Big[(\tilde{f}(x, \mathbf{y}) - f(x, \mathbf{y}))\mathbb{1}\{\mathbf{y} = Y\}\Big] = \sum_{\mathbf{y}' \in 2^{\mathcal{Y}}} (\tilde{f}(x, \mathbf{y}') - f(x, \mathbf{y}'))\mathbb{P}\{\mathbf{y}' = Y\} \tag{125}$$

接下来通过归纳法证明，对于所有 $\mathbf{y} \in \mathcal{Y}$，都有 $\widetilde{f}(x, \mathbf{y}) - f(x, \mathbf{y}) = 0$。首先，假设 $\mathbf{y}^* = \mathbf{0}$。那么 $\mathbb{P}\{\mathbf{y}' = Y\} = \mathbb{1}\{\mathbf{y}' = \mathbf{0}\}$，式（125）简化为：

$$0 = \tilde{f}(x, \mathbf{0}) - f(x, \mathbf{0}), \tag{126}$$

因此，对于这个 $\mathbf{y}^*$，$\widetilde{f}$ 与 f 相等。

接下来，假设对于所有至多具有 m 个非零分量的 $\mathbf{y}'$，都有 $\widetilde{f}(\mathbf{y}', x) = f(\mathbf{y}', x)$。设 $\mathbf{y}$ 是一个具有 $m+1$ 个非零分量的向量，则式（125）可写为：

$$\begin{aligned} 0 = \sum_{\substack{\mathbf{y}' \in 2^{\mathcal{Y}} \\ |\mathbf{y}'| \le m}} (\tilde{f}(x, \mathbf{y}') - f(x, \mathbf{y}'))\mathbb{P}\{\mathbf{y}' = Y\} + (\tilde{f}(x, \mathbf{y}^*) - f(x, \mathbf{y}^*))\mathbb{P}\{\mathbf{y}^* = Y\} \\ = (\tilde{f}(x, \mathbf{y}^*) - f(x, \mathbf{y}^*))\mathbb{P}\{\mathbf{y}^* = Y\}. \end{aligned} \tag{127}$$

这里，第一个求和为零，因为其中所有求和项使用的向量 $\mathbf{y}'$ 都至多具有 m 个元素。由于假设所有倾向概率均非零，因子 $\mathbb{P}\{\mathbf{y}^* = Y\}$ 非零，这意味着 $\widetilde{f}(x, \mathbf{y}^*) - f(x, \mathbf{y}^*)$ 必须为零。

因此，$\widetilde{f}$ 与 f 完全相同。由于这对所有 $x \in \mathcal{X}$ 都成立，算子 $\mathfrak{P}$ 与 $\mathfrak{P}_{\mathbf{p}}$ 必须完全相同。证毕。

译注（原文记号保留）。本证明在 $\widetilde{f}(\mathbf{y}, x)$ 与 $\widetilde{f}(x, \mathbf{y})$ 等表达式之间交替使用参数顺序；式（125）、（127）的求和下标写作 $2^{\mathcal{Y}}$；归纳步骤的文字使用 $\mathbf{y}$，相应公式使用 $\mathbf{y}^*$。这些差异均按原文保留。

附录 C 实验

C.1 用于 PsRecall 估计的模型

生成表 2 结果的网络使用 DiSMEC 算法（Babbar and Schölkopf, 2017）训练，损失函数为平方铰链损失（VN），或 Qaraei et al. (2021) 所述、基于平方铰链损失构造的无偏 0-1 损失估计的凸代理。数据集来自极端分类资源库（Bhatia et al., 2016），并通过 tf-idf 变换预处理。

在标签过多的这些情形中，仍可计算无偏估计，代价是方差进一步增加：对这些样本，人为生成缺失更多标签的子采样真值，并相应调整倾向概率。实践中，如果真值含有超过 25 个标签，我们的实现把全部倾向概率除以 2，并以 50% 的概率删除每个真实标签。为稍微减小方差增加，对 100 次子采样取平均。如果所得子样本仍含过多标签，可递归使用这一技术。

表 2 中 PsRecall 数值的最终计算包含离群值过滤。AmazonCat-13K 数据集对应的直方图见图 7。

C.2 归一化 BCE

正文中指出，在强正则化区间，使用归一化 BCE 的无偏训练表现较差，是因为不良局部极小值。本节提供支持证据。

如图 8 所示，较差表现来自训练数据上的高损失（虚线），而非泛化。然而，与使用无偏损失 c 训练、直接优化该量相比，用普通损失 b 训练在带噪训练数据上的损失（即在带噪训练数据上计算的无偏估计）低得多。这有两种可能解释：一是改用无偏损失改变了损失与正则项的平衡，使正则项的总体权重显著增大，从而对损失优化得更少；二是优化过程陷入局部极小值。

可通过以下实验区分两种原因：先用普通损失预训练 10 轮，以得到初始权重。如果表现差的原因是正则化权衡，那么随后 20 轮无偏训练会增加训练损失，直至达到相应权衡；反之，若原因是局部极小值，从一个已知“好”极小值附近开始，就会收敛到该极小值。

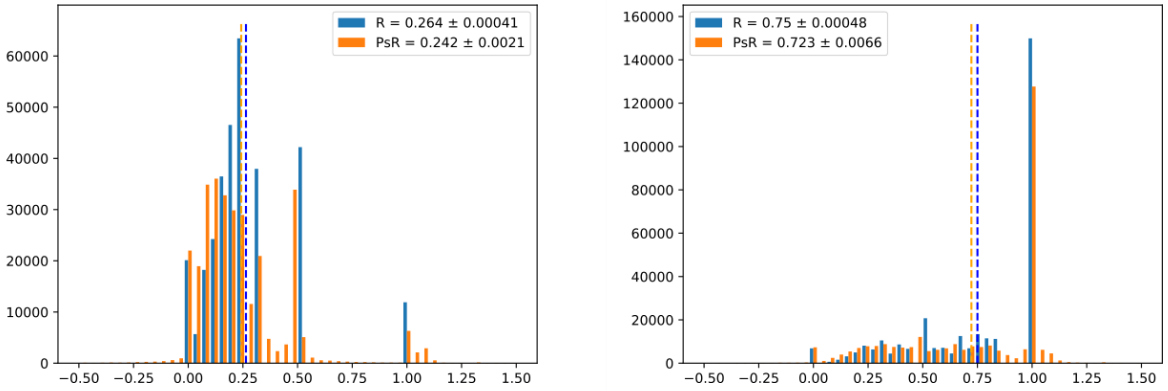


图 7。 在 AmazonCat-13K 数据集上，使用倾向评分 0-1 损失的凸代理训练 DiSMEC 模型后，top-1 预测（左）和 top-5 预测（右）的倾向评分召回率（PsR）与普通召回率（R）直方图。纵轴表示测试集中估计值落入对应区间的样本数。误差通过自助法计算 95% 置信区间。竖直虚线表示均值。

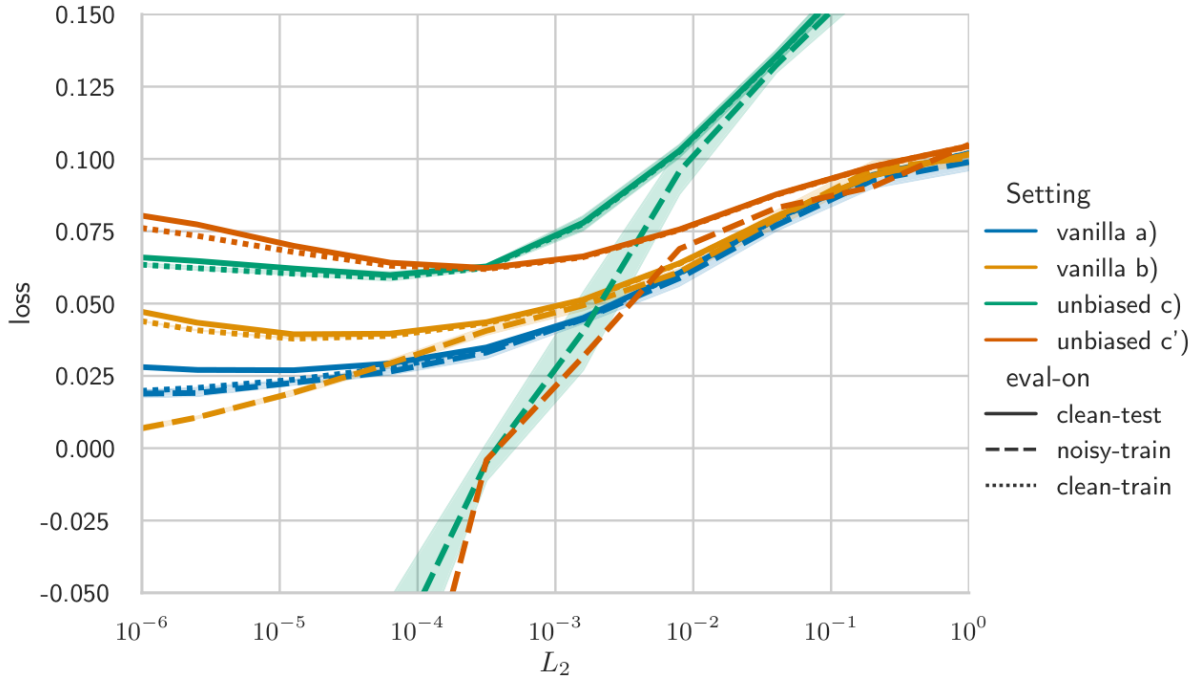


图 8。 不同正则化强度下的归一化二元交叉熵，分别在带噪训练数据、干净训练数据和干净测试数据上评估。配置 c′ 对应先进行普通损失预训练、再进行无偏训练。图例：vanilla a/b 为普通配置 a/b，unbiased c/c′ 为无偏配置 c/c′；clean-test 为干净测试集，noisy-train 为带噪训练集，clean-train 为干净训练集。纵轴 loss 为损失，横轴为 L_2 正则化强度。

图 8 呈现第二种情况的行为，因此支持了局部极小值假说。