面向高效多视图子空间聚类的鲁棒共识锚点学习

Robust Consensus Anchor Learning for Efficient Multi-view Subspace Clustering

Yalan Qin[1]、Nan Pu[2]、Guorui Feng[1]、Nicu Sebe[2]

[1] 中国上海大学通信与信息工程学院，上海 200444。[2] 意大利特伦托大学信息工程与计算机科学系，特伦托 40128。通信作者：Guorui Feng（fgr2082@aliyun.com）。

第 42 届国际机器学习大会（ICML），加拿大温哥华；PMLR 267:50327-50337，2025。原文版权 © 2025 原作者。原文：https://proceedings.mlr.press/v267/qin25e.html

译文说明与许可

本文件是非官方中文全文译文，由 Codex 辅助翻译与排版，未获原作者审阅或背书。原文按 CC BY 4.0 许可发布；本译文同样按 CC BY 4.0 提供。许可：https://creativecommons.org/licenses/by/4.0/ 。PMLR 出版协议：https://proceedings.mlr.press/pmlr-license-agreement.html 。

修改内容：将正文、定理与证明、算法、图表说明、致谢和影响声明翻译为中文并重新分页；公式 (1)-(34)、引理中的矩阵不等式、图 1-3 和表 1-3 从已核实的官方 PDF 截取，以保留符号、曲线和数值；图内英文标记与参考文献保留原样。文中引文沿用原作者的作者-年份标识。未省略正文或证明；无不可读区域；参考文献保留原英文书目信息以便检索。

原文 11 页。仓库副本与 PMLR 官方下载版逐字节一致，SHA-256：923aabbbcdd7605a235c49cc0bd607731cc5c9ccd5e581d99478bed6369b4d9d。图 1-3 均为论文实验曲线或运行时间图，表 1-3 为实验结果；已检查正文、图注和文末，未见单独列明的第三方图像版权例外。数据集与被引文献的权利不因此改变。

摘要

多视图子空间聚类是人工智能中一种重要的无监督分类算法，用于划分来自不同子空间的无标签数据。近期，基于锚点的方法被用于降低大规模数据集上多视图聚类的计算复杂度。这些方法的主要区别在于各自定义的目标函数。尽管取得了显著成功，它们很少通过有效方式保证所学习共识锚点的鲁棒性，以实现高效多视图聚类，也很少研究仿射子空间中簇的具体局部分布。此外，鲁棒共识锚点与不同视图共享的公共簇结构尚不能同时学习。

本文提出面向高效多视图子空间聚类的鲁棒共识锚点学习方法（RCSC）。首先，我们证明：当数据充分采样自相互独立的子空间，且目标函数满足一定条件时，所得锚点图具有块对角结构。作为一种特例，我们给出在共识锚点学习中结合 Frobenius 范数、非负约束和仿射约束的模型，从而保证所学习共识锚点的鲁棒性，实现高效多视图聚类，并研究仿射子空间中簇的具体局部分布。八个多视图数据集上的实验从有效性与效率两个方面验证了 RCSC 的优势。

1. 引言

聚类是人工智能与机器学习中的一个重要领域（Jain, 2008）。随着信息技术的发展，现实场景中能够收集来自多个视图或通道的大量数据（Liu et al., 2025; Qin et al., 2023d）。这类数据称为多视图数据，在现实世界中广泛存在。例如，可以用局部二值模式（LBP）、方向梯度直方图（HOG）和 Gabor 特征等多种表示来描述一幅图像。为在聚类任务中处理多视图数据，已有研究提出了各种多视图聚类方法。

与单视图数据的聚类方法（Qin et al., 2023e;a; 2021; 2022b; 2025b; Pu et al., 2024）相比，多视图聚类在实践中能够取得更合理的性能（Qin et al., 2022a; Liu et al., 2024; Qin et al., 2023b; Liu et al., 2023b; Qin et al., 2023c; Sun et al., 2024; Qin et al., 2024a; Liu et al., 2022a; Qin et al., 2024d; Liu et al., 2023a; Qin et al., 2025c; Liu et al., 2022b; Qin et al., 2025e）。它能够整合同一对象在不同视图下获得的多种特征表示，提供更全面的对象信息。在现有多视图聚类研究中，基于图的方法近年来受到了广泛关注。

基于图的多视图聚类方法（Nie et al., 2017b; Zhan et al., 2019; Wang et al., 2020）通过构建图结构反映多视图数据中样本之间的关系，再对所得图进行划分以得到最终结果。这些方法通常采用 $n \times n$ 的邻接图描述数据点之间的关系。Cao et al.（2015）提出基于多样性与平滑性的多视图聚类方法，研究不同表示之间的互补性。Wang et al.（2020）通过相互增强技术学习统一的全局图和各视图专属图。Chen et al.（2020）同时学习全局自表示、潜在嵌入空间和簇结构，以进行多视图数据的子空间学习。Liang et al.（2020）通过多视图图学习获得统一图，并利用多个视图专属图之间的一致性与不一致性。

Nie et al.（2017a）提出同时进行局部结构学习与半监督分类/聚类。Wang et al.（2020）把统一图、由跨视图相似性诱导的图以及指示矩阵耦合到统一框架中。尽管进展显著，大多数此类多视图聚类方法仍面临较高的计算复杂度。构造 $n \times n$ 邻接图需要 $O(n^2)$，划分该图需要 $O(n^3)$，这限制了它们对大规模多视图数据集的可扩展性。

为解决计算复杂度问题，研究者提出了基于锚点的多视图聚类方法（Qin et al., 2025a;d; Qin & Qian, 2024; Qin et al., 2024c;b），并在实际应用中表现出良好能力。与构造 $n \times n$ 图不同，这些方法通常从数据集中生成少量锚点，通过构造 $n \times l$ 锚点图表示数据结构，其中 l 表示锚点总数。通常 l 小于 n，因此能大幅减小数据规模，从而提高聚类效率。

具体而言，Yang et al.（2021）提高了效率，并要求所有视图产生相同锚点。Kang et al.（2020）使用基于锚点的子空间学习，为每个视图学习锚点图，然后启发式地将不同锚点图合并为统一图。Li et al.（2022）提出通过锚点图融合实现可扩展多视图聚类的方法，利用离散簇结构自适应地学习统一图。Wang et al.（2022）使用多个投影矩阵和一组潜在共识锚点来学习统一锚点图。Yang et al.（2022）在 K-means 引导下从原始数据中寻找 l 个锚点，将所得质心作为锚点，并在锚点与原始数据集之间构建稀疏锚点图。

尽管取得了显著成功，这些方法很少保证所学习共识锚点的鲁棒性，以实现高效多视图聚类，也很少研究仿射子空间中簇的具体局部分布。所学习共识锚点之间的相关性未得到充分探索，而这种相关性能够促进分组效应，使高度相关的锚点聚为一组。此外，鲁棒共识锚点和不同视图共享的公共簇结构无法在统一框架中同时学习，因此不能保证这些过程相互增强，也无法得到更有判别力的共识锚点与簇指示矩阵。

为解决上述问题，我们提出新的 RCSC 方法。首先，从理论上证明：在子空间独立的假设下，如果目标函数满足一定条件，就可以得到块对角锚点图。作为一种特例，我们在共识锚点学习中结合 Frobenius

范数、非负约束和仿射约束，以保证所学习共识锚点的鲁棒性，实现高效多视图聚类，并研究仿射子空间中簇的具体局部分布。虽然模型简单，我们仍从理论上对所构建的 RCSC 给出几何分析。三个约束的联合能够限制每个数据点在具有特定簇局部分布的仿射子空间中的描述方式，从而保证所学习共识锚点的鲁棒性。

通过视图专属投影，我们能够充分探索所学习共识锚点之间的相关性，促进分组效应，并将高度相关的锚点聚在一起。我们在统一框架中联合建模鲁棒锚点学习、划分与锚点图构建，从而同时学习鲁棒共识锚点和不同视图共享的公共簇结构，保证这些过程相互增强，得到更有判别力的共识锚点与簇指示矩阵。通过对实际基施加正交约束，我们基于严格的聚类解释，把一个因子矩阵约束为簇指示矩阵。随后开发交替最小化算法求解所提出的问题。本文的主要贡献如下。

1. 提出面向高效多视图子空间聚类的 RCSC。首先从理论上证明，目标函数满足一定条件时可以获得块对角结构的锚点图。作为一种特例，给出在共识锚点学习中结合 Frobenius 范数、非负约束和仿射约束的模型，保证所学习共识锚点的鲁棒性，并研究仿射子空间中簇的具体局部分布。

2. 在视图专属投影的引导下，充分探索所学习共识锚点之间的相关性，促进分组效应，使高度相关的锚点聚为一组。在统一框架中联合进行鲁棒锚点学习、划分与锚点图构建，因而同时学习鲁棒共识锚点和不同视图共享的公共簇结构，保证这些过程相互增强，获得更有判别力的共识锚点与簇指示矩阵。

3. 对实际基施加正交约束，并基于严格的聚类解释，将一个因子矩阵约束为簇指示矩阵。不同多视图数据集上的大量实验验证了 RCSC 的有效性与效率，特别是在大规模数据集上。

2. 方法

本节先介绍 RCSC 的动机与建模，再给出优化过程以及相关计算复杂度分析。

2.1. 动机

锚点策略通常通过选取少量数据点作为锚点基来发现潜在结构。现有一些基于锚点的多视图聚类方法使用 K-means 获得聚类质心，同时固定锚点基。尽管取得了显著成功，这些方法很少保证所学习共识锚点的鲁棒性，以实现高效多视图聚类，也很少研究仿射子空间中簇的具体局部分布。所学习共识锚点之间的相关性未得到充分挖掘，而这种相关性能够促进分组效应，使高度相关的锚点聚在一起。此外，鲁棒共识锚点与多个视图共享的公共簇结构未被同时学习。因此，这些过程之间的相互增强得不到有效保证，也无法得到更有判别力的共识锚点与簇指示矩阵。

2.2. 建模

我们基于潜在空间，通过某种生成模型生成各视图的数据点。给定多视图数据集 $\{X^p \in R^{d_p \times n}\}_{p=1}^{v}$，其中 d_p 和 n 分别为数据维数与数据集大小，首先假设数据无噪声，并将相应目标函数写为：

$$\begin{aligned} &\min_{U^p, A, S} \sum_{p=1}^{v} ||X^p - U^p A S||_F^2, \\ &s.t.\ (U^p)^T U^p = I,\ A^T A = I, \end{aligned} \tag{1}$$

其中，$S \in R^{l \times n}$ 为共享亲和矩阵，$\{U^p\}_{p=1}^{v} \in R^{d_p \times d}$ 表示用于引导共识锚点的投影矩阵，$A \in R^{d \times l}$ 表示统一锚点，l 和 d 分别为锚点数量与各视图的共享维数。$U^p A \in R^{d_p \times l}$ 为基矩阵。下面从理论上证明

：在子空间独立的假设下，如果相应目标函数满足一定条件，就能够得到块对角锚点图，如定理 1 所示。

定理 1. 假设子空间 $\{\Omega_i\}_{i=1}^k$ 相互独立，X^p_i 的各列由 Ω_i 中的一些向量组成，$U^p{}_iA_i$ 的各列由 Ω_i 的一组基组成，其中 $(U^p)^TU^p = I$，$A^TA = I$。那么，以下形式中的解 S 具有块对角结构且唯一：

$$X^p = (U^pA)S \tag{2}$$

证明. 对于非零数据点 $x^p \in \Omega_i$，只需证明存在唯一的 s，使 $x^p = (U^pA)s$，其中 $s = [s_1^T, \ldots, s_k^T]$，$s_i \neq 0$，且对所有 $j \neq i$ 均有 $s_j = 0$。由于 $(U^p)^TU^p = I$ 且 $A^TA = I$，可得 $(U^pA)^T(U^pA) = A^T(U^p)^TU^pA = I$。因此 U^pA 是正交的。由子空间之间的正交性，x^p 存在如下唯一分解：

$$\begin{aligned} x^p &= 0 + \cdots + x^p + \cdots + 0 \\ &= (U_1^pA_1)s_1 + \cdots + (U_i^pA_i)s_i + \cdots + (U_k^pA_k)s_k, \end{aligned} \tag{3}$$

其中 $(U^p{}_iA_i)s_i \in \Omega_i$，$i = 1, \ldots, k$。因此，$(U^p{}_iA_i)s_i = x^p$，且对所有 $j \neq i$，$(U^p{}_jA_j)s_j = 0$。由于 $U^p{}_iA_i$ 是 Ω_i 的一组基，有 $s_i \neq 0$ 且 s_i 唯一，并且对所有 $j \neq i$ 均有 $s_j = 0$。

根据定理 1，可以学习 X^p 的一组基并将其用作字典。若子空间相互独立，则求解式 (1) 容易得到真实解。为了处理仿射子空间中更一般的多视图聚类问题，我们在原始目标函数中加入仿射约束 $S^T1 = 1$，得到以下优化问题：

$$\begin{aligned} &\min_{U^p,A,S} \sum_{p=1}^{v} ||X^p - U^pAS||_F^2, \ \ s.t.\ S^T\mathbf{1} = 1, \\ &(U^p)^TU^p = I,\ A^TA = I, \end{aligned} \tag{4}$$

其中 1 表示所有元素均为 1 的向量。为局部描述来自不同子空间的受污染数据点的分布，我们进一步对 S 加入非负约束，得到：

$$\begin{aligned} &\min_{U^p,A,S} \sum_{p=1}^{v} ||X^p - U^pAS||_F^2, \ \ s.t.\ S \geq 0,\ S^T\mathbf{1} = 1, \\ &(U^p)^TU^p = I,\ A^TA = I. \end{aligned} \tag{5}$$

因此，非负约束使所学习的 S 具有概率意义。实际应用中，数据通常可能受到噪声污染。我们在式 (5) 的仿射约束和非负约束基础上，采用 Frobenius 范数惩罚噪声，形式为：

$$\begin{aligned} &\min_{U^p,A,S} \sum_{p=1}^{v} ||X^p - U^pAS||_F^2 + \lambda\|S\|_F^2,\ s.t.\ S \geq 0, \\ &S^T\mathbf{1} = 1,\ (U^p)^TU^p = I,\ A^TA = I, \end{aligned} \tag{6}$$

其中 $\lambda > 0$ 是平衡不同部分的参数。由此保证高效多视图聚类的鲁棒性，并研究仿射子空间中簇的具体局部分布。分组效应由以下定理说明。

定理 2. 给定数据点 $x^p \in R^{d_p}$、矩阵 $U^pA \in R^{d_p \times n}$ 和参数 λ。假设 U^pA 的每一列均已归一化。设 s* 为以下问题的最优解：

$$\min_{U^p,A,s} \sum_{p=1}^{v} ||x^p - U^pAs||_2^2 + \lambda \|s\|_2^2, \quad s.t.\ S \geq 0, \\ S^T\mathbf{1} = 1,\ (U^p)^TU^p = I,\ A^TA = I. \tag{7}$$

则有：

$$\frac{\|s_i^* - s_j^*\|_2}{\|x^p\|_2} \leq \frac{1}{\lambda}\sqrt{2(1-r)}, \tag{8}$$

其中 $r = (u^p_i a_i)^T(u^p_j a_j)$ 表示基之间的相关性。

证明. 令 $L(s) = ||x^p - U^pAs||_2^2 + \lambda||s||_2^2$。由于 s* 是式 (7) 的最优解，它满足：

$$\left.\frac{\partial L(s)}{\partial s_k}\right|_{s=s^*} = 0. \tag{9}$$

由于 $(U^p)^TU^p = I$ 且 $A^TA = I$，可得 $(U^pA)^T(U^pA) = A^T(U^p)^TU^pA = I$。因此 U^pA 是正交的。于是有：

$$-2(u_i^p a_i)^T(x^p - U^pAs^*) + 2\lambda s_i^* = 0, \tag{10}$$

$$-2(u_j^p a_j)^T(x^p - U^pAs^*) + 2\lambda s_j^* = 0, \tag{11}$$

从而：

$$s_i^* - s_j^* = \frac{1}{\lambda}((u_i^p a_i)^T - (u_j^p a_j)^T)(x^p - U^pAs^*), \tag{12}$$

$$\|u_i^p a_i\|^2 = \|u_j^p a_j\|^2 = 1, \tag{13}$$

以及：

$$(u_i^p a_i)^T u_j^p a_j = 0. \tag{14}$$

于是 $||u^p_i a_i - u^p_j a_j||_2 = \sqrt{2}$。注意到 s* 是式 (7) 的最优解，可得：

$$\|x^p - U^pAs^*\|_2^2 + \lambda\|s^*\|_2^2 = L(s^*) \leq L(0) = \|x^p\|_2^2. \tag{15}$$

因此，$||x^p - U^pAs^*||_2 \leq ||x^p||_2$。于是式 (15) 意味着：

$$\frac{\|s_i^* - s_j^*\|_2}{\|x^p\|_2} \leq \frac{\sqrt{2}}{\lambda}. \tag{16}$$

上述定理中的分组效应表明，所得解依赖于相关性。定理 2 表明，如果 $u^p_i a_i$ 与 $u^p_j a_j$ 高度相关，那么 s_i^* 与 s_j^* 之间的差异接近于零。由此，在视图专属投影 U^p 的引导下，我们充分探索所学习共识锚点 A 之间的相关性，促进分组效应，并使高度相关的锚点聚为一组。

如上所述，我们在共享亲和矩阵学习中引入了 Frobenius 范数、非负约束和仿射约束。虽然形式简单，这三个约束的联合可以限制每个数据点在具有特定簇局部分布的仿射子空间中的描述方式，从而保证所学习共识锚点的鲁棒性。将基矩阵 U^pA 记为：

$$U^pA = [(U^pA)^1, \cdots, (U^pA)^t, \cdots, (U^pA)^k], \qquad (17)$$

其中 $(U^pA)^t$ 是位于第 t 个仿射子空间的基矩阵。用 $(U^pA)^t_{-i}$ 表示第 t 个仿射子空间中除基 $(U^pA)_i$ 之外的基矩阵，用 $(U^pA)^{-t}$ 表示除第 t 个仿射子空间之外所有仿射子空间中的基矩阵。上述三个矩阵中的基集合分别记为 $\Gamma((U^pA)^t)$、$\Gamma((U^pA)^{-t})$ 和 $\Gamma((U^pA)^t_{-i})$。

相对于 $(U^pA)^t$，一个基可能处于三种位置：边缘、内部和顶点，分别用 $\text{edge}((U^pA)^t)$、$\text{inside}((U^pA)^t)$ 和 $\text{vertex}((U^pA)^t)$ 表示。对于非顶点基（边缘与内部），先给出以下引理，再给出定理。

引理 1. 假设 A 和 D 均为方阵，对于维数相容的矩阵 B 和 C，有：

$$\left\| \begin{pmatrix} A & B \\ C & D \end{pmatrix} \right\|_* \geq \left\| \begin{pmatrix} A & \mathbf{0} \\ \mathbf{0} & D \end{pmatrix} \right\|_* = \|A\|_* + \|D\|_*$$

定理 3. 对于 t = 1, 2, ..., k 的任意非顶点基，原文写为 $(U^pA)_i \in \text{edge}((U^pA)^t)$ 且 $(U^pA)_i \in \text{inside}((U^pA)^t)$，若 $\Gamma((U^pA)^t)$ 与 $\Gamma((U^pA)^{-t})$ 不相交，则式 (6) 的最优解具有块对角结构。

证明. 我们通过逆否命题证明上述定理。假设式 (6) 存在一个最优解 S，且 S 不具有块对角性质。将块对角矩阵 W 定义如下：当 $(U^pA)_i$ 与 $(U^pA)_j$ 位于同一子空间时，$W_{ij} = S_{ij}$；否则 $W_{ij} = 0$。

$$W_{ij} = \begin{cases} S_{ij}, & \text{if } (U^pA)_i \text{ and } (U^pA)_j \text{ in same subspace} \\ 0, & \text{otherwise.} \end{cases} \qquad (18)$$

然后用 Q = S - W 表示 S 与 W 的差。用 $\mathbb{C} = \{j : (U^pA)_j \in \Gamma((U^pA)^t)\}$ 和 $\mathbb{k} = \{j : (U^pA)_j \notin \Gamma((U^pA)^t)\}$，分别表示第 t 个仿射子空间与其他仿射子空间中基的索引。位于 $\Gamma((U^pA)^t)$ 中、使 S 不满足块对角结构的每一个边缘或内部基 $(U^pA)_i$，可以写为：

$$\sum_{j\in\mathbb{k}} Q_{ij}(U^pA)_j = (U^pA)_i - \sum_{j\in\mathbb{C}} W_{ij}(U^pA)_j. \qquad (19)$$

由于 $\Sigma_{j\in\mathbb{C}} W_{ij} + \Sigma_{j\in\mathbb{k}} Q_{ij} = 1$，将式 (19) 两边除以 $\Sigma_{j\in\mathbb{k}} Q_{ij}$，得到：

$$\begin{aligned} \frac{\sum_{j\in\mathbb{k}} Q_{ij}(U^pA)_j}{\sum_{j\in\mathbb{k}} Q_{ij}} &= \frac{(U^pA)_i - \sum_{j\in\mathbb{C}} W_{ij}(U^pA)_j}{\sum_{j\in\mathbb{k}} Q_{ij}} \\ &= \frac{(U^pA)_i - \sum_{j\in\mathbb{C}} W_{ij}(U^pA)_j}{1 - \sum_{j\in\mathbb{C}} W_{ij}}. \end{aligned} \qquad (20)$$

可以看到，式 (20) 的左边和右边分别是 $\Gamma((U^pA)^{-t})$ 和 $\Gamma((U^pA)^t)$ 中的基。因此可推出，两集合确实相交。于是，根据引理 1，有 $||S||_* \geq ||W||_*$。因而 W 是最优解，并且具有块对角结构。尽管难以像定理 3 那样为顶点给出具有类似结构的充分条件，但我们发现，在实践中顶点所占比例远小于边缘和内部基。

为了将划分过程纳入统一框架，我们采用正交与非负分解，直接为数据分配簇。这样，基于因子矩阵恢复簇结构时不再需要额外后处理步骤。具体而言，我们对实际基施加正交约束。上述过程写为：

$$\begin{aligned}
&\min_{\alpha,U^p,A,S,G,F} \sum_{p=1}^{v} \alpha_p^2 ||X^p - U^p AS||_F^2 + \lambda \|S\|_F^2 \\
&+ \beta \|S - GF\|_F^2,\ s.t.\ S \geq 0,\ S^T \mathbf{1} = 1, \\
&\alpha^T \mathbf{1} = 1,\ (U^p)^T U^p = I,\ A^T A = I,\ G^T G = I, \\
&F_{ij} \in \{0,1\},\ \sum_{i=1}^{k} F_{ij} = 1,\ \forall j = 1,2,\cdots,n,
\end{aligned} \tag{21}$$

其中 α_p^2 表示所学习的系数，$\beta > 0$ 是平衡不同项的参数，$G \in R^{l \times k}$ 表示质心矩阵，$F \in R^{k \times n}$ 表示簇分配：若第 j 个数据点不属于第 i 个簇，则 $F_{ij} = 0$，否则为 1。

2.3. 优化

为求解式 (21)，我们设计交替优化算法，在固定其他变量的条件下依次求解各个变量。

U^p 子问题：固定其他变量，关于 U^p 的目标函数为：

$$\min_{U^p} \sum_{p=1}^{v} \alpha_p^2 ||X^p - U^p AS||_F^2,\ \ s.t.\ \ (U^p)^T U^p = I. \tag{22}$$

通过迹运算，将上述优化问题转换为：

$$\max_{U^p} Tr((U^p)^T C^p),\ \ s.t.\ \ (U^p)^T U^p = I, \tag{23}$$

其中 $C^v = X^p S^T A^T$。假设 C^v 的奇异值分解（SVD）为 $U'_C \Sigma_C V_C^T$，则通过计算 $U'_C V_C^T$ 即可得到最优 U^p。

S 子问题：固定其他变量，关于 S 的目标函数为：

$$\begin{aligned}
&\min_{S} \sum_{p=1}^{v} \alpha_p^2 ||X^p - U^p AS||_F^2 + \lambda \|S\|_F^2 + \beta \|S - GF\|_F^2, \\
&s.t.\ S \geq 0,\ S^T \mathbf{1} = 1.
\end{aligned} \tag{24}$$

将其改写为如下二次规划（QP）问题：

$$\min h^T S_{:,j} + \frac{1}{2} S_{:,j}^T W S_{:,j}, \ \ s.t.\ S \geq 0,\ S_{:,j}^T \mathbf{1} = 1, \tag{25}$$

其中 $h^T = -2\Sigma^v_{p=1}(X^p_{:,j})^T U^p A - 2\beta F_{:,j}^T G^T$，$W = 2(\Sigma^v_{p=1}\alpha_p^2 + \lambda + \beta)I$。因此，通过求解该二次规划问题，对 S 的每一列进行优化。

A 子问题：固定其他变量，关于 A 的目标函数为：

$$\min_A \sum_{p=1}^{v} \alpha_p^2 ||X^p - U^p A S||_F^2, \ \ s.t.\ A^T A = I. \tag{26}$$

类似地，式 (26) 等价于以下问题：

$$\max_A Tr(A^T B), \ \ s.t.\ A^T A = I, \tag{27}$$

其中 $B = \Sigma^v_{p=1}\alpha_p^2 (U^p)^T X^p S^T$。于是最优 A 为 $U'_B V_B^T$，其中 $B = U'_B \Sigma_B V_B^T$。

F 子问题：固定其他变量，关于 F 的目标函数为：

$$\begin{aligned} &\min_F \beta \|S - GF\|_F^2, \ \ s.t.\ F_{ij} \in \{0,1\}, \\ &\sum_{i=1}^{k} F_{ij} = 1,\ \forall j = 1, 2, \cdots, n. \end{aligned} \tag{28}$$

对每个对象独立求解该优化问题，得到：

$$\min_{F_{:,j}} \beta \|S_{:,j} - GF_{:,j}\|^2, \ \ s.t.\ F_{:,j} \in \{0,1\}^k,\ \|F_{:,j}\|_1 = 1. \tag{29}$$

可通过下式找到最优行：

$$i^* = \arg\min_i \|S_{:,j} - G_{:,i}\|^2. \tag{30}$$

G 子问题：固定其他变量，关于 G 的目标函数为：

$$\min_G \beta \|S - GF\|_F^2, \ \ s.t.\ G^T G = I. \tag{31}$$

将关于 G 的优化问题改写为：

$$\max_G Tr(G^T J), \ \ s.t.\ G^T G = I, \tag{32}$$

其中 $J = SF^T$。于是最优 G 为 $U'_J V_J^T$，其中 $J = U'_J \Sigma_J V_J^T$。

α_p 子问题：固定其他变量，关于 α_p 的目标函数为：

$$\min_{\alpha} \sum_{p=1}^{v} \alpha_p^2 ||X^p - U^p AS||_F^2, \quad s.t.\ \alpha^T \mathbf{1} = 1. \tag{33}$$

根据柯西-布尼亚科夫斯基-施瓦茨不等式，最优 α_p 可由下式获得：

$$\alpha_p = \frac{\frac{1}{||X^p - U^p AS||_F}}{\sum_{p=1}^{v} \frac{1}{||X^p - U^p AS||_F}}. \tag{34}$$

由于各子问题的凸性，目标函数在每次迭代中单调下降，直至收敛。RCSC 的过程列于算法 1。

算法 1. RCSC 算法

输入：多视图数据集 $\{X^p\}_{p=1}^v$，参数 λ、β，簇数 k。

输出：簇分配 F。

1：初始化 A、U^p、$\{\alpha_p\}_{p=1}^v$、S、F 和 G。

2：重复以下步骤。

3：求解式 (24)，更新 S。

4：求解式 (22)，更新 $\{U^p\}_{p=1}^v$。

5：求解式 (26)，更新 A。

6：求解式 (31)，更新 G。

7：求解式 (28)，更新 F。

8：求解式 (33)，更新 α。

9：直至收敛。

2.4. 复杂度分析

本方法的计算开销包括优化所有变量所产生的开销。具体而言，更新 S 需要 $O(l^3n)$。优化 U^p 时，每个视图的矩阵乘法需要 $O(d_p dk^2)$，SVD 需要 $O(d_p d^2)$。优化 A 时，矩阵乘法需要 $O(dlk^2)$，SVD 需要 $O(dl^2)$。优化 F 需要 $O(lnk)$。更新 G 需要 $O(lk^2 + lk^3)$，包括 SVD 与矩阵乘法的时间开销。更新 α_p 需要 $O(1)$。

本方法的总时间开销为 $O((pd^2 + pdk^2 + dlk^2 + nl^3 + lk^2 + lk^3 + dl^2 + lnk)o)$，其中 o 表示迭代总次数，$p = \Sigma_{p=1}^v d_p$。由于 $n \gg k$ 且 $n \gg l$，本方法的计算开销近似线性，即 $O(n)$。

3. 实验

本节在八个多视图数据集上，使用不同指标，从有效性与效率两个方面，将所提出方法与代表性方法进行比较。

3.1. 数据集与实验设置

实验采用八个真实世界多视图数据集：ORL、Mfeat、Caltech101-20、Caltech101-all、SUNRGBD（Song et al., 2015）、NUSWIDEOBJ（Chua et al., 2009）、AWA 和 YoutubeFace。比较的八种代表性多视图聚类方法包括 AMGL（Nie et al., 2016）、SFMC（Li et al., 2022）、BMVC（Zhang et al., 2019）、LMVSC（Kang et al., 2020）、MSGL（Kang et al., 2022）、FRMVS（Wang et al., 2022）、EOMSC-CA（Liu et al., 2022c）和 OMSC（Chen et al., 2022）。

评估所有方法的聚类性能时，需要确定锚点数量。为保证公平，对比较方法均使用最佳参数。我们的方法在 [2k, 3k, ..., 7k] 范围内调整锚点数，其中 k 为数据集中的簇总数。为减少随机性，每个实验重复 20 次，并报告均值与方差。采用三种广泛使用的指标评价聚类结果：准确率（ACC）、归一化互信息（NMI）与 F1 分数。各项指标的值越高，表示在该数据集上的聚类表现越好。

首先研究参数 λ 和 β 对最终聚类性能的影响。这两个参数用于协调划分项和 Frobenius 范数项的重要程度。图 1 给出了 λ 与 β 变化时所提出方法的聚类性能。可以看到，适当设置这两个参数通常有利于不同数据集上的聚类结果。根据图 1，当 λ = 0.1 且 β = 0.1 时，在不同数据集上通常能够取得较理想的结果。此外，在不同数据集上，所提出方法在 λ 与 β 的考察范围内总体表现稳定，表明 RCSC 对这两个参数总体具有鲁棒性。

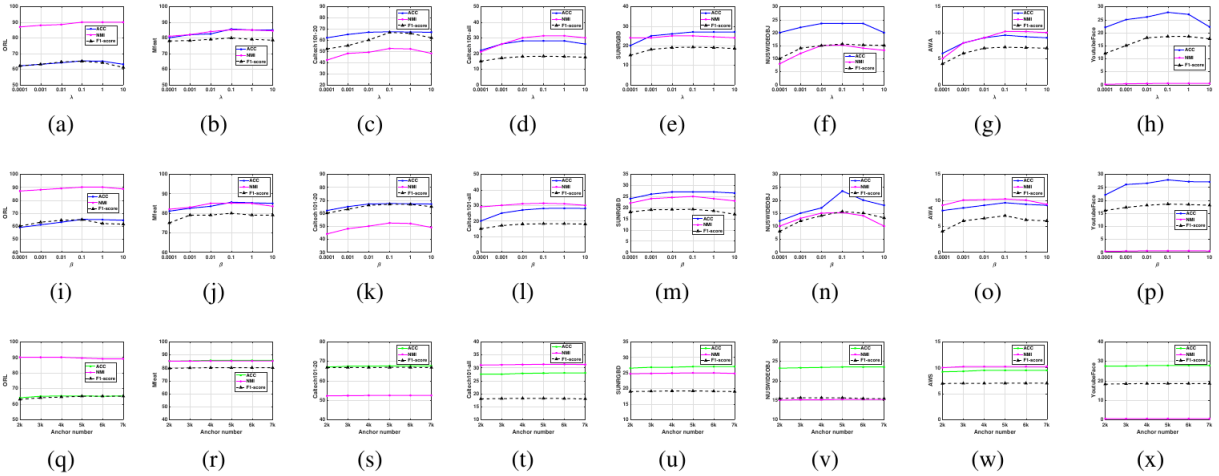


图 1. 前两行分别为八个数据集上的 λ 和 β 参数选择结果；第三行为八个数据集上的锚点数量敏感性研究。ACC 为准确率，NMI 为归一化互信息，F1-score 为 F1 分数；Anchor number 为锚点数量。保留原图内数据集名称与英文缩写。

3.2. 实验结果与分析

本节在多个多视图数据集上，将所提出方法与八种代表性方法比较。具体而言，表 1-3 分别报告所有多视图聚类方法在 ACC、NMI 和 F1 分数方面的结果。N/A 表示由于内存不足，方法无法在相应数据集上完成计算。根据表 1-3 的结果，可得出以下结论。

Dataset	AMGL	SFMC	BMVC	LMVSC	MSGL	FPMVS	EOMSC-CA	OMSC	Ours
ORL	64.50±0.01	61.40±0.05	48.70±0.05	58.60±0.02	21.00±0.05	52.00±0.50	62.20±0.05	63.80±0.00	**65.20±0.00**
Mfeat	82.60±0.02	75.50±0.20	69.30±0.05	81.75±0.05	75.40±0.02	82.20±0.05	82.25±0.03	84.00±0.05	**85.60±0.00**
Caltech101-20	28.70±0.20	59.40±0.05	16.80±0.05	29.00±0.30	48.00±0.02	66.15±0.10	64.10±0.50	65.00±0.10	**67.40±0.00**
Caltech101-all	14.80±0.01	17.70±0.05	21.20±0.03	15.50±0.01	14.10±0.02	27.50±0.05	22.30±0.03	24.00±0.00	**28.00±0.50**
SUNRGBD	9.80±0.01	11.30±0.05	16.70±0.01	18.00±0.05	13.00±0.01	23.40±0.05	23.70±0.05	25.20±0.00	**27.00±0.00**
NUSWIDEOBJ	N/A	12.20±0.05	12.90±0.05	14.70±0.05	12.00±0.05	19.20±0.05	19.60±0.05	21.00±0.05	**23.50±0.00**
AWA	N/A	3.92±0.03	8.60±0.05	7.20±0.03	8.00±0.02	8.90±0.01	8.65±0.05	9.00±0.10	**10.50±0.10**
YoutubeFace	N/A	N/A	8.90±0.05	14.00±0.02	16.70±0.01	23.00±0.03	26.45±0.05	26.50±0.00	**27.80±0.00**

表 1. 所有数据集上的 ACC（%）聚类结果。N/A 表示内存不足；Dataset 为数据集，Ours 为本文方法。所有数值、误差项与原文强调样式均原样保留。

Dataset	AMGL	SFMC	BMVC	LMVSC	MSGL	FPMVS	EOMSC-CA	OMSC	Ours
ORL	87.10±0.07	82.70±0.01	67.70±0.03	78.50±0.03	43.70±0.02	74.40±0.05	88.10±0.02	88.50±0.10	**90.00±0.00**
Mfeat	84.70±0.05	84.80±0.10	66.05±0.15	76.00±0.20	76.54±0.05	79.40±0.01	83.20±0.15	84.20±0.10	**85.32±0.15**
Caltech101-20	47.50±0.20	42.80±0.00	16.20±0.03	41.20±0.10	31.50±0.05	**63.30±0.05**	51.10±0.05	51.80±0.30	52.40±0.00
Caltech101-all	35.30±0.01	26.10±0.03	**42.50±0.04**	33.30±0.02	26.10±0.02	34.10±0.05	24.65±0.05	30.00±0.00	31.30±0.00
SUNRGBD	18.50±0.10	2.30±0.05	19.50±0.05	24.50±0.05	9.30±0.05	24.10±0.05	22.50±0.01	24.30±0.00	**25.00±0.10**
NUSWIDEOBJ	N/A	0.96±0.01	12.90±0.02	12.80±0.05	5.70±0.03	13.20±0.05	13.20±0.15	14.00±0.00	**15.20±0.00**
AWA	N/A	0.30±0.05	9.70±0.02	8.50±0.05	7.90±0.03	8.50±0.03	9.70±0.03	10.00±0.02	**10.22±0.00**
YoutubeFace	N/A	N/A	5.90±0.05	**11.80±0.01**	0.07±0.01	2.40±0.01	0.32±0.01	0.37±0.00	0.50±0.00

表 2. 所有数据集上的 NMI（%）聚类结果。N/A 表示内存不足；Dataset 为数据集，Ours 为本文方法。

Dataset	AMGL	SFMC	BMVC	LMVSC	MSGL	FPMVS	EOMSC-CA	OMSC	Ours
ORL	51.20±0.03	30.60±0.05	30.50±0.04	45.90±0.09	51.50±0.20	38.40±0.15	62.10±0.00	63.20±0.10	**65.00±0.00**
Mfeat	79.80±0.05	71.10±0.15	58.80±0.01	72.50±0.02	70.10±0.02	76.00±0.40	77.00±0.01	78.20±0.00	**79.90±0.00**
Caltech101-20	21.80±0.05	31.60±0.02	11.40±0.20	25.60±0.50	41.80±0.05	66.00±0.05	64.70±0.20	65.00±0.10	**66.79±0.20**
Caltech101-all	4.05±0.10	4.65±0.10	18.00±0.05	10.50±0.05	8.60±0.04	17.90±0.03	10.80±0.03	15.00±0.00	**18.20±0.15**
SUNRGBD	6.40±0.40	12.10±0.00	10.20±0.01	11.60±0.20	9.50±0.15	16.00±0.05	15.30±0.05	17.00±0.00	**19.20±0.00**
NUSWIDEOBJ	N/A	11.50±0.01	8.80±0.02	9.30±0.05	8.50±0.05	13.50±0.07	13.60±0.05	14.50±0.00	**15.60±0.10**
AWA	N/A	4.60±0.03	5.59±0.02	3.60±0.05	4.20±0.01	6.20±0.05	5.90±0.05	6.20±0.00	**7.00±0.20**
YoutubeFace	N/A	N/A	5.80±0.02	8.30±0.01	15.00±0.10	14.00±0.05	16.40±0.01	17.10±0.00	**18.50±0.00**

表 3. 所有数据集上的 F1 分数（%）聚类结果。N/A 表示内存不足；Dataset 为数据集，Ours 为本文方法。

• 对大多数数据集，所提出方法在不同指标下取得更理想的性能，在规模较大的多视图数据集上也表现良好。例如，在 AWA 上，本方法的 NMI 比 MSGL 高约 2.32%。

• 与一般基于图的方法相比，在大规模多视图数据集上，基于锚点的方法在大多数情况下倾向于获得更好的三项指标表现。这说明基于锚点构建图有助于处理大规模多视图数据集。

• 在大多数多视图数据集上，本方法始终优于其他基于锚点的方法。这验证了保证所学习共识锚点鲁棒性的必要性，也验证了在视图专属投影引导下，探索所学习共识锚点之间的相关性、促进分组效应并将高度相关锚点聚在一起，对高效多视图子空间聚类的必要性。

3.3. 敏感性分析与鲁棒性研究

本节研究锚点总数对聚类结果的影响。为简单起见，固定共享维数，在多个数据集上根据不同指标对锚点数量进行敏感性分析。根据图 1，所提出方法未受到锚点数量的显著影响，不同锚点数下的聚类结果相对稳定。

我们还研究了所提出方法在不同数据集上的鲁棒性。具体而言，随机选择多视图数据集的一半数据，加入高斯白噪声进行污染。对选中数据点 x^p_i 的加噪方式为 $\hat{x}^p_i = x^p_i + pj$，其中 $\hat{x}^p_i \in [0,255]$，p 为污染比例，j 为服从标准高斯分布的噪声。根据图 2，与其他方法相比，所提出方法在不同数据集上具有鲁棒性并表现更好。原因在于，在仿射子空间中保证所学习共识锚点的鲁棒性，有助于高效多视图子空间聚类获得满意表现。

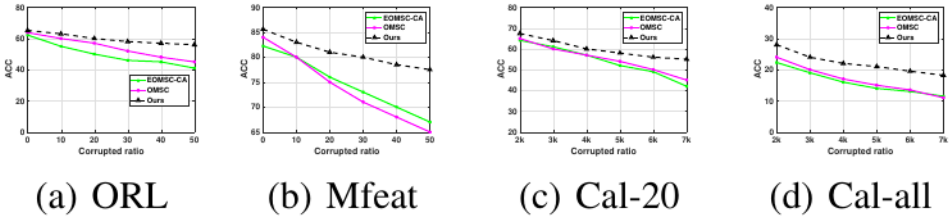


图 2. 采用 ACC 指标，在不同数据集上研究本方法的鲁棒性。Corrupted ratio 为污染比例，Ours 为本文方法，Cal-20/Cal-all 对应 Caltech101-20/Caltech101-all。原图后两个子图的横轴刻度保留原样，相关疑点见译者校勘记录。

3.4. 运行时间

我们报告比较方法和本方法在不同数据集上的执行时间。注意，Caltech101-20 与 Caltech101-all 是 Caltech101 数据集的两个版本，为简单起见这里只列出 Caltech101-all 的运行时间。如图 3 所示，在大多数多视图数据集上，所提出方法的运行时间对数与现有高效方法（如 MSGL）相当。因此，本方法在不同数据集上能够获得有优势的聚类结果，同时保持相对有竞争力的效率。这是因为在统一框架中联合建模鲁棒共识锚点与公共簇结构，对引导多视图聚类效率至关重要。得到最终结果不需要额外聚类算法，例如谱聚类。

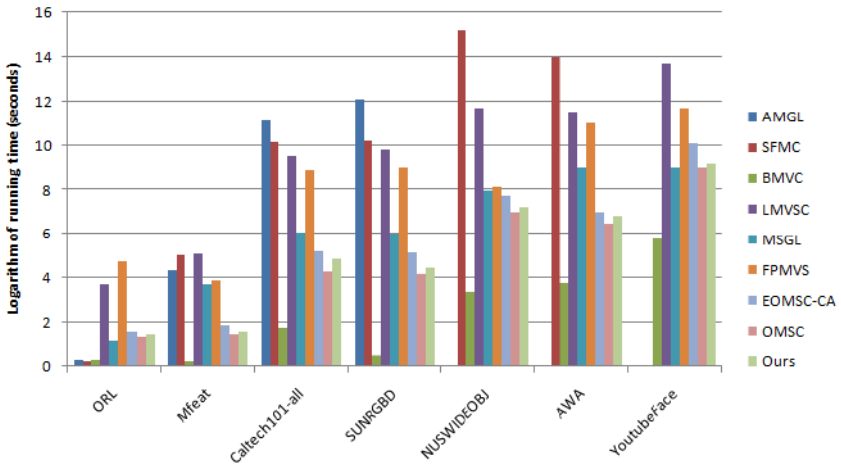


图 3. 不同数据集上的运行时间对数。纵轴为运行时间（秒）的对数，Ours 为本文方法；保留原图中的方法名称、数据集名称与数值标记。

4. 结论

本文提出新的 RCSC 方法。从理论上证明，当目标函数满足一定条件时，可以得到块对角锚点图。作为一种特例，我们在共识锚点学习中给出结合 Frobenius 范数、非负约束和仿射约束的模型，以保证所学习共识锚点的鲁棒性，实现高效多视图聚类，并研究仿射子空间中簇的具体局部分布。大量实验根据三种指标，在不同多视图数据集上验证了所提出方法的有效性与效率。

致谢

本工作得到东方英才计划领军项目（项目号 BJKJ2024011）和国家自然科学基金（62402303）的部分资助。

影响声明

本文所介绍工作的目标是推进机器学习领域的发展。我们的工作可能带来许多社会影响，但我们认为其中没有需要在此特别强调的事项。

译者校勘记录（非原文）

本译文忠实保留原文的数学表达与实验数值，不对其理论正确性作新增背书。原文若干位置存在记号或论证不一致：定理 1 从独立性转用正交性；定理 2 的维数写为 $d_p \times n$，约束使用 S，而证明令受约束最优解导数为零并比较 L(0)；式 (25) 的 h 项与前式权重、式 (34) 与平方加权目标之间也需原作者核对。定理 3 的边缘/内部关系、基索引及核范数引理与 Frobenius 目标之间的衔接均按原文保留。上述说明是校勘提示，未擅自修改证明。

正文比较方法名为 FRMVS，而表头为 FPMVS；图 1 的子图 (w) 数据集名为 AWS，而正文为 AWA；图 2 的子图 (c)、(d) 横轴使用 2k 至 7k 刻度。原图与表格保留这些差异。原文将重复实验统计量称为 variances，本译文译为“方差”，未根据 ± 记号改写为标准差。原文声称 AWA 上 NMI 提高约 2.32%，表 2 的对应数值为 10.22 与 7.90，译文保留原句表述。

参考文献

以下完整保留原文全部英文参考文献的作者、题名、出版物、年份与页码。书目题名不另行翻译，以保留检索一致性；这不是正文遗漏。

References

Cao, X., Zhang, C., Fu, H., Liu, S., and Zhang, H. Diversity-induced multi-view subspace clustering. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 586–594, 2015.

Chen, M., Huang, L., Wang, C., and Huang, D. Multi-view clustering in latent embedding space. In *The AAAI Conference on Artificial Intelligence*, pp. 3513–3520, 2020.

Chen, M., Wang, C., Huang, D., Lai, J., and Yu, P. S. Efficient orthogonal multi-view subspace clustering. In *The ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 127–135, 2022.

Chua, T., Tang, J., Hong, R., Li, H., Luo, Z., and Zheng, Y. NUS-WIDE: a real-world web image database from national university of singapore. In *Proceedings of the 8th ACM International Conference on Image and Video Retrieval*, 2009.

Jain, A. K. Data clustering: 50 years beyond k-means. In *Machine Learning and Knowledge Discovery in Databases*, volume 5211, pp. 3–4, 2008.

Kang, Z., Zhou, W., Zhao, Z., Shao, J., Han, M., and Xu, Z. Large-scale multi-view subspace clustering in linear time. In *The AAAI Conference on Artificial Intelligence*, pp. 4412–4419, 2020.

Kang, Z., Lin, Z., Zhu, X., and Xu, W. Structured graph learning for scalable subspace clustering: From single view to multiview. *IEEE Trans. Cybern.*, 52(9):8976–8986, 2022.

Li, X., Zhang, H., Wang, R., and Nie, F. Multiview clustering: A scalable and parameter-free bipartite graph fusion method. *IEEE Trans. Pattern Anal. Mach. Intell.*, 44(1): 330–344, 2022.

Liang, Y., Huang, D., Wang, C., and Yu, P. S. Multi-view graph learning by joint modeling of consistency and inconsistency. *CoRR*, abs/2008.10208, 2020.

Liu, C., Wu, Z., Wen, J., Xu, Y., and Huang, C. Localized sparse incomplete multi-view clustering. *IEEE Transactions on Multimedia*, 25:5539–5551, 2023a.

Liu, C., Wen, J., Wu, Z., Luo, X., Huang, C., and Xu, Y. Information recovery-driven deep incomplete multiview clustering network. *IEEE Transactions on Neural Networks and Learning Systems*, 35(11):15442–15452, 2024.

Liu, C., Wen, J., Xu, Y., Zhang, B., Nie, L., and Zhang, M. Reliable representation learning for incomplete multiview missing multi-label classification. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, pp. 1–17, 2025.

Liu, J., Liu, X., Xiong, J., Liao, Q., Zhou, S., Wang, S., and Yang, Y. Optimal neighborhood multiple kernel clustering with adaptive local kernels. *IEEE Trans. Knowl. Data Eng.*, 34(6):2872–2885, 2022a.

Liu, J., Liu, X., Yang, Y., Guo, X., Kloft, M., and He, L. Multiview subspace clustering via co-training robust data representation. *IEEE Trans. Neural Networks Learn. Syst.*, 33(10):5177–5189, 2022b.

Liu, J., Liu, X., Yang, Y., Liao, Q., and Xia, Y. Contrastive multi-view kernel learning. *IEEE Trans. Pattern Anal. Mach. Intell.*, 45(8):9552–9566, 2023b.

Liu, S., Wang, S., Zhang, P., Xu, K., Liu, X., Zhang, C., and Gao, F. Efficient one-pass multi-view subspace clustering with consensus anchors. In *AAAI Conference on Artificial Intelligence*, pp. 7576–7584, 2022c.

Nie, F., Li, J., and Li, X. Parameter-free auto-weighted multiple graph learning: A framework for multiview clustering and semi-supervised classification. In *Proceedings of the International Joint Conference on Artificial Intelligence*, pp. 1881–1887, 2016.

Nie, F., Cai, G., and Li, X. Multi-view clustering and semi-supervised classification with adaptive neighbours. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pp. 2408–2414, 2017a.

Nie, F., Li, J., and Li, X. Self-weighted multiview clustering with multiple graphs. In *Proceedings of the International Joint Conference on Artificial Intelligence*, pp. 2564–2570, 2017b.

Pu, N., Li, W., Ji, X., Qin, Y., Sebe, N., and Zhong, Z. Federated generalized category discovery. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 28741–28750, 2024.

Qin, Y. and Qian, L. Fast elastic-net multi-view clustering: A geometric interpretation perspective. In *Proceedings of the 32nd ACM International Conference on Multimedia*, pp. 10164–10172, 2024.

Qin, Y., Wu, H., and Feng, G. Structured subspace learning-induced symmetric nonnegative matrix factorization. *Signal Process.*, 186:108115, 2021.

Qin, Y., Wu, H., Zhang, X., and Feng, G. Semi-supervised structured subspace learning for multi-view clustering. *IEEE Trans. Image Process.*, 31:1–14, 2022a.

Qin, Y., Wu, H., Zhao, J., and Feng, G. Enforced block diagonal subspace clustering with closed form solution. *Pattern Recognit.*, 130:108791, 2022b.

Qin, Y., Feng, G., Ren, Y., and Zhang, X. Block-diagonal guided symmetric nonnegative matrix factorization. *IEEE Trans. Knowl. Data Eng.*, 35(3):2313–2325, 2023a.

Qin, Y., Feng, G., Ren, Y., and Zhang, X. Consistency-induced multiview subspace clustering. *IEEE Trans. Cybern.*, 53(2):832–844, 2023b.

Qin, Y., Qin, C., Zhang, X., Qi, D., and Feng, G. Nim-nets: Noise-aware incomplete multi-view learning networks. *IEEE Trans. Image Process.*, 32:175–189, 2023c.

Qin, Y., Sun, Y., Peng, D., Zhou, J. T., Peng, X., and Hu, P. Cross-modal active complementary learning with self-refining correspondence. In *Advances in Neural Information Processing Systems*, 2023d.

Qin, Y., Zhang, X., Shen, L., and Feng, G. Maximum block energy guided robust subspace clustering. *IEEE Trans. Pattern Anal. Mach. Intell.*, 45(2):2652–2659, 2023e.

Qin, Y., Pu, N., and Wu, H. Elastic multi-view subspace clustering with pairwise and high-order correlations. *IEEE Trans. Knowl. Data Eng.*, 36(2):556–568, 2024a.

Qin, Y., Pu, N., and Wu, H. EDMC: efficient multi-view clustering via cluster and instance space learning. *IEEE Trans. Multim.*, 26:5273–5283, 2024b.

Qin, Y., Qin, C., Zhang, X., and Feng, G. Dual consensus anchor learning for fast multi-view clustering. *IEEE Trans. Image Process.*, 33:5298–5311, 2024c.

Qin, Y., Tang, Z., Wu, H., and Feng, G. Flexible tensor learning for multi-view clustering with markov chain. *IEEE Trans. Knowl. Data Eng.*, 36(4):1552–1565, 2024d.

Qin, Y., Feng, G., and Zhang, X. Scalable one-pass incomplete multi-view clustering by aligning anchors. In *Association for the Advancement of Artificial Intelligence*, pp. 20042–20050, 2025a.

Qin, Y., Pu, N., Sebe, N., and Feng, G. Latent space learning-based ensemble clustering. *IEEE Trans. Image Process.*, 34:1259–1270, 2025b.

Qin, Y., Pu, N., Wu, H., and Sebe, N. Margin-aware noise-robust contrastive learning for partially view-aligned problem. *ACM Trans. Knowl. Discov. Data*, 19(1):26:1–26:20, 2025c.

Qin, Y., Pu, N., Wu, H., and Sebe, N. Discriminative anchor learning for efficient multi-view clustering. *IEEE Trans. Multim.*, 27:1386–1396, 2025d.

Qin, Y., Zhang, X., Yu, S., and Feng, G. A survey on representation learning for multi-view data. *Neural Networks*, 181:106842, 2025e.

Song, S., Lichtenberg, S. P., and Xiao, J. SUN RGB-D: A RGB-D scene understanding benchmark suite. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 567–576, 2015.

Sun, Y., Qin, Y., Li, Y., Peng, D., Peng, X., and Hu, P. Robust multi-view clustering with noisy correspondence. *IEEE Trans. Knowl. Data Eng.*, 36(12):9150–9162, 2024.

Wang, H., Yang, Y., and Liu, B. GMC: graph-based multi-view clustering. *IEEE Trans. Knowl. Data Eng.*, 32(6):1116–1129, 2020.

Wang, S., Liu, X., Zhu, X., Zhang, P., Zhang, Y., Gao, F., and Zhu, E. Fast parameter-free multi-view subspace clustering with consensus anchor guidance. *IEEE Trans. Image Process.*, 31:556–568, 2022.

Yang, B., Zhang, X., Nie, F., Wang, F., Yu, W., and Wang, R. Fast multi-view clustering via nonnegative and orthogonal factorization. *IEEE Trans. Image Process.*, 30:2575–2586, 2021.

Yang, B., Zhang, X., Nie, F., Chen, B., Wang, F., Nan, Z., and Zheng, N. Ecca: Efficient correntropy-based clustering algorithm with orthogonal concept factorization.

IEEE Transactions on Neural Networks and Learning Systems, pp. 1–14, 2022.

Zhan, K., Nie, F., Wang, J., and Yang, Y. Multiview consensus graph clustering. *IEEE Trans. Image Process.*, 28 (3):1261–1270, 2019.

Zhang, Z., Liu, L., Shen, F., Shen, H. T., and Shao, L. Binary multi-view clustering. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(7):1774–1782, 2019.